MINIPROJETO • MÓDULO 4

Construção e Avaliação de um Lakehouse

Enunciado, tarefas, entregáveis e critérios de avaliação

1. Contexto e enunciado

O desafio parte de um problema de negócio e exige decisões arquiteturais justificadas.

A organização
A AulaStore é uma empresa varejista omnichannel que reúne dados de lojas físicas, e-commerce, aplicativo, CRM, atendimento, parceiros e sensores. Os dados estão distribuídos em diferentes sistemas e formatos.

O problema
A diretoria deseja integrar esses dados para compreender vendas, comportamento digital e percepção dos clientes, sem sobrecarregar os sistemas operacionais.

O desafio
Você foi contratado como arquiteto de dados. Sua missão é propor, construir e avaliar um Lakehouse de pequena escala, demonstrando como dados heterogêneos podem ser armazenados, organizados em tabelas, processados e transformados em informação para decisão.

Pergunta central
Como a arquitetura proposta transforma dados dispersos em capacidade analítica?

Foco acadêmico
Justificar escolhas, explicitar trade-offs e avaliar limitações.

Resultado esperado
Lakehouse funcional + análise + avaliação pós-projeto.

2. Objetivos de aprendizagem

Ao final, você deve demonstrar domínio conceitual e capacidade de aplicação.

- Construir um Lakehouse: implementar uma arquitetura de pequena escala, com armazenamento organizado e dados de diferentes naturezas.
- Conduzir análises: consultar, transformar e combinar dados para responder perguntas de negócio.
- Descrever o percurso: documentar requisitos, ingestão, armazenamento, tabelas, processamento, consumo e decisões técnicas.
- Sintetizar lições: identificar o que funcionou, dificuldades, riscos e aprendizados.
- Avaliar a arquitetura: discutir vantagens, limitações, custos, escalabilidade e adequação ao problema.
- Explicitar separações arquiteturais: distinguir Storage, Table Format, Compute e Consumption.

3. Escopo: dados e fontes

O projeto deve trabalhar deliberadamente com heterogeneidade.

Fonte	Formato	Natureza	Finalidade / característica
Vendas	CSV	Estruturado	Transacional
Clientes	CSV	Estruturado	Cadastro
Produtos	CSV	Estruturado	Catálogo
Eventos Web/App	JSON	Semiestruturado	Alta frequência
Avaliações	CSV + texto	Misto	Opinião
Atendimento	TXT	Não estruturado	Conversas

Regra do escopo

Não é necessário usar todas as fontes, mas o projeto deve demonstrar integração de pelo menos três fontes e de dados estruturados com dados não estruturados ou semiestruturados.

4. Etapas do projeto

Cada etapa deve gerar evidências que serão incorporadas ao relatório final.

Etapa	Foco	Evidência
1	Definir requisitos	Problema, objetivos, perguntas analíticas, requisitos funcionais e não funcionais.
2	Projetar arquitetura	Escolher componentes, camadas, formatos e fluxo; justificar trade-offs.
3	Construir o armazenamento	Criar a área de armazenamento e convencionar organização dos arquivos.
4	Criar e alimentar as tabelas	Preservar Bronze e transformar dados em tabelas Silver e Gold.
5	Processar e integrar	Limpar, padronizar, validar e combinar as fontes.
6	Analisar e consumir	Executar consultas/transformações, gerar visualizações e formular insights.
7	Avaliar e aprender	Confrontar resultados com objetivos, discutir limitações e registrar lições.

Princípio arquitetural

As caixas “Storage”, “Table Format”, “Compute” e “Consumption” representam responsabilidades distintas. Você deve identificar explicitamente onde cada responsabilidade ocorre na solução adotada.

5. Tarefas — Parte 1 | Planejamento e construção

O aluno deve produzir evidências técnicas, não apenas descrever o que faria.

T1	**Definir o problema** Formalizar o problema de negócio e pelo menos 5 perguntas analíticas.
T2	**Definir requisitos** Registrar requisitos funcionais e não funcionais; definir critérios de sucesso.
T3	**Mapear dados** Inventariar fontes, formatos, tipos, chaves e frequência de atualização.
T4	**Projetar a arquitetura** Desenhar explicitamente: Fonte → Ingestão → Storage → Processamento/SQL → Camadas tratadas → Consumo.
T5	**Construir a estrutura Lakehouse** Implementar a organização Bronze/Silver/Gold conforme as definições desta atividade.
T6	**Alimentar o Lakehouse** Ingerir as fontes selecionadas, preservar os arquivos originais e registrar como as tabelas foram criadas.

T4 — separação arquitetural obrigatória

Na arquitetura desenhada, identifique explicitamente: Storage ≠ Table Format ≠ Compute ≠ Consumption. Para cada componente, informe sua função, tecnologia escolhida e justificativa.

6. Tarefas — Parte 2 | Integração e análise

O núcleo do projeto é demonstrar que o Lakehouse amplia a capacidade de combinar fontes.

T7	**Processar** Limpar, padronizar, validar e transformar os dados; registrar regras.
T8	**Integrar** Combinar dados estruturados com dados semiestruturados e/ou não estruturados.
T9	**Preparar consumo** Criar tabelas Gold adequadas aos casos de uso analítico.
T10	**Analisar** Responder pelo menos 5 perguntas analíticas usando SQL, Python ou equivalente.
T11	**Gerar insights** Apresentar pelo menos 3 conclusões de negócio sustentadas pelos dados.
T12	**Comunicar resultados** Construir dashboard, relatório analítico ou conjunto de visualizações interpretadas.

7. Tarefas específicas do Lakehouse

Estas tarefas tornam explícito o que diferencia o exercício de um simples Data Lake baseado em arquivos.

T13	**Criar tabelas Lakehouse** A partir dos dados processados, criar tabelas Silver e Gold usando o table format adotado. Registrar nome, finalidade, esquema, chaves e regras de transformação.
T14	**Demonstrar gerenciamento de tabela** Executar pelo menos uma operação que evidencie capacidade de gerenciamento do table format, como evolução de schema, histórico/time travel, atualização/upsert ou outra operação equivalente suportada pela tecnologia escolhida.
~~**T15**~~	~~**Comparar Data Lake × Lakehouse**~~ ~~Explicar o que a arquitetura ganhou ao introduzir tabelas, metadados e capacidades de gerenciamento sobre o armazenamento de arquivos. A comparação deve ser baseada em evidências do próprio miniprojeto.~~

8. Perguntas analíticas sugeridas

As perguntas podem ser substituídas, desde que preservem o propósito do projeto.

1. Quais categorias de produtos apresentam maior faturamento (bruto, líquido)?
2. Quais produtos possuem maior volume de vendas e melhor avaliação (venda em unidade, nº de pedido)?
3. Existe relação entre avaliação média e volume de vendas?
4. Quais comportamentos digitais antecedem uma compra?
5. Quais categorias concentram maior proporção de avaliações negativas?
6. Quais temas aparecem com maior frequência nas reclamações?

Regra de ouro

Não basta apresentar números: cada análise deve responder "o que isso significa para o negócio?".

9. Avaliação pós-projeto e lições aprendidas

A avaliação deve confrontar a arquitetura construída com os objetivos e requisitos definidos no início.

Vantagens a analisar

• Flexibilidade para diferentes formatos • Centralização de fontes heterogêneas • Preservação de dados brutos
• Tabelas analíticas gerenciáveis • Reuso para diferentes análises • Potencial de escalabilidade

Limitações e riscos a analisar

• Complexidade de governança • Qualidade pode se tornar um problema • Custos de armazenamento/processamento em escala • Dependência de metadados e catálogo • Risco de "data swamp" • Limites do ambiente gratuito

Perguntas de reflexão

- A solução atendeu aos requisitos?
- O que mudaria em 1.000× mais dados? *(Por análise de arquitetura, identificando componentes e recursos. Não precisa simular um cenário 1000x)*
- Onde surgiram gargalos?
- O que deveria ser automatizado?
- Que benefício concreto surgiu ao introduzir tabelas Lakehouse sobre o armazenamento de arquivos?
- Quais responsabilidades permaneceriam separadas entre Storage, Table Format, Compute e Consumption?

Lições aprendidas

Registrar pelo menos dois aprendizados concretos, relacionando decisões técnicas, dificuldades encontradas e recomendações para uma próxima revisão.

10. Entregáveis

*O material final deve permitir que outra pessoa compreenda, **reproduza** e avalie o projeto.*

#	Entregável	Conteúdo esperado
01	Relatório técnico	Contexto, objetivos, requisitos, arquitetura, decisões e referências.
02	Evidências de construção	Estrutura do storage, tabelas Bronze/Silver/Gold, screenshots, descrições e/ou logs.
03	Scripts / notebooks	Ingestão, tratamento, integração, criação de tabelas e análises.
04	Dataset(s) curated	Tabelas Gold preparadas para os casos de uso.
05	Dashboard / relatório	Visualizações e interpretação dos resultados.
06	Avaliação pós-projeto	Vantagens, limitações, riscos e oportunidades de melhoria.
07	Lições aprendidas	Mínimo de cinco lições e recomendações para evolução.

11. Critérios de avaliação

A avaliação privilegia a capacidade de conectar arquitetura, dados, análise, gerenciamento de tabelas e decisão.

Critério	Peso	Evidência principal
Definição do problema e requisitos	10%	Problema, perguntas, requisitos e critérios de sucesso.
Arquitetura e decisões técnicas	20%	Fluxo completo e justificativas de Storage / Table Format / Compute / Consumption.
Construção do Lakehouse	10%	Bronze, Silver, Gold e tabelas funcionais.
Integração dos dados	10%	Integração de pelo menos três fontes e heterogeneidade demonstrada.
Processamento e análise	10%	Transformações, consultas, respostas às perguntas analíticas.
Qualidade dos resultados e insights	15%	Validações, clareza e sustentação dos insights.
Capacidades específicas de Lakehouse	10%	Demonstração de gerenciamento de tabela e compreensão do table format.
Avaliação pós-projeto	15%	Vantagens, limitações, custos, riscos e escalabilidade.

Princípio

Ferramentas não substituem justificativa arquitetural. A escolha tecnológica deve ser coerente com requisitos, escala, objetivo pedagógico e restrições de custo.

12. Plataformas e opções de execução

O projeto deve ser executável sem exigir crédito cloud pago do aluno.

Trilha	Componentes	Papel	Custo esperado
Principal • Cloud gratuita	Databricks Free Edition + Unity Catalog + Delta Lake + Spark/SQL + notebooks	Lakehouse gerenciado e execução serverless para o laboratório	Sem custo, sujeito a quotas
Alternativa • Local	Python + Pandas/PyArrow + DuckDB + formato de tabela Lakehouse	Execução local quando o aluno não puder usar a nuvem	Sem custo de serviço
Consumo • Desktop	Power BI Desktop	Dashboard e exploração local, sem depender de publicação em serviço pago	Gratuito

Recomendação didática

A trilha principal recomendada é o Databricks Free Edition: ela reduz a necessidade de administração de infraestrutura e permite concentrar o exercício em arquitetura, tabelas, processamento e análise. A oferta é gratuita para usuários qualificados, sem necessidade de pagamento, mas possui quotas e limitações de uso.

13. Trilha cloud gratuita recomendada — Databricks Free Edition

Stack de referência para execução em nuvem adequada a um miniprojeto acadêmico de pequena escala.

Stack recomendado

Responsabilidade	Tecnologia	Como aparece no projeto	Observação didática
Storage	Default Storage / ~~Unity Catalog Volumes~~	Arquivos Bronze e artefatos do workspace	Ensina onde o dado fica armazenado.
Table Format	Delta Lake	Tabelas Silver e Gold	Ensina como uma tabela Lakehouse é estruturada e gerenciada.
Compute	Serverless Spark / SQL	Transformações e consultas	Ensina onde o processamento acontece, sem administrar cluster.
Consumption	Databricks SQL / Dashboard; Power BI Desktop opcional	Análises, indicadores e visualizações	Ensina que consumo é uma camada diferente do armazenamento e do processamento.
Governança	Unity Catalog	Catálogo, nomes, metadados e acesso	Torna governança parte da arquitetura, não um item posterior.

Fluxo mínimo de execução

Fontes → Ingestão → Storage/Arquivos Bronze → Spark/SQL → Tabelas Delta Silver → Tabelas Delta Gold → Dashboard/BI

Restrição de escopo

Para preservar o caráter didático, não é necessário utilizar clusters, administração de rede, infraestrutura IaaS ou serviços adicionais de cloud. O laboratório deve permanecer pequeno e orientado à aprendizagem de arquitetura.

Atenção sobre gratuidade

O Databricks Free Edition é uma oferta sem custo, mas possui política de uso justo e quotas. Se a quota de compute for excedida, o ambiente pode ficar indisponível até o reset do limite. Por isso, o professor deve manter os datasets e cargas do miniprojeto pequenos.

Base tecnológica: documentação oficial atual do Databricks (Free Edition, Delta Lake e Unity Catalog) e da Microsoft (Power BI Desktop).

CHECKLIST DE EXECUÇÃO

Da pergunta de negócio à entrega

☐ Problema e objetivos definidos

☐ Requisitos e perguntas analíticas documentados

☐ Fontes e tipos de dados mapeados

☐ Arquitetura conceitual desenhada e justificada

☐ Storage identificado separadamente do Table Format, Compute e Consumption

☐ Arquivos originais preservados na camada Bronze

☐ Tabelas Silver criadas e tratadas

☐ Tabelas Gold criadas para os casos analíticos

☐ Dados estruturados + semiestruturados/não estruturados integrados

☐ Pelo menos uma capacidade específica de gerenciamento de tabela demonstrada

☐ Análises executadas e insights interpretados

☐ Vantagens e limitações avaliadas

☐ ~~Cinco~~ Duas ou mais lições aprendidas registradas

☐ Entregáveis organizados para avaliação

☐ Entrega final: evidência de construção + análise + reflexão arquitetural.

Princípio final do projeto

A tecnologia é um meio para demonstrar arquitetura. O resultado esperado não é apenas “fazer funcionar”, mas explicar por que a solução foi desenhada dessa maneira, quais responsabilidades cada componente assume e quais trade-offs aparecem quando o volume e a complexidade aumentam.