

Debora Corsino

Vivemos um momento único, em que a tecnologia, os dados e a inteligência artificial transformaram a forma como trabalhamos, tomamos decisões e geramos valor para a sociedade.

No entanto, por trás de qualquer tecnologia, sempre existem pessoas, desafios reais e a busca constante por aprendizado e evolução.



AGENDA GERAL

1. Modulo 1 – Introdução aos tripos de dados e ao contexto de Big Data	➢ 22/09/26
2. Modulo 2 – Overview das ferramentas para o gerenciamento de dados distribuídos	➢ 28/09/26
3. Modulo 3 – Organização e manuseio de dados em bases distribuídas	➢ 29/0926
4. Prática presencial	➢ 03/10/26
5. Miniprojeto (15 dias para entrega)	➢ 18/10/26
6. Disponibilização de nota	➢ 02/11/26

ARQUITETURA DE DADOS E BIG DATA

Introdução e definições

Módulo 1 · Instrodução aos tipos de dados e ao contexto de Big Data

- Tipos de dados: estruturados, semiestruturados e não estruturados
- Dados transacionais e dados analíticos
- Dados batch e dados em streaming
- Fontes modernas de dados: sensores, logs, redes sociais, APIs
- Introdução à arquitetura de dados e ao Big Data
  - Big Data e os 3, 5 e 7 Vs

Objetivos e Agenda do capítulo

O capital de dados

Como os dados passaram a gerar vantagem competitiva

Tipos de dados

Classificação quanto à origem, finalidade, estrutura e velocidade de processamento

Big Data

Características do Big Data: Os 3V's, 5V's, 7V's

Introdução à Arquitetura de dados

Organizando os dados desde 1970

Do registro operacional ao capital estratégico

O dado deixa de ser mero registro operacional para se tornar o principal ativo de valoração estratégica do mercado a partir do momento que ele passou a mudar uma decisão.

O Dado como ativo financeiro

Antes: Sistemas registravam transações para controlar o negócio

Depois: Empresas perceberam que o histórico acumulado revelava padrões, comportamentos e oportunidades.

Hoje: Dados são um ativo estratégico – reutilizável, combinável e capaz de gerar novos produtos, eficiência e decisões como criar barreiras competitivas favoráveis.

Casos Empresariais Emblemáticos

Uber: Precificação dinâmica (surge pricing) e rotas calculadas via inteligência de dados geográficos contínuos.

Amazon: Antecipação de demanda e precificação dinâmica refinada em tempo real com base no histórico de navegação.

Netflix: Motor de recomendação alimentado por **hábitos de visualização** reduz o churn e economiza mais de US$ 1 bilhão por ano.

Contratos → inteligência

A proptech Edsvard usa dados não estruturados para localizar cláusulas e reduzir trabalho manual.

Operação → prevenção

Sensores e logs de máquinas antecipam falhas e mudam manutenção reativa para preditiva.

Cliente → contexto

Transações e sinais sociais enriquecem personalização, previsão e resposta comercial.

De onde vem?

Dados são gerados nos seguintes agrupamentos:

Sistemas empresariais - Transações

ERP, CRM, vendas, pagamentos e atendimento

Sensores e IoT

Equipamentos industriais, dispositivos vestíveis:

Temperatura, localização, vibração, consumo, telemetria

Logs

Máquinas:

Todo tipo de evento, erros, requisições HTTP e comportamento do usuário.

APIs / Webhook / MCP

Ecossistema - Integrações entre microsserviços transmitindo cargas de dados (plataformas, serviços, aplicações):

Cliques, sessões, tempo, comportamento digital.

Redes sociais

Fluxos de mensagens, imagens, vídeos e interações que exigem análise de sentimento e visão computacional.

A mesma fonte pode produzir diferentes formatos, ritmos e usos.

Propósito

Classificando o dado quanto ao propósito

Dados Transacionais (OLTP)

Foco: Suporte a operações diárias do negócio com **máxima velocidade** e **alta disponibilidade.**

- Propriedades ACID (Garantia de consistência)
- Pequenas leituras e escritas frequentes
- Exemplos: Vendas no caixa, transferências bancárias, pagamento aprovado, pedido criado, estoque movimentado.

pedido · pagamento · leitura de sensor

Registrar o que acontece é transacional.

Dados Analíticos (OLAP)

Foco: Suporte a tomadas de decisão estratégica e análise de tendências históricas.

- Consultas complexas em grandes volumes
- Modelagem dimensional e orientação a colunas
- Exemplos: vendas por região, rentabilidade, comportamento do cliente, tendências históricas.

tendência · segmento · previsão de demanda

Explicar e orientar é Analítico.

O mesmo evento pode alimentar os dois mundos — com modelagem e latência diferentes.

Estrutura do dado

Classificando o dado quanto a sua estrutura

Estruturados

Esquema estrito e pré-definido (*Schema-on-Write*). Armazenados em bancos relacionais (SQL).

Exemplos: Tabelas SQL, planilhas CSV organizadas.

Fontes comuns

Sistemas transacionais (ERP, CRM, terminais POS, formulário eletrônico,)

Ponto forte: facilidade para consulta, validação, integração e análise tabular.

Semiestruturados

Não possuem tabela rígida, mas contêm marcadores, chaves e tags organizadoras.

Exemplos: Arquivos JSON, documentos XML, YAML, NoSQL, eventos de APIs,

Fontes comuns

APIs, logs, IoT

Ponto forte: São fundamentais na integração de aplicações modernas e arquiteturas orientadas a eventos.

Não Estruturados

Sem estrutura interna pré-definida. Representam mais de 80% do volume total do Big Data.

Exemplos: Textos livres, e-mails, vídeos, áudios, imagens, PDFs e postagens sociais.

Fontes comuns

Redes sociais, documentos corporativos, câmeras, atendimento digital

Ponto forte: Para gerar valor, frequentemente exigem técnicas de busca, NLP, visão computacional e/ou IA.

Mais estrutura facilita consulta; menos estrutura preserva riqueza — e exige interpretação.

Cadência de processamento

Classificando quanto à cadencia

BATCH / Lote

Fonte → acumula → processamento programado → armazenamento/ publicação

Principais Características:
Alta latência tolerada, grande throughput, otimização de custo operacional.



Fechamento financeiro · carga histórica · relatórios periódicos

STREAMING

evento → processamento em fluxo contínuo contínuo→ ação (alertas, automações, dash)

Principais Características:
Baixíssima latência (milissegundos), ação imediata sobre eventos.



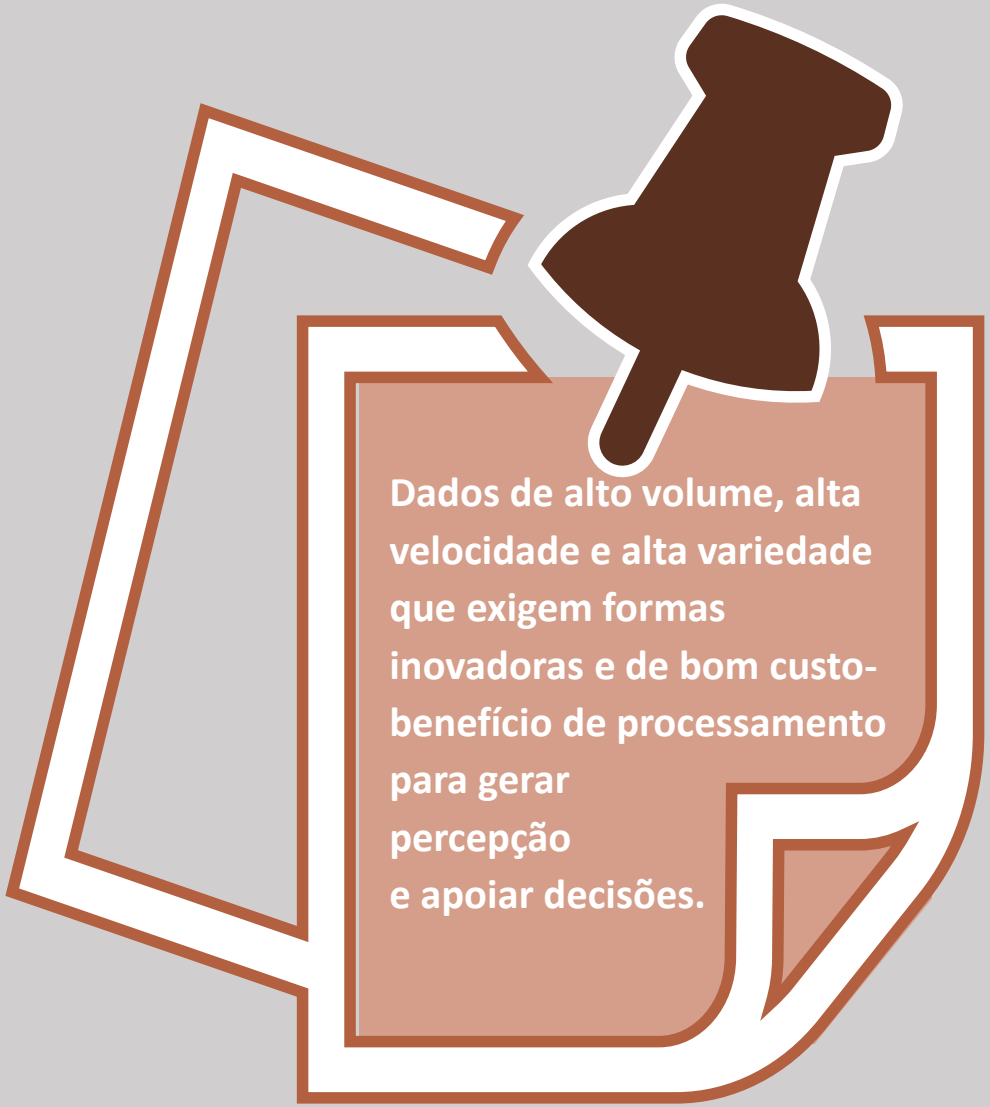
Fraude · alertas de sensores · personalização em tempo real

Big Data não é sinônimo de "muito dado"

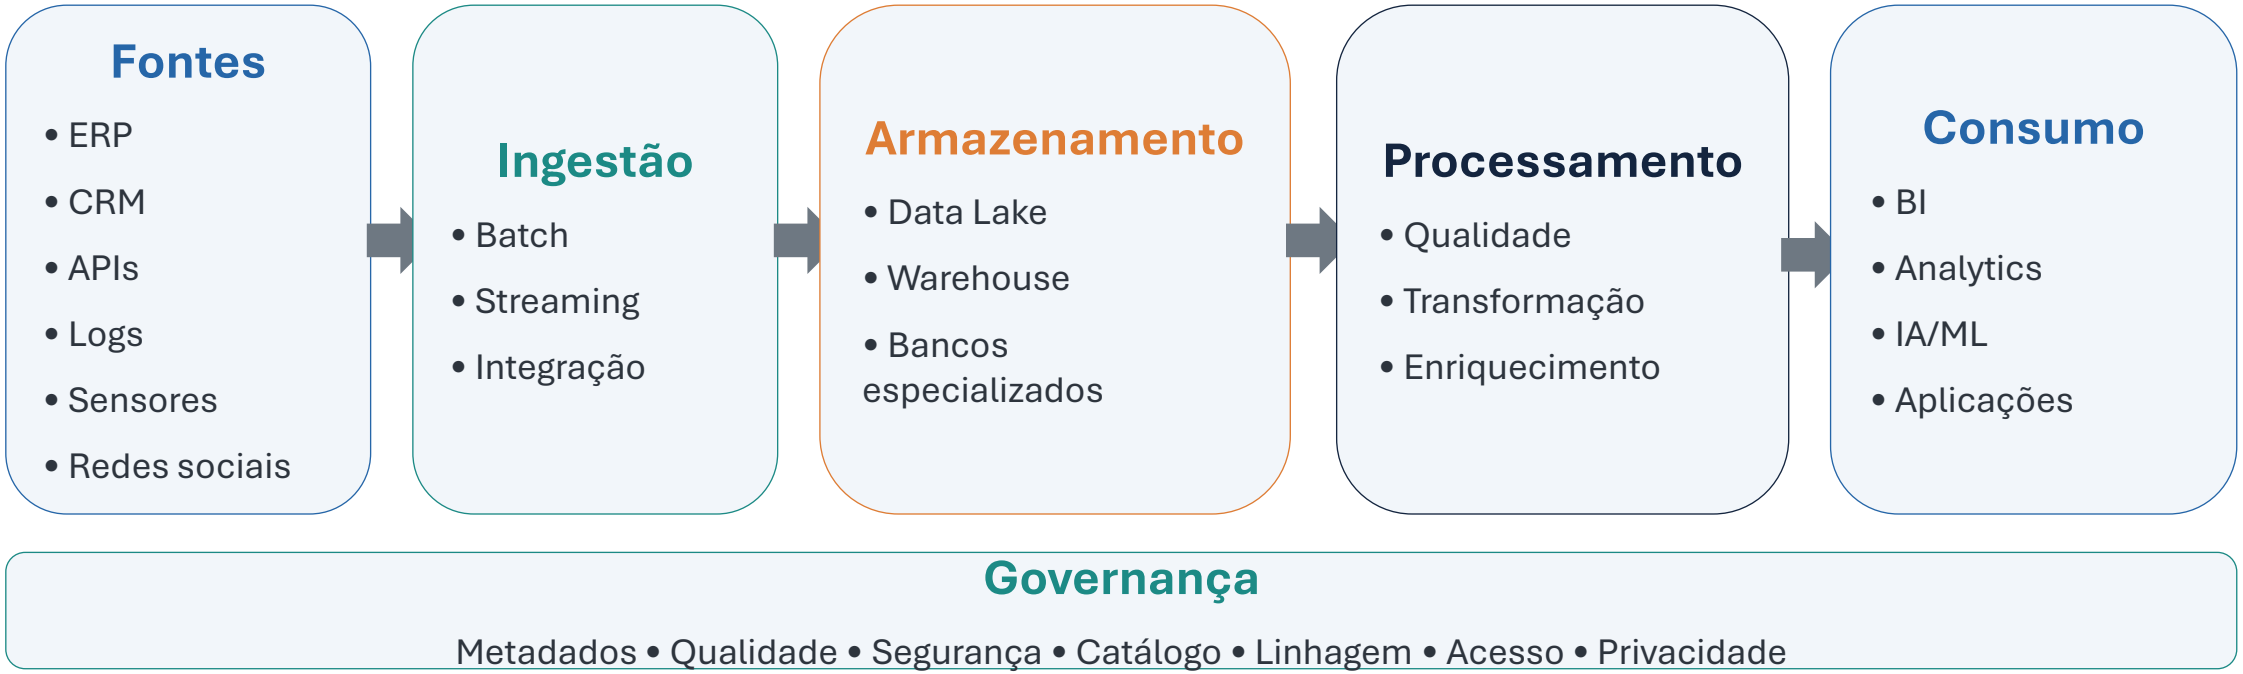
ONDE ENTRA O CONTEXTO DE BIG DATA?

- Big Data surge quando métodos tradicionais deixam de ser suficientes para lidar com escala e complexidade.
- Na prática, o desafio não é apenas armazenar: é integrar, governar, processar e disponibilizar dados com custo e desempenho adequados.
- Novas fontes de dados.
- Volume: muitos dados; Variedade: múltiplos formatos e fontes; Velocidade: geração e consumo acelerados.
- Data lakes, data warehouses, bancos especializados e processamento distribuído passam a coexistir.

Definição de referência (Gartner)



Como garantir que o dado seja de fato, um capital estratégico?



Dados viram capital quando o sistema inteiro consegue aprender e agir repetidamente.

Exercícios – Modulo 1

Exercícios — Módulo 1

Arquitetura de Dados e Big Data

1. Do operacional ao capital estratégico

Uma rede varejista registra diariamente milhões de vendas em seus sistemas de PDV.

Inicialmente, os dados são utilizados apenas para:
- emitir comprovantes;
- controlar estoque;
- registrar pagamentos.

Após alguns anos, a empresa começa a utilizar o histórico para prever demanda, recomendar produtos e otimizar a distribuição.

Questão: Explique como o dado deixou de ser apenas um registro operacional e passou a representar um **ativo estratégico**.

Em sua resposta, apresente pelo menos:
1. duas diferenças entre uso operacional e estratégico dos dados;
2. dois exemplos de geração de valor;
3. um desafio arquitetural que surge quando a empresa passa a reutilizar os dados.

2. Classificação de fontes de dados

Classifique os seguintes dados como provenientes de fontes predominantemente: **transacionais, APIs, sensores/IoT, logs, redes sociais ou aplicativos/clickstream**.

a) Temperatura registrada por sensores em uma fábrica.
b) Registro de autenticação de usuários em uma aplicação.
c) Pedido realizado por um cliente em um e-commerce.
d) Dados meteorológicos obtidos de um serviço externo.
e) Cliques realizados por usuários durante uma sessão de navegação.
f) Comentários publicados por consumidores sobre uma marca.

Desafio adicional: indique quais dessas fontes poderiam gerar dados em streaming.

3. Estruturado, semiestruturado ou não estruturado?

Classifique os seguintes exemplos:

1. Tabela de clientes em banco relacional
2. Documento JSON retornado por uma API
3. Vídeo de câmera de segurança
4. Arquivo XML de integração
5. E-mail com texto livre e anexos
6. Registro de vendas em tabela relacional
7. Log estruturado em JSON
8. Áudio de atendimento ao cliente

CAPÍTULO 2

Arquitetura de Dados

A base conceitual e tecnológica que governa a transformação do caos de dados em ativos utilizáveis e seguros.

Arquitetura transforma variedade em capacidade

Arquitetura de dados é o conjunto de princípios, modelos e componentes que organiza como dados são coletados, integrados, armazenados, processados, protegidos e disponibilizados.

Governança & Segurança

Define políticas de acesso, mascaramento, linhagem do dado (*Data Lineage*) e conformidade legal com LGPD e GDPR.

Escalabilidade & Elasticidade

Garante que a infraestrutura em nuvem cresça sob demanda sem gargalos de desempenho ou falhas de sistema.

Desacoplamento

Separação clara entre camadas de armazenamento (Data Lake) e camadas de computação (Spark, Snowflake, Trino).

01 **INGESTÃO**

Como o dado entra?

02 **ARMAZENAMENTO**

Onde vive e por quanto tempo?

03 **PROCESSAMENTO**

Batch, streaming ou ambos?

04 **CONSUMO**

Quem usa e com qual latência?

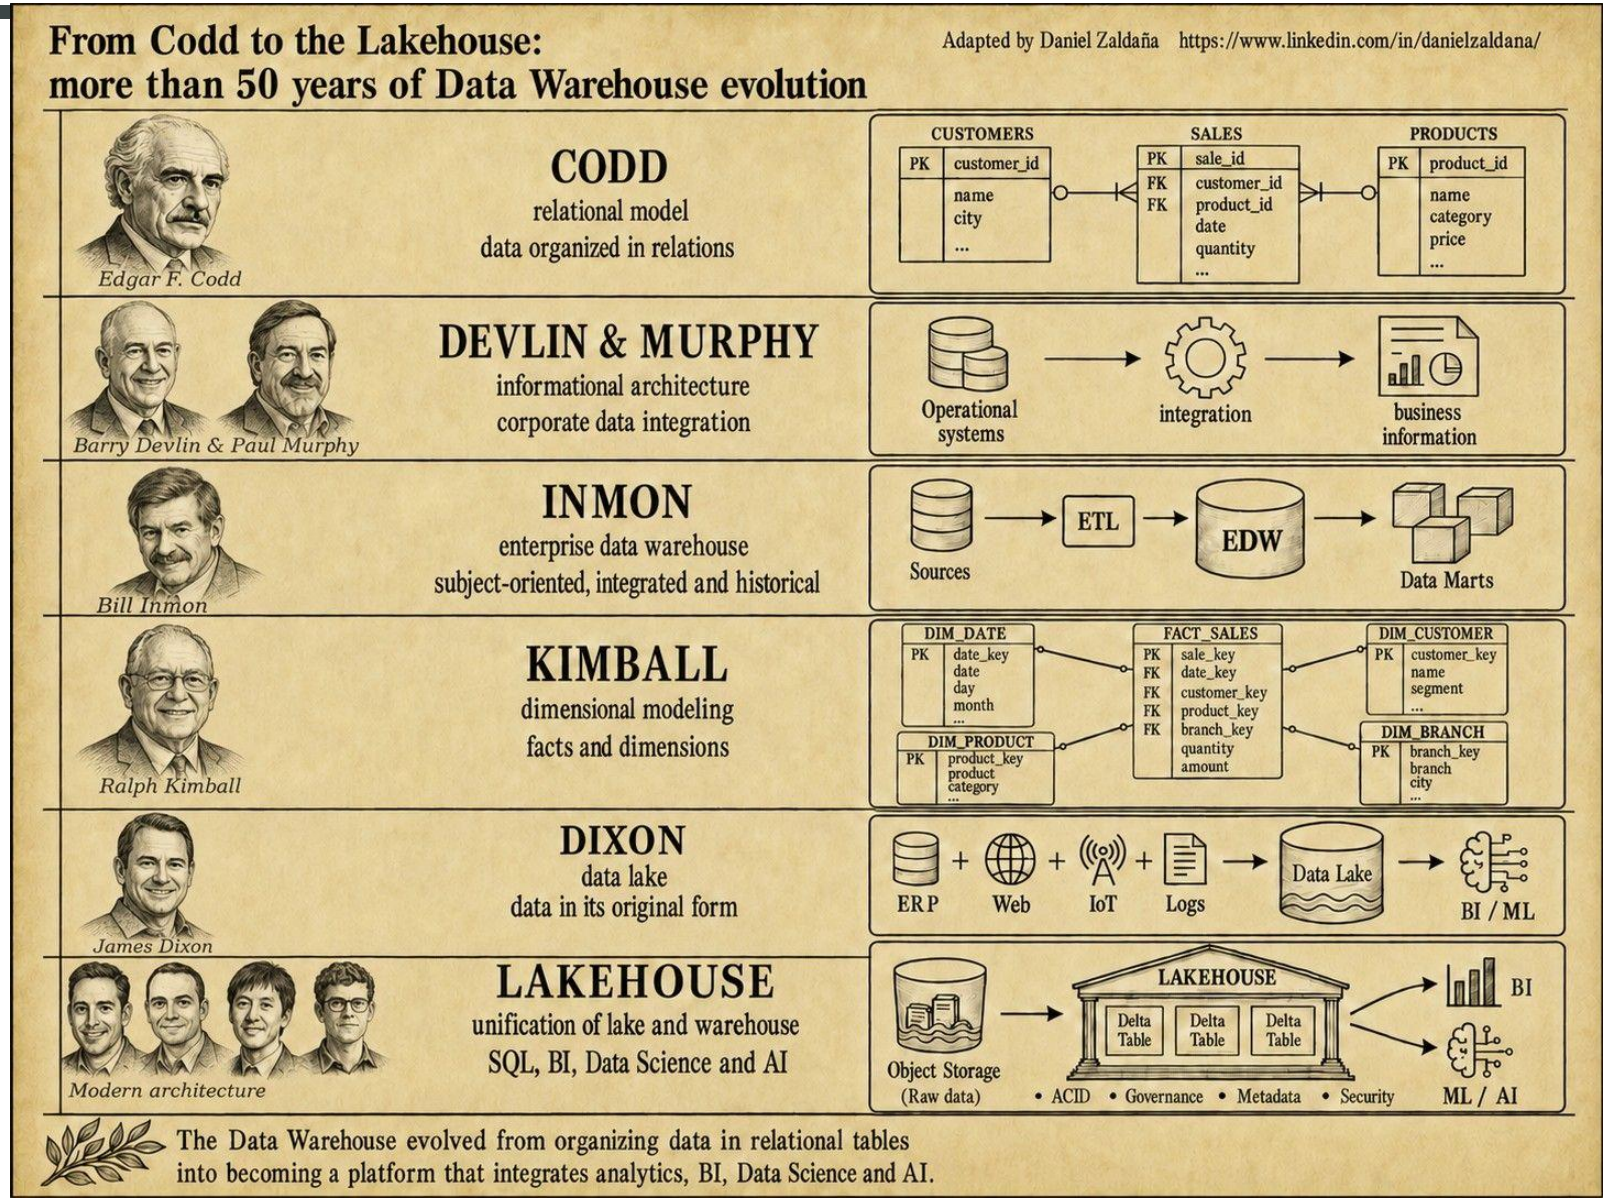
05 **GOVERNANÇA**

Quem responde por qualidade, acesso e privacidade?

A arquitetura de dados deve começar com uma pergunta:

Qual decisão estamos tentando melhorar?

- Há 50 anos, cada etapa da evolução arquitetural respondeu a um novo desafio. Começou por organizar dados, integrar sistemas, apoiar análises históricas, lidar com Big Data e viabilizar aplicações de machine learning e inteligência artificial.
- Ou seja, para atender as novas necessidades de negócios, foi necessário criar-se novos modelos de arquitetura (não necessariamente substitutos dos anteriores), gerando um ecossistema variado em opções tecnológicas.
- O valor da tecnologia que escolhemos depende do que acontece depois que os dados são capturados.



Modelo Relacional

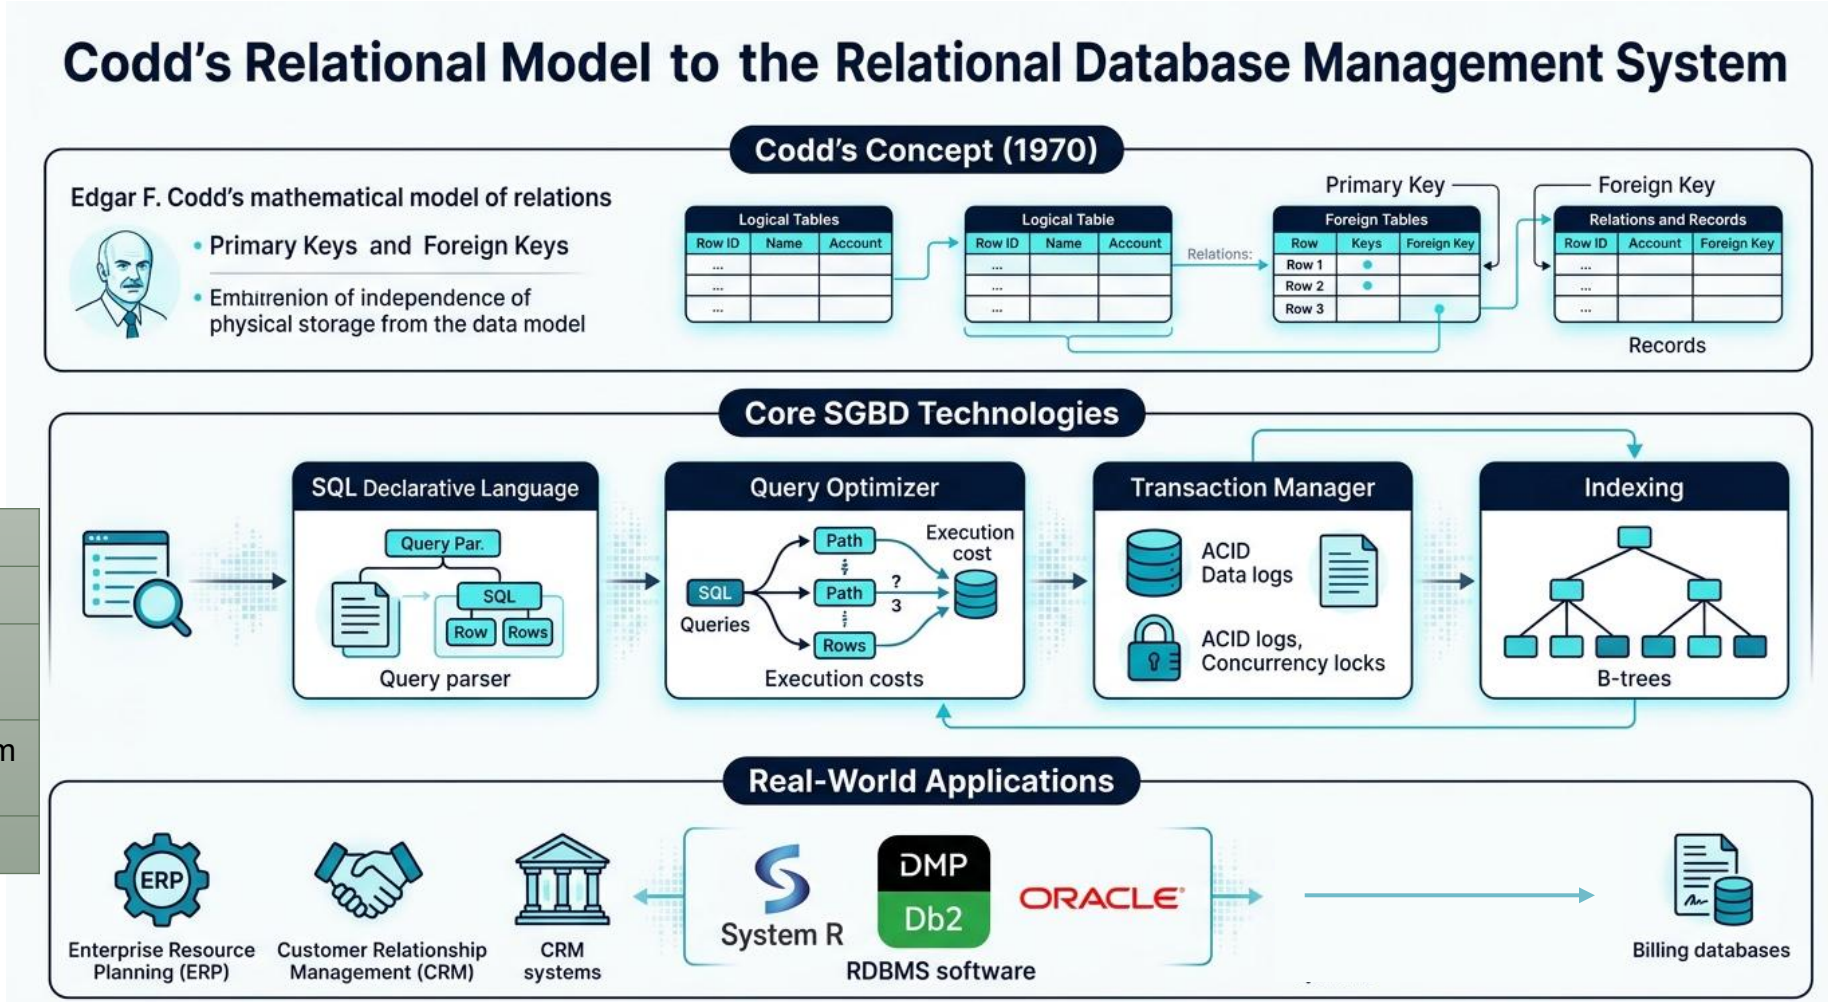
- 1970: O foco era consistência, integridade referencial e eliminação de redundâncias para os sistemas operacionais (OLTP).

Tecnologias habilitadoras

- **SGBD** relacional (*Relational Database Management System, RDBMS*)
- Linguagem **SQL**
- Gerenciamento transacional

Propriedade	Significado
Atomicidade	Tudo ou nada
Consistência	Preserva regras de integridade
Isolamento	Transações não interferem indevidamente
Durabilidade	Dados persistentes

3FN: "*Todo atributo que não faz parte da chave deve depender diretamente da chave primária, e somente dela*" *M.Kaufman*



Resolveu: *Independência entre programas e armazenamento*
Gerou: *Sobrecarga no transacional*

EBIS

Resolveu: *Complexidade de acesso aos dados*

Gerou: *Silos analíticos*

O CONCEITO

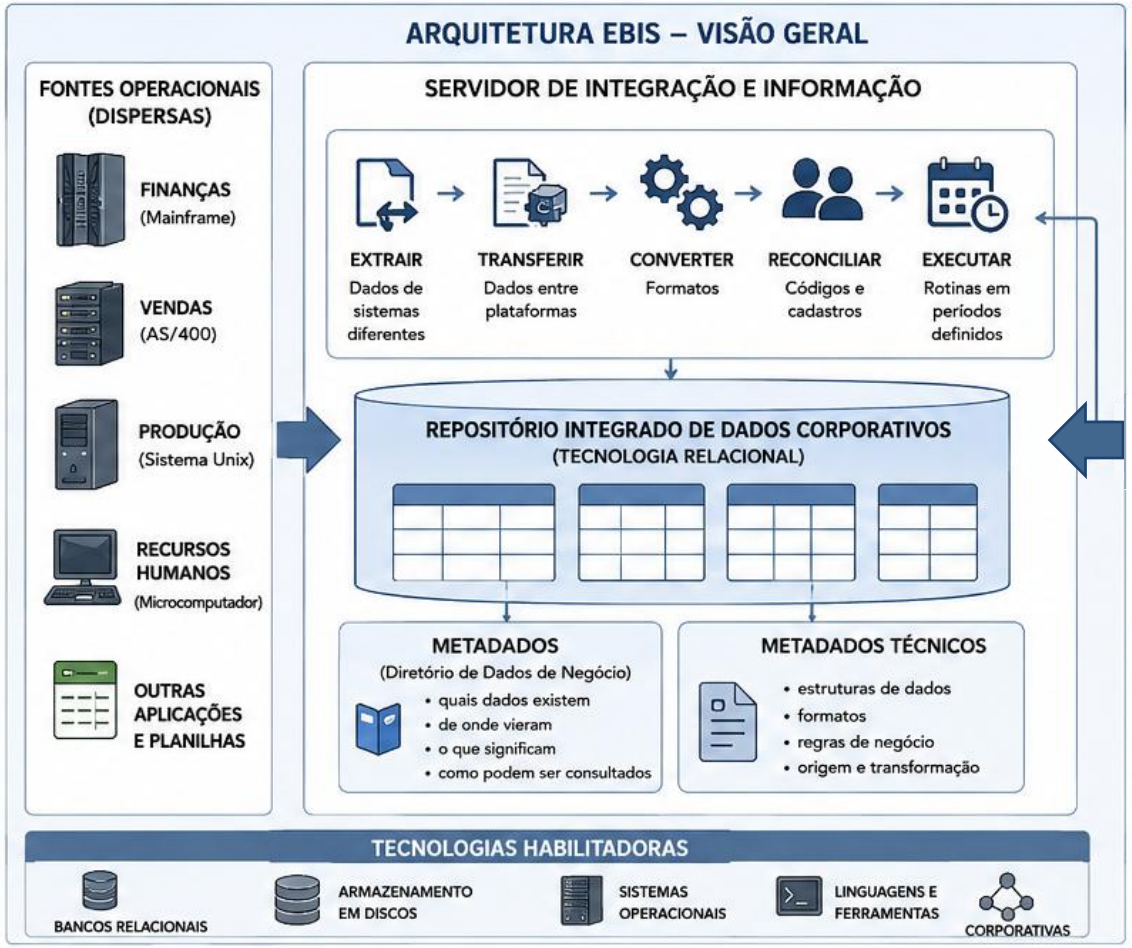
Na década de 1980, os dados já estavam em sistemas corporativos, mas permaneciam dispersos por áreas e aplicações. Devlin e Murphy descreveram, em 1988, a arquitetura EBIS, com um repositório integrado de dados corporativos apoiado em tecnologia relacional e orientado ao acesso informacional.
[9sight.com], [archive.org]

O QUE PRECISOU EVOLUIR

Não bastava ter bancos relacionais isolados. Foi necessário criar mecanismos para:

- extrair dados de sistemas diferentes
- transferir dados entre plataformas
- converter formatos
- reconciliar códigos e cadastros
- executar rotinas em períodos definidos
- armazenar metadados
- disponibilizar informação de maneira uniforme

ARQUITETURA EBIS – VISÃO GERAL



REDES E ARQUITETURA CLIENTE-SERVIDOR



INTEGRAÇÃO DE DADOS – TECNOLOGIAS INICIAIS

Grande parte da integração era construída com:

- programas batch
- arquivos sequenciais
- exportações e importações
- rotinas em COBOL, PL/I e outras linguagens



DIRETÓRIOS E METADADOS DE NEGÓCIO

A arquitetura EBIS incluía um diretório de dados de negócio para descrever as informações em termos compreensíveis aos usuários.



FERRAMENTAS DE CONSULTA E RELATÓRIO

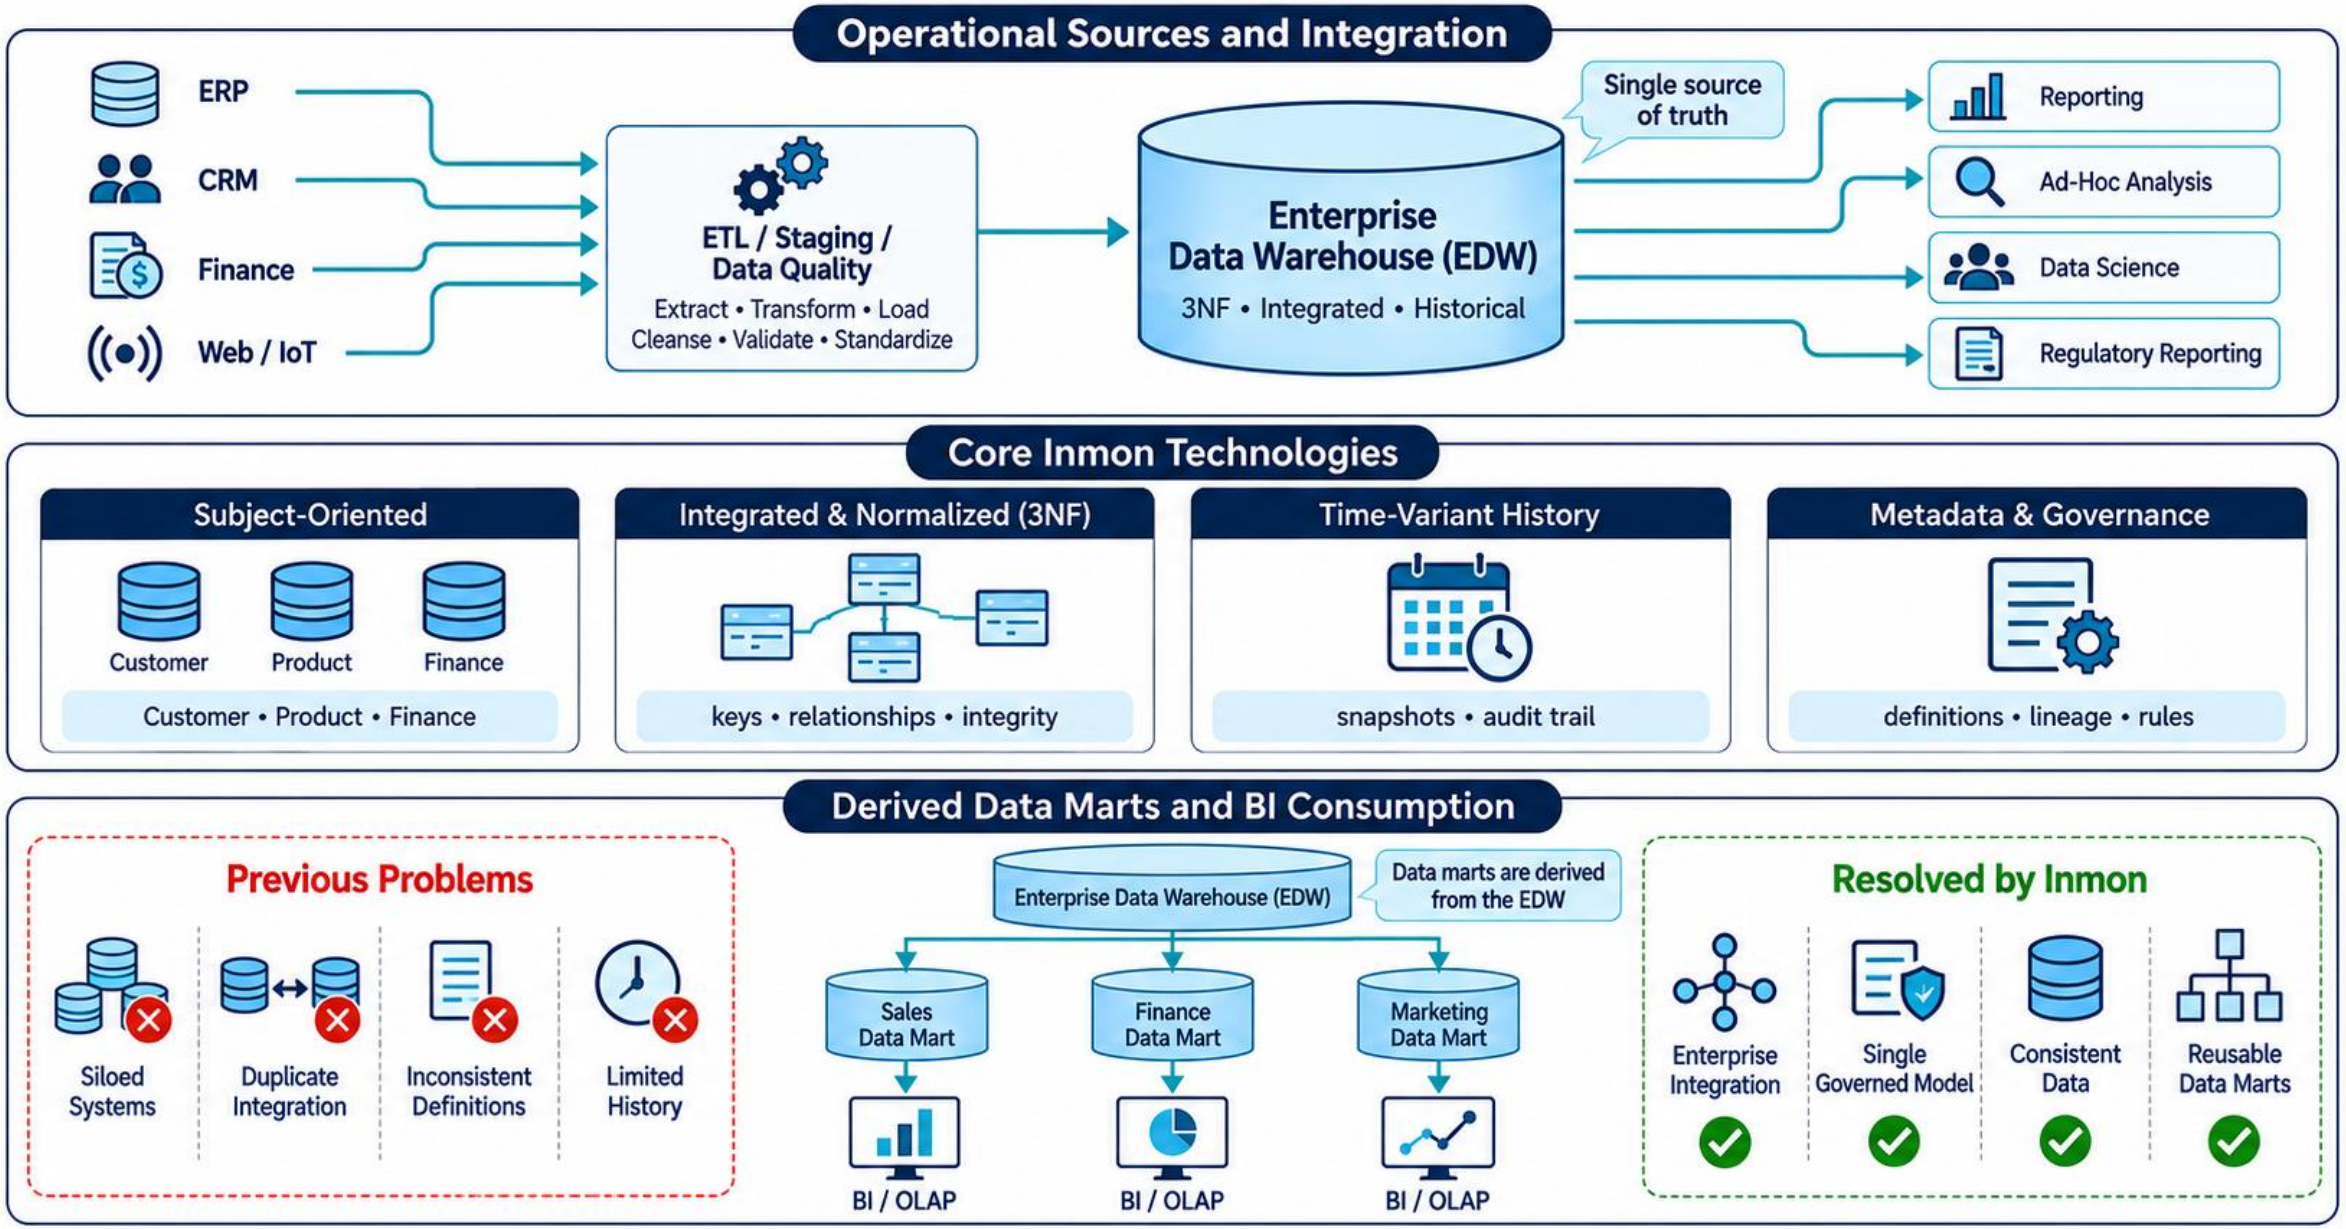
Surgiram ferramentas que permitiam ao usuário acessar informações sem programar diretamente os sistemas operacionais.



Esse foi o passo entre ter bancos de dados e ter uma arquitetura corporativa de informação.

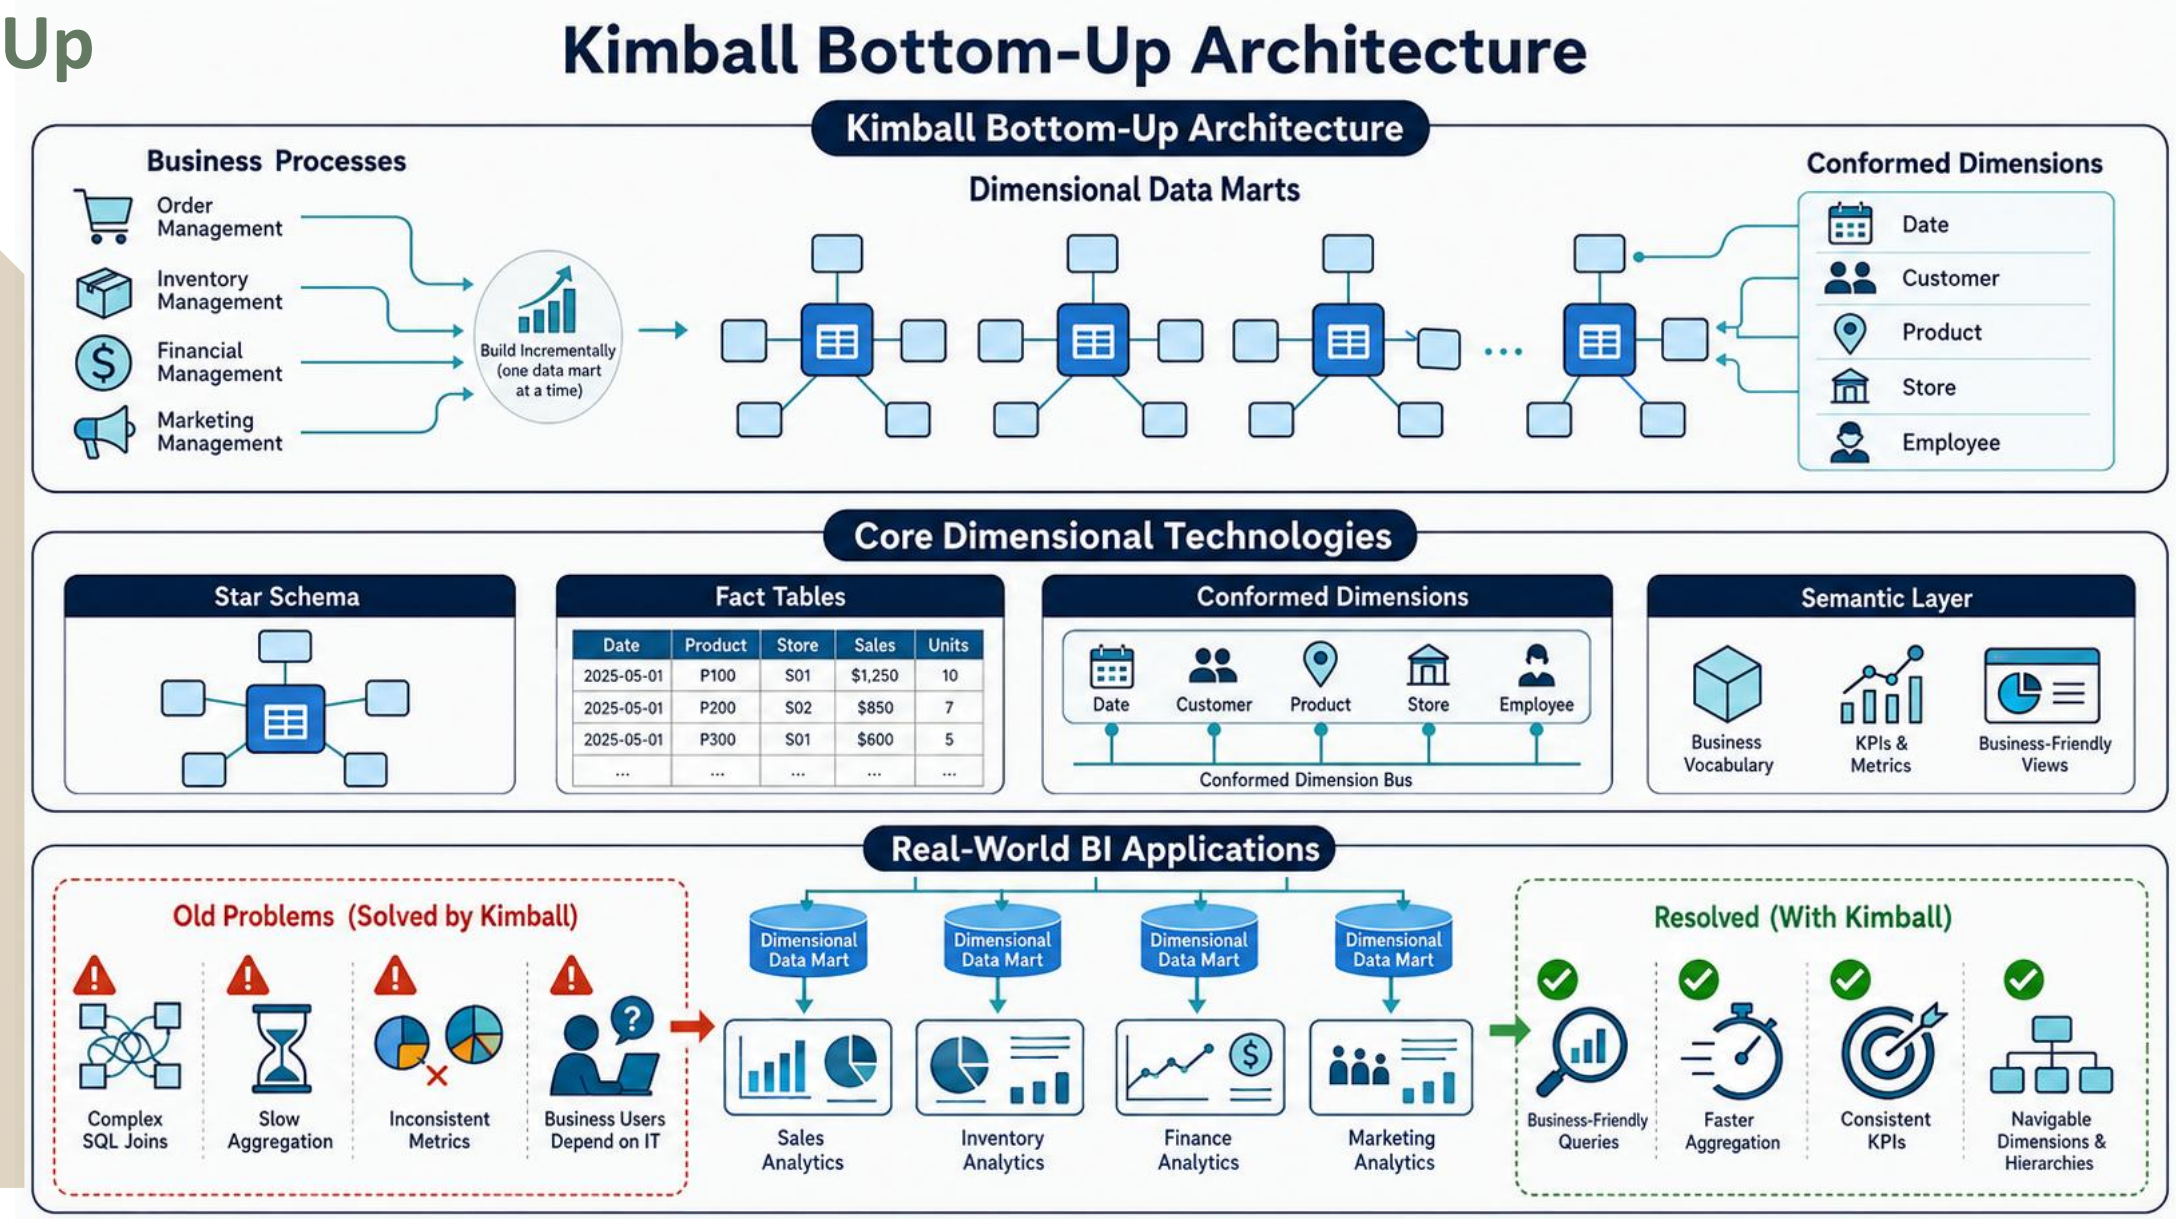
Top-Down

Inmon Top-Down Architecture



Bottom-Up

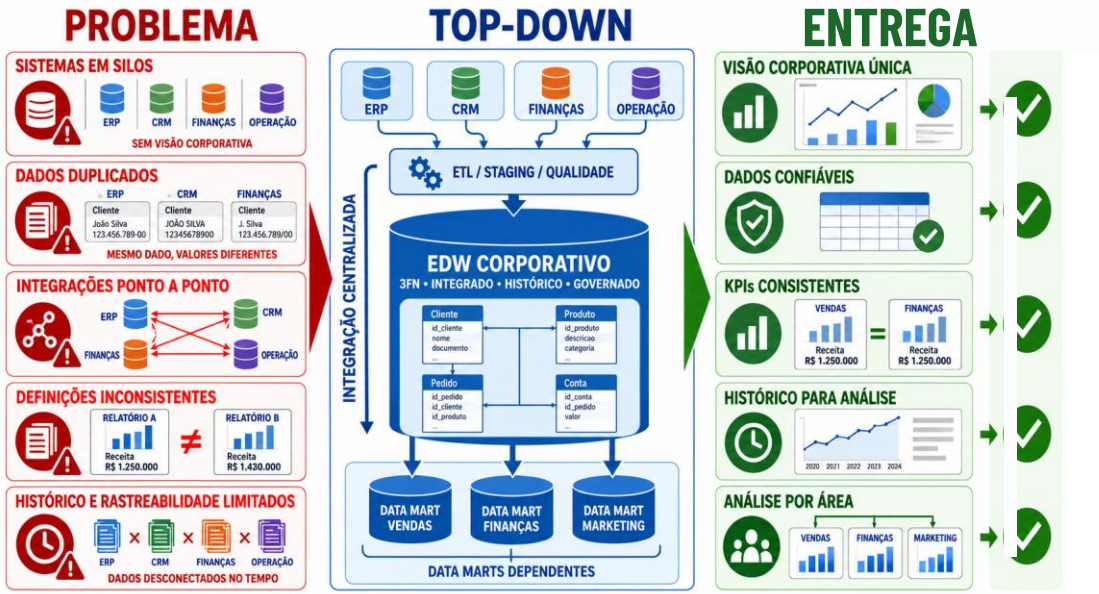
- Kimball = *abordagem prática para análises.*
- *Processos de negócio originando data marts dimensionais;*
- *Construção incremental*
- *Esquema Estrela*
- *Dimensões conformadas conectando os data marts*
- *Camada semântica*



COMPARANDO

TOP-DOWN/ HUB-AND-SPOKE (INMON)

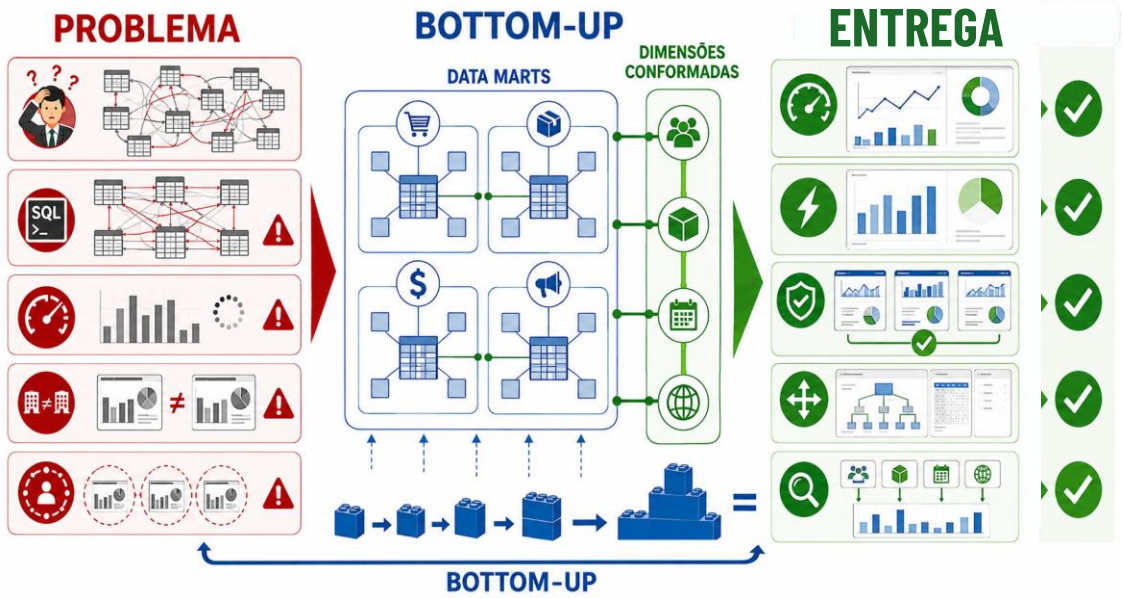
"Como construo uma visão integrada e corporativa dos dados"



Sistemas → EDW → Data Marts → BI

BOTTOM-UP (KIMBALL)

"Como disponibilizo rapidamente dados compreensíveis e performáticos para análise"



Processos de negócio → Data Marts dimensionais → integração por dimensões conformadas → BI

- Bancos
- Seguradoras
- Telecom
- Governo
- Grandes indústrias (sistemas legados)

Big Data – Características

Volume

Quantidade de dados gerados e armazenados, de gigabytes a petabytes.

Variedade

Amplitude de formatos: estruturado, semiestruturado e não estruturado.

Velocidade

Cadência de geração, processamento e acesso: batch, near real-time ou tempo real.

Veracidade

Confiabilidade e exatidão do dado. Fontes heterogêneas exigem validação.

Valor

A dimensão mais importante: utilidade real para a decisão de negócio.

Variabilidade

Inconsistência de formato e significado ao longo do tempo.

Visualização

Capacidade de tornar o dado compreensível para quem decide.

Viabilidade

Se vale a pena, em custo e risco, explorar aquele dado.

Não há consenso no número exato

O que importa é o raciocínio: quanto mais dimensões o profissional nomeia, mais completa é sua leitura do cenário.

Estudo de caso

Estudo de Caso — Módulo 1

Arquitetura de Dados e Big Data

Caso: AulaStore — quando o crescimento do negócio transforma dados em um problema arquitetural

1. Contexto da empresa

A AulaStore é uma empresa brasileira de varejo que começou como uma rede de lojas físicas. Nos primeiros anos, seu principal sistema era um ERP responsável por vendas, estoque, compras, financeiro e cadastro de produtos. Os dados eram utilizados predominantemente para registrar e controlar a operação.

Nos últimos quatro anos, a empresa passou por uma forte transformação digital. Atualmente, ela possui 180 lojas físicas, um e-commerce, um aplicativo mobile, um programa de fidelidade e integração com marketplaces e parceiros logísticos.

A diretoria percebeu que os dados gerados pelas novas operações poderiam ser utilizados não apenas para registrar o que aconteceu, mas para apoiar decisões, prever demanda, personalizar ofertas e reagir rapidamente a eventos operacionais.

2. O ecossistema atual de dados

Fonte	Exemplos de dados	Frequência	Uso atual
ERP	vendas, estoque, compras, financeiro	Transações contínuas	Operação e fechamento
E-commerce	pedidos, carrinho, busca, navegação	Alta / contínua	Vendas e marketing
App mobile	sessões, cliques, localização autorizada	Contínua	Experiência digital
Sensores	temperatura, estoque, telemetria	Segundos/minutos	Monitoramento
APIs	preço, frete, catálogo, parceiros	Variável	Integração
Logs	acesso, erro, segurança, aplicação	Contínua	TI e auditoria
Redes sociais	texto, imagem, vídeo, interação	Contínua	Marketing
Atendimento	chat, e-mails, gravações	Contínua	Experiência do cliente

3. O problema de negócio

A diretoria solicitou uma nova capacidade analítica. O objetivo é criar uma visão integrada do cliente, da operação e da cadeia de abastecimento.

Requisitos definidos pela diretoria:

- acompanhar vendas e margem diariamente;
- detectar possíveis fraudes poucos segundos após uma transação;

FGV

MÓDULO 1 CONCLUÍDO

Disciplina · Arquitetura de Dados e Big Data — MBA em Inteligência Artificial e Analytics Aplicados a Negócios

Debora Corsino