ARQUITETURA DE DADOS E BIG DATA

Como operar a arquitetura moderna

Módulo 3 · Organização e manuseio de dados em bases distribuídas

- Pipelines modernos
  - Ingestão,
  - Transformação/ processamento de dados
  - Armazenamento
  - ML e GenIA
- Governaça de um ecossistema distribuído:
  - Data Fabric
  - Data Mesh
- Cloud computing

1

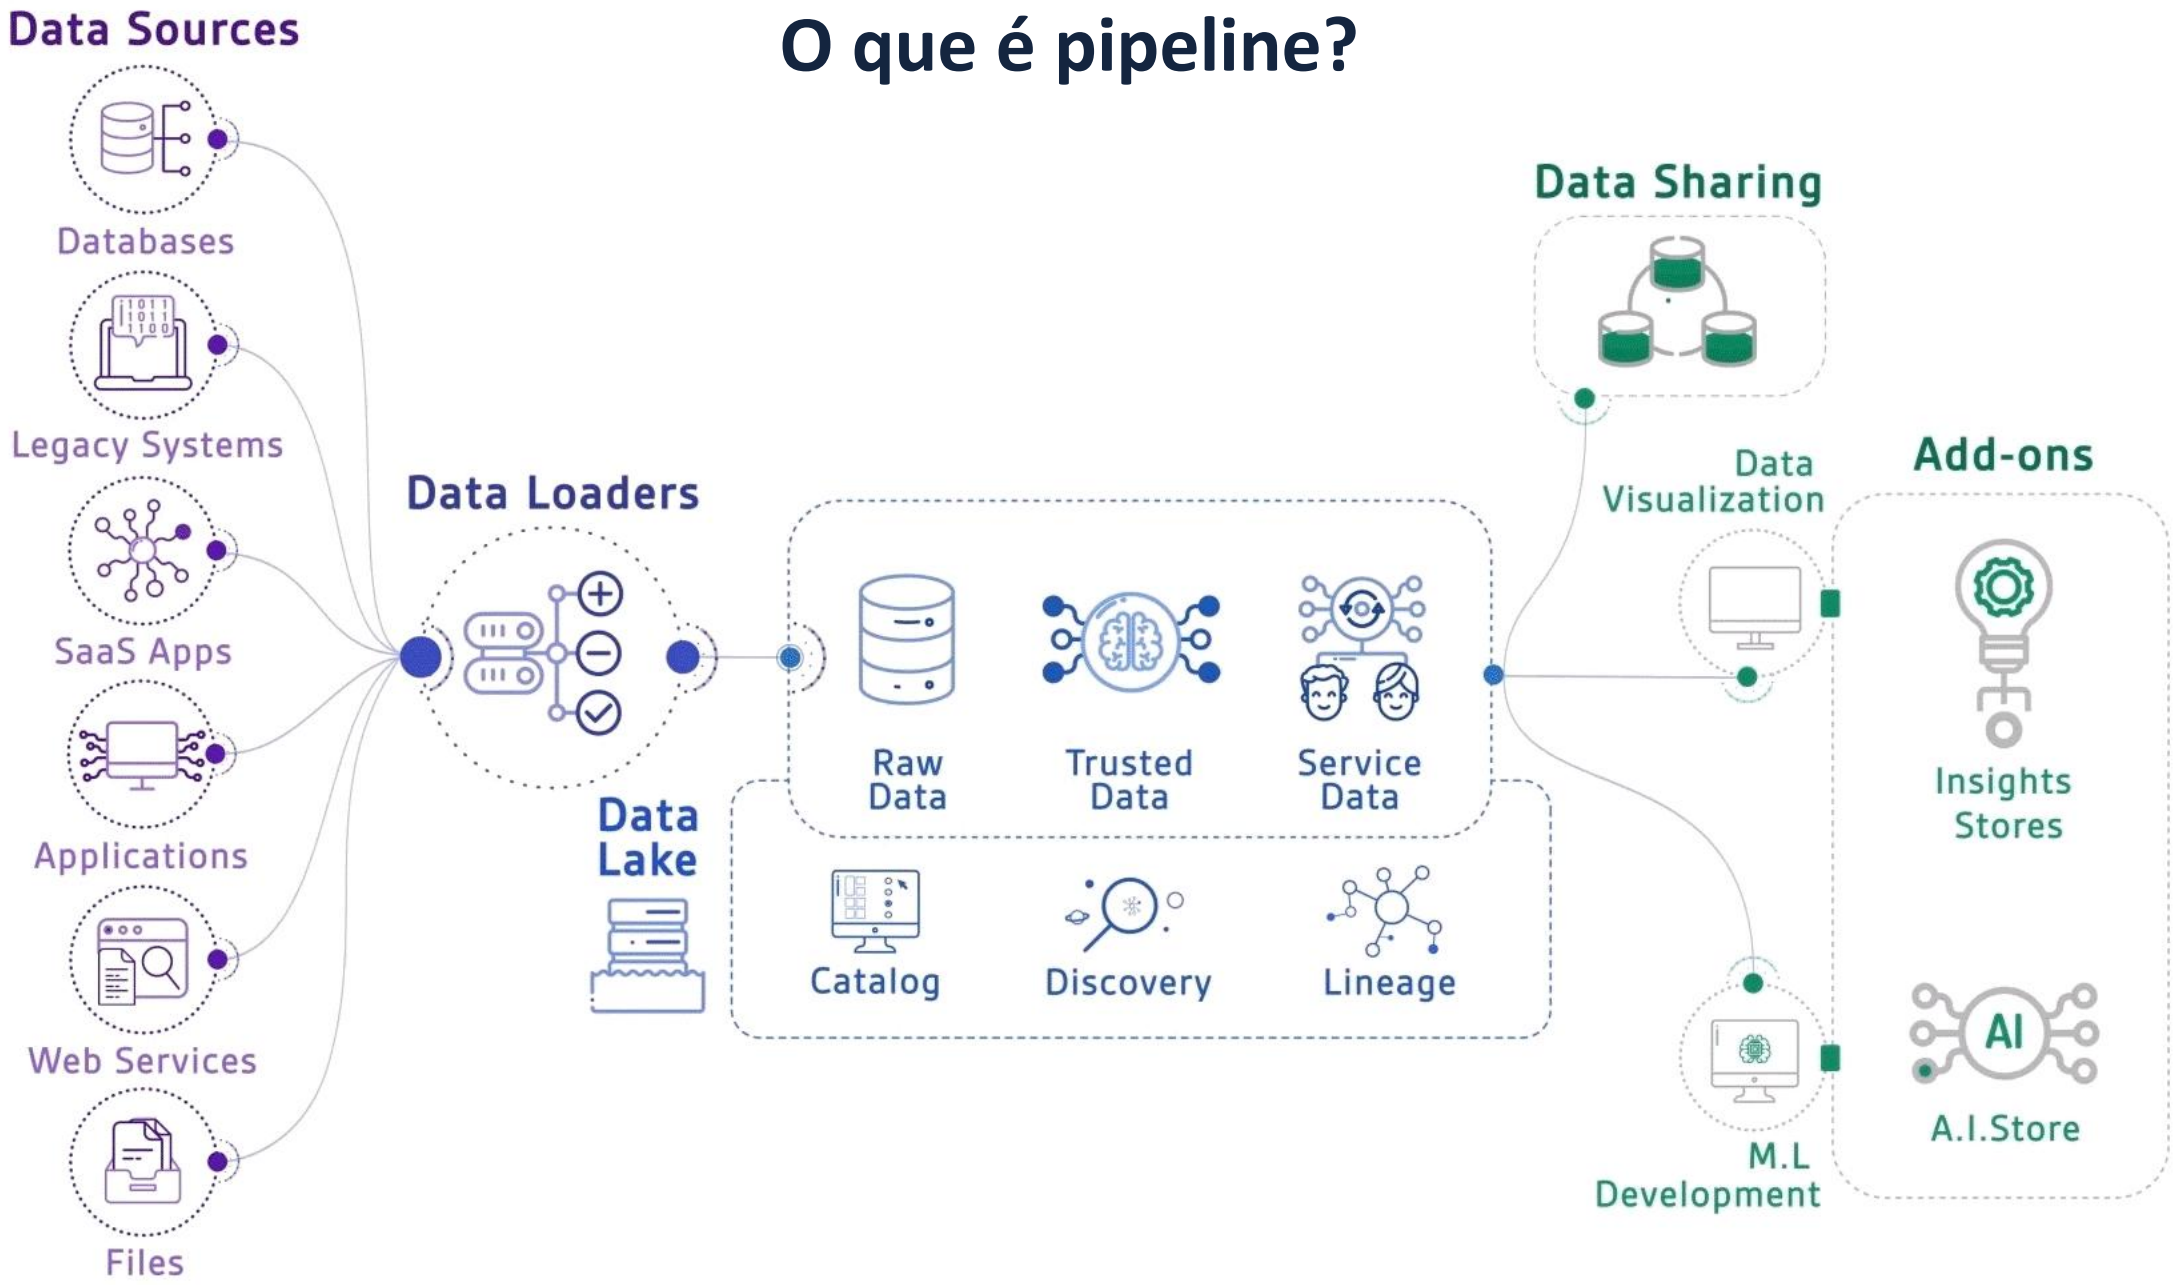
BLOCO

Pipelines

Pipelines modernos

- O que é pipeline de dados
- Classificações do pipeline
- Pipeline para IA generative

O que é pipeline?



Coletar **Armazenar** **Processar** **Persistir** **Servir**

Classificação quanto a Ingestão

• **Volume de ingestão** - Quanto dado será ingerido:

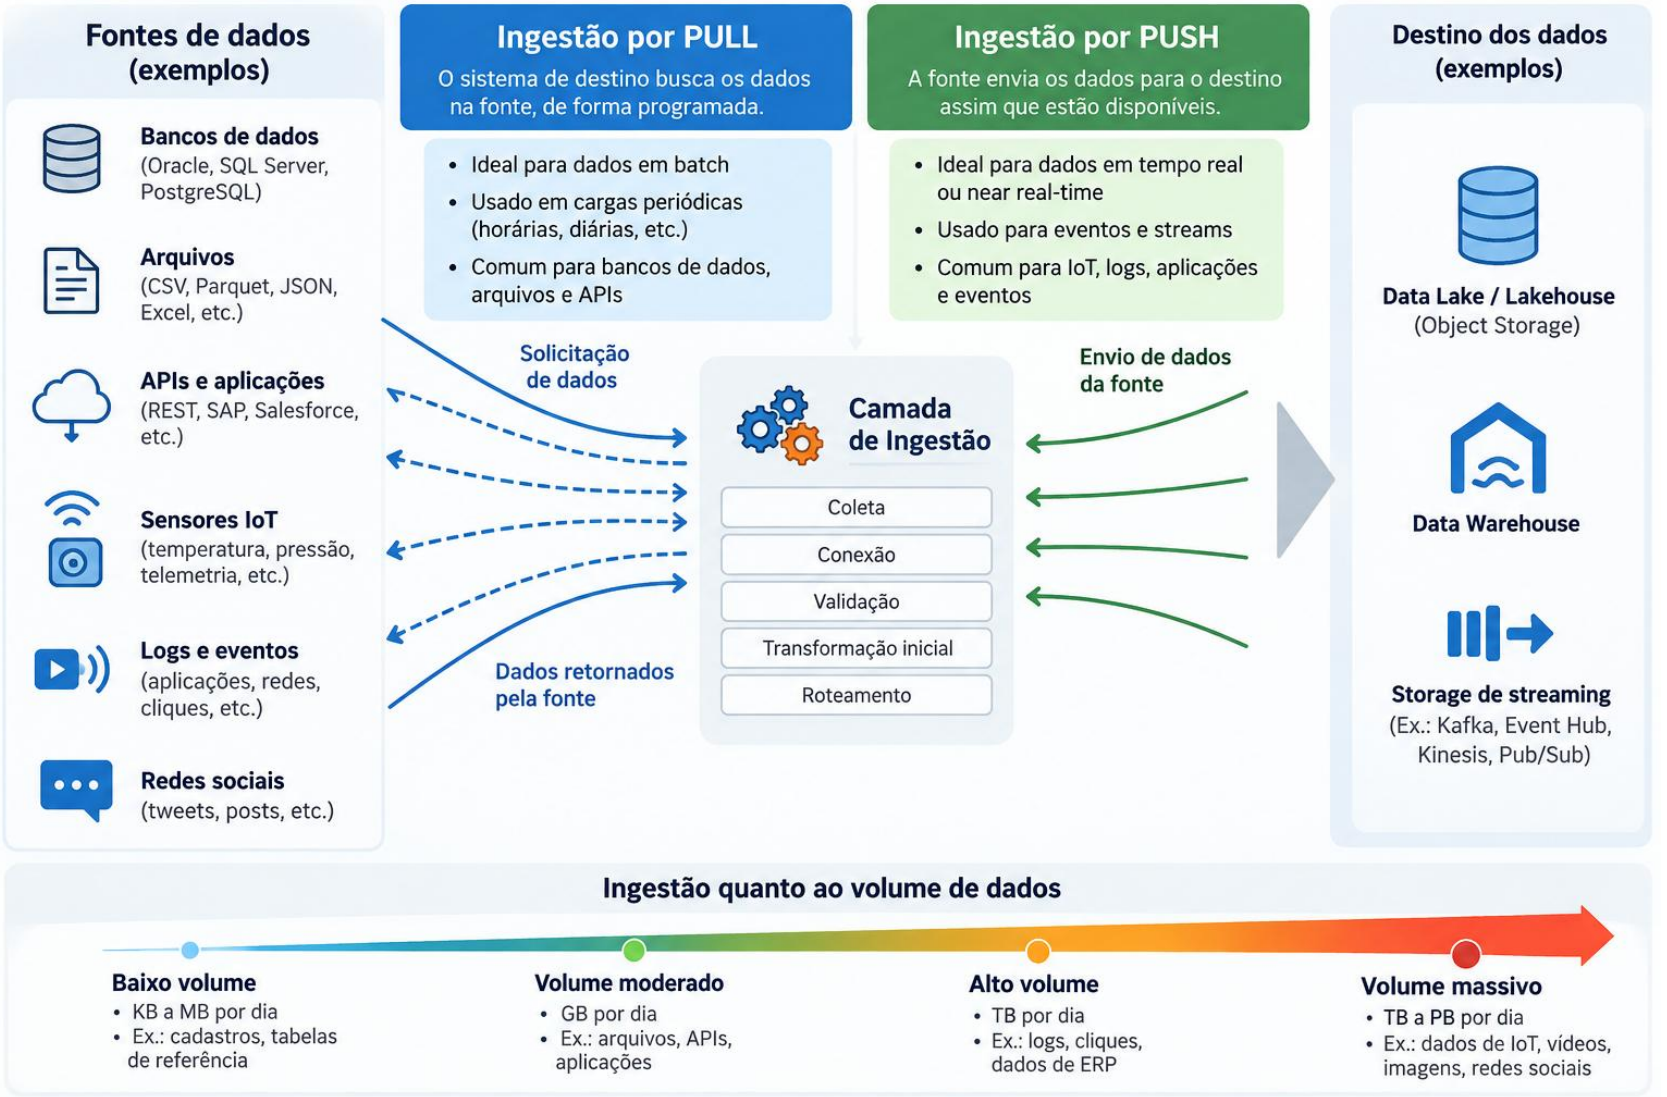
Full extract: *A cada execução, a origem é varrida novamente e o dataset completo é transferido.*

Incremental load: *Carga progressiva. Extrai apenas o que mudou por meio de watermarks (timestamp, offset, identificador incremental)*

CDC: *Leitura dos logs de transação e carga apenas das mudanças desde a última verificação*

• **Comunicação** – Quem inicia a transferência:
Pull: *O pipeline consulta periodicamente a fonte.*
Pipeline → API → Fonte

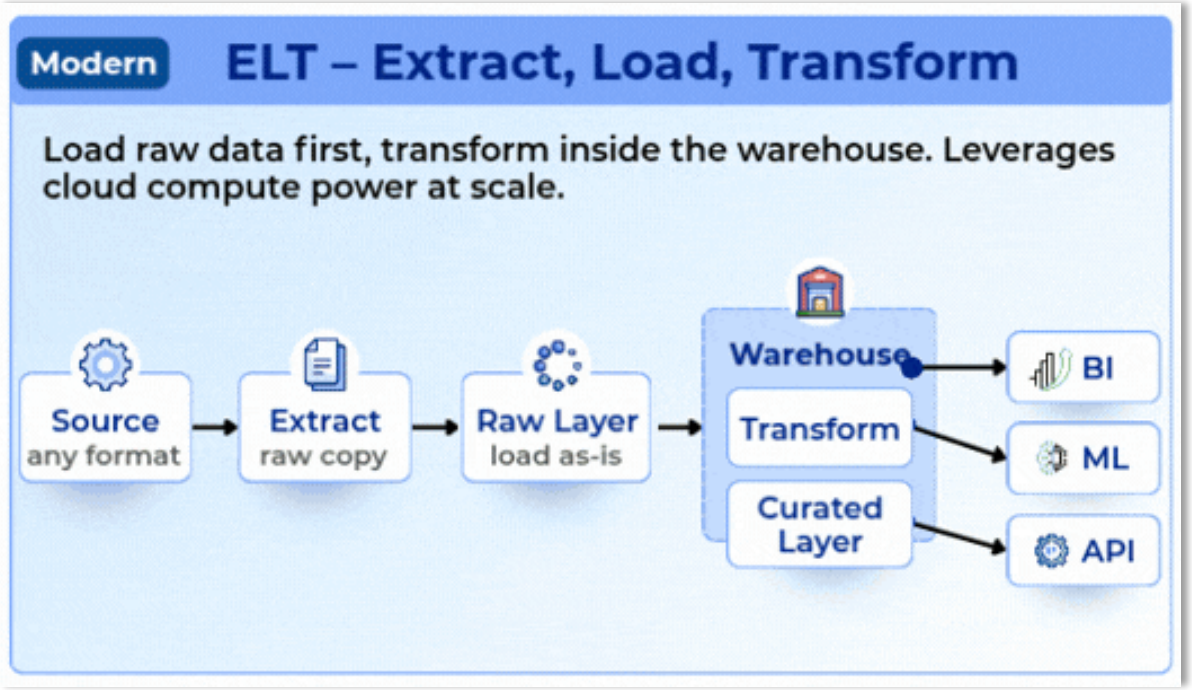
Push: *A origem publica um evento.*
Fonte → Evento → Broker → Consumidores



Classificação quanto Transformação



ETL: A transformação ocorre antes da carga chegar no destino.



ELT: Os dados são carregados primeiro e transformados posteriormente, no ambiente de destino

Transformação não significa apenas “limpar dados”

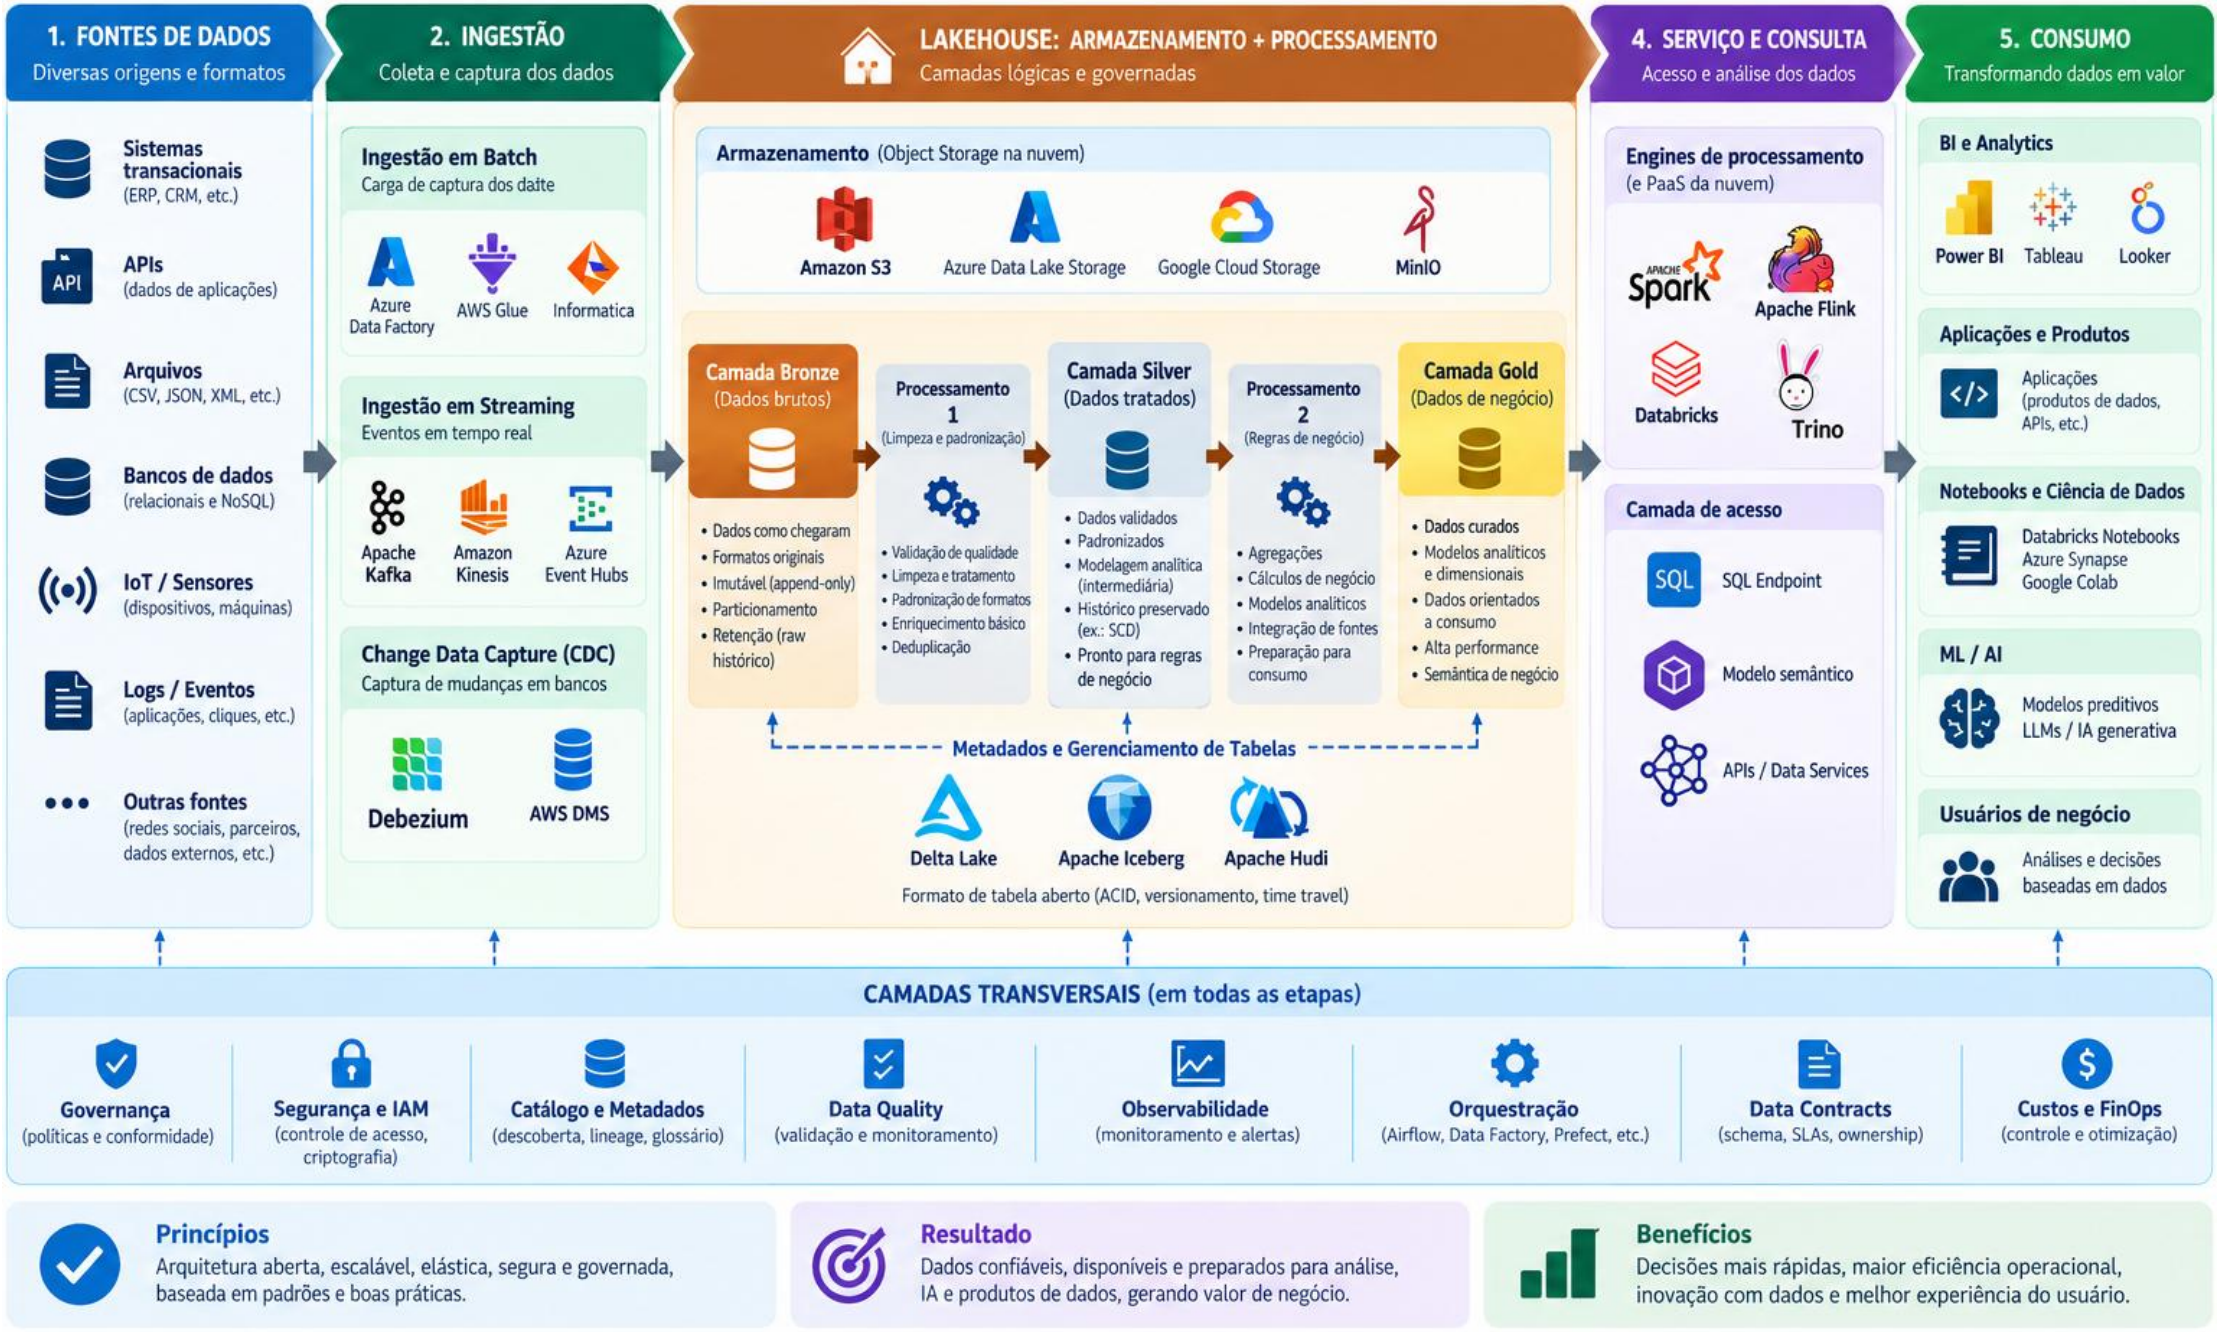
Escolha com base em governança, custo, capacidade computacional e reprocessamento.

- **Normalizar**
- **Enriquecer**
- **Agregar**
- **Deduplicar**
- **Mascarar**
- **Reconciliar**
- **Calcular métricas**
- **Detectar anomalias**

Exemplo:
Em um e-commerce, pedidos e cliques entram na camada RAW sem perda do registro original. Na TRUSTED, eventos repetidos são deduplicados, produtos são associados ao catálogo, dados pessoais são mascarados e os valores dos pedidos são reconciliados com pagamentos. Na REFINED, o pipeline calcula faturamento, conversão e ticket médio por período, região ou canal.

Uma anomalia, como uma queda súbita de conversão, pode então ser detectada sobre dados cuja origem e transformação são explicáveis.

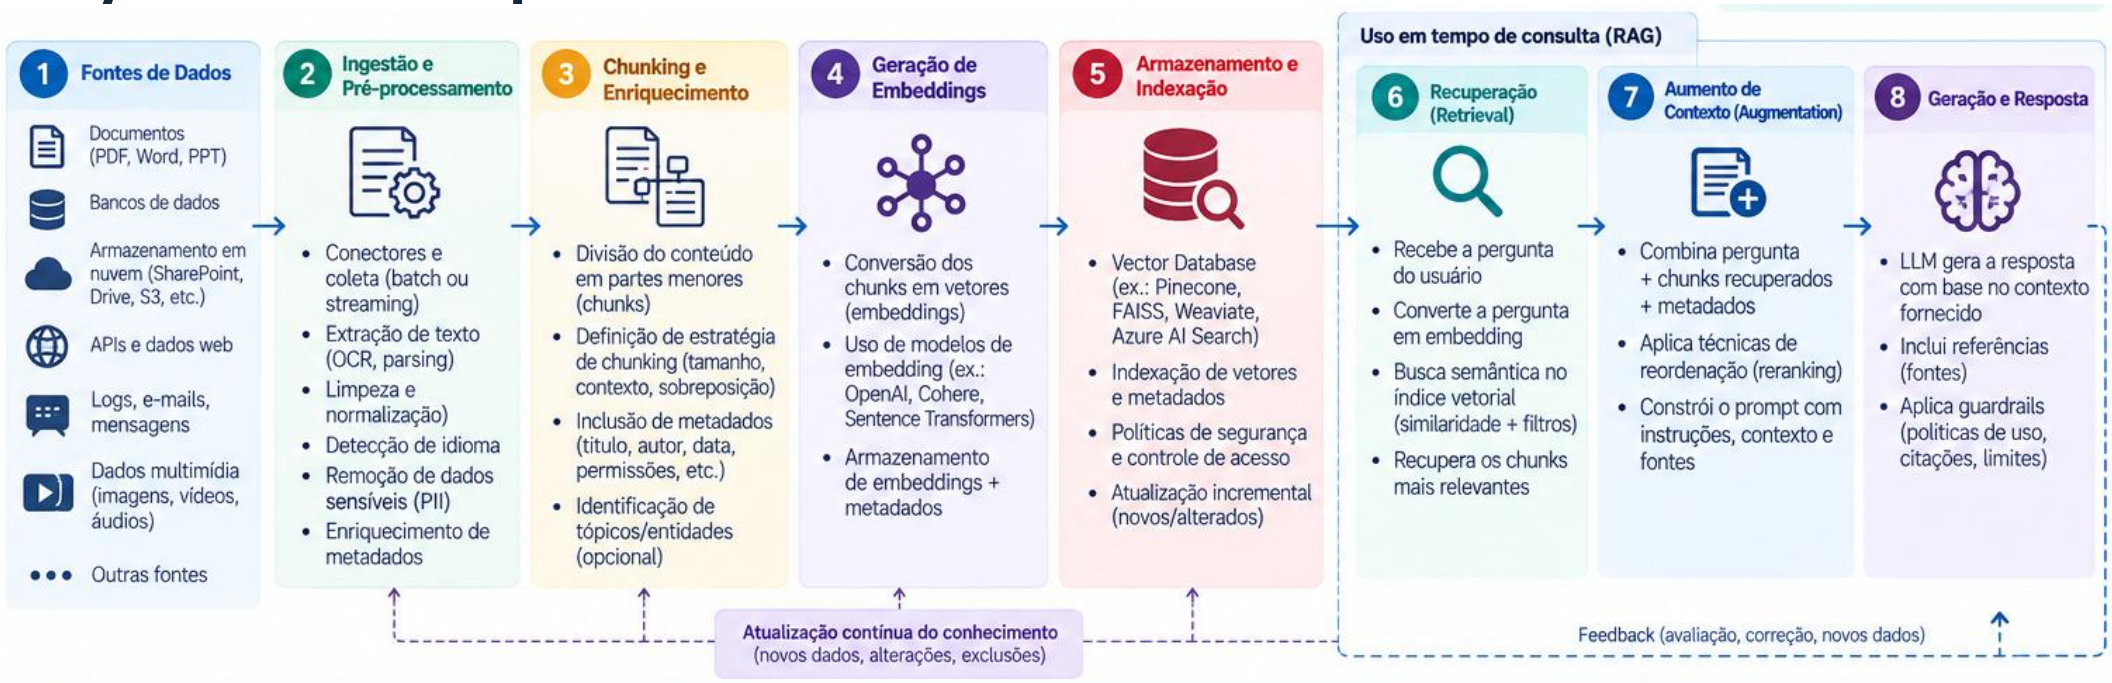



1. FONTES DE DADOS
Diversas origens e formatos
Sistemas transacionais
(ERP, CRM, etc.)
APIs
(dados de aplicações)
Arquivos
(CSV, JSON, XML, etc.)
Bancos de dados
(relacionais e NoSQL)
IoT / Sensores
(dispositivos, máquinas)
Logs / Eventos
(aplicações, cliques, etc.)
Outras fontes
(redes sociais, parceiros, dados externos, etc.)
2. INGESTÃO
Coleta e captura dos dados
Ingestão em Batch
Carga de captura dos daite
Azure Data Factory
AWS Glue
Informatica
Ingestão em Streaming
Eventos em tempo real
Apache Kafka
Amazon Kinesis
Azure Event Hubs
Change Data Capture (CDC)
Captura de mudanças em bancos
Debezium
AWS DMS
LAKEHOUSE: ARMAZENAMENTO + PROCESSAMENTO
Camadas lógicas e governadas
Armazenamento (Object Storage na nuvem)
Amazon S3
Azure Data Lake Storage
Google Cloud Storage
MinIO
Camada Bronze
(Dados brutos)
Dados como chegaram
Formatos originais
Imutável (append-only)
Particionamento
Retenção (raw histórico)
Processamento 1
(Limpeza e padronização)
Validação de qualidade
Limpeza e tratamento
Padronização de formatos
Enriquecimento básico
Deduplicação
Camada Silver
(Dados tratados)
Dados validados
Padronizados
Modelagem analítica (intermediária)
Histórico preservado (ex.: SCD)
Pronto para regras de negócio
Processamento 2
(Regras de negócio)
Agregações
Cálculos de negócio
Modelos analíticos
Integração de fontes
Preparação para consumo
Camada Gold
(Dados de negócio)
Dados curados
Modelos analíticos e dimensionais
Dados orientados a consumo
Alta performance
Semântica de negócio
Metadados e Gerenciamento de Tabelas
Delta Lake
Apache Iceberg
Apache Hudi
Formato de tabela aberto (ACID, versionamento, time travel)
4. SERVIÇO E CONSULTA
Acesso e análise dos dados
Engines de processamento
(e PaaS da nuvem)
Spark
Apache Flink
Databricks
Trino
Camada de acesso
SQL Endpoint
Modelo semântico
APIs / Data Services
5. CONSUMO
Transformando dados em valor
BI e Analytics
Power BI
Tableau
Looker
Aplicações e Produtos
Aplicações (produtos de dados, APIs, etc.)
Notebooks e Ciência de Dados
Databricks Notebooks
Azure Synapse
Google Colab
ML / AI
Modelos preditivos
LLMs / IA generativa
Usuários de negócio
Análises e decisões baseadas em dados
CAMADAS TRANSVERSAIS (em todas as etapas)
Governança
(políticas e conformidade)
Segurança e IAM
(controle de acesso, criptografia)
Catálogo e Metadados
(descoberta, lineage, glossário)
Data Quality
(validação e monitoramento)
Observabilidade
(monitoramento e alertas)
Orquestração
(Airflow, Data Factory, Prefect, etc.)
Data Contracts
(schema, SLAs, ownership)
Custos e FinOps
(controle e otimização)
Princípios
Arquitetura aberta, escalável, elástica, segura e governada, baseada em padrões e boas práticas.
Resultado
Dados confiáveis, disponíveis e preparados para análise, IA e produtos de dados, gerando valor de negócio.
Benefícios
Decisões mais rápidas, maior eficiência operacional, inovação com dados e melhor experiência do usuário.

Classificação quanto à finalidade – ML Pipeline



GenIA/ RAG Data Pipeline



O que torna o RAG Pipeline diferente?

1. Foco em conhecimento não estruturado (documentos, textos, mídias).
2. Geração de embeddings e uso de um banco vetorial.
3. Recuperação semântica de contexto relevante.
4. Integração com LLM para gerar respostas fundamentadas.
5. Atualização contínua do conhecimento (pode ser batch ou streaming).
6. Enfase em governança, segurança e rastreabilidade das fontes.

Principais Tecnologias (exemplos)

Ingestão	Connectors, Apache NiFi, Airflow, Cloud Functions, Databricks, AWS Glue
Processamento	Spark, Dataflow, ETL, OCR, parsers
Embeddings	OpenAI, Cohere, Hugging Face, Sentence Transformers
Vector DB	Pinecone, Weaviate, FAISS, Milvus, Azure AI Search, Elasticsearch
Orquestração	Airflow, Prefect, Databricks, Vertex AI Pipelines
LLM	OpenAI, Gemini, Claude, Llama, etc.
Monitoramento	LangSmith, OpenTelemetry, logging e métricas

Exemplo de fluxo em uso

1. Usuário faz uma pergunta: "Quais são as políticas de reembolso de viagem?"
2. A pergunta é convertida em embedding e busca os documentos mais relevantes.
3. Os chunks recuperados são adicionados ao prompt.
4. O LLM gera a resposta com base no contexto, citando as fontes.
5. Feedback do usuário pode ser usado para melhorar o pipeline (ex.: novo documento, ajuste de chunking, reindexação).

Casos de uso

- Assistentes corporativos (baseados em documentos internos)
- Suporte ao cliente (com base na base de conhecimento)
- Pesquisa e análise de informações (em grandes volumes de documentos)
- Educação e treinamento (com materiais institucionais)
- Aplicações setoriais (saúde, jurídico, financeiro, etc.)

CENARIO

O dashboard diz “crescimento”. O caixa diz “queda”.

Segunda-feira, 8h00. Uma campanha-relâmpago entra no ar — e os sistemas começam a contar histórias incompatíveis:

- **A —** Cliques indicam +38% de conversão, mas o ERP em batch ainda não fechou a madrugada.
- **B —** Após uma recuperação, pedidos foram duplicados; pagamentos apontam queda na receita aprovada.
- **C —** O recomendador promove um item sem estoque, enquanto o assistente afirma que ele está disponível.
- **D —** Uma mudança de esquema eliminou o campo “desconto” e dados pessoais chegaram à camada RAW sem mascaramento.

30 min

É o tempo até a reunião do conselho.

Você mantém ou interrompe a campanha?

Qual número é confiável — e como você prova a decisão?

RESPOSTA DO CENÁRIO

Pause agora; retome com dados reconciliados

Em 30 minutos, contenha o risco, reconstrua a verdade operacional e gere evidência auditável.

0–5 min

CONTER O RISCO

- Pausar a campanha e a recomendação do SKU.
- Bloquear no RAG respostas de estoque sem dado atual.
- Preservar os eventos brutos; não “corrigir” a origem.

5–20 min

RECONCILIAR NA TRUSTED

- Usar CDC/streaming para decisão; batch fica para reconciliação posterior.
- Deduplicar por chave idempotente e reconciliar pedido × pagamento.
- Quarentenar a quebra de esquema e mascarar dados pessoais.

20–30 min

PUBLICAR E PROVAR

- Na REFINED, publicar receita aprovada, conversão paga e estoque confirmado.
- Validar freshness, completude e anomalias; registrar watermark, execução e linhagem.
- Retomar somente após os controles passarem.

FONTE DE VERDADE: pedido único + pagamento aprovado + estoque confirmado.

ML e RAG consomem apenas dados TRUSTED/REFINED; sem confiança, o sistema deve se abster.

2

Introdução a Data Mesh e Data Fabric

- Recaptulando: do Data Warehouse ao Lakehouse
- Data Fabric: evolução tecnológica
- Data Mesh: os quatro princípios de Dehghani
- Quando considerar cada abordagem

Contexto

Uma grande companhia de petróleo possui diversas áreas de negócio, como:

- Exploração e Produção (Upstream)
- Refino
- Logística e Transporte
- Comercialização
- SMS (Segurança, Meio Ambiente e Saúde)
- Manutenção Industrial
- Suprimentos

Com a informatização da empresa, todas essas áreas passaram a depender da equipe central de Dados e TI para criar relatórios, disponibilizar dados, desenvolver dashboards e garantir a qualidade das informações.
No entanto, a equipe central não possui conhecimento profundo sobre cada processo operacional específico.

Cenário

A área de **Exploração e Produção** deseja criar um modelo preditivo para identificar falhas em Bombas Centrífugas Submersas (BCS) instaladas em poços offshore.
Para isso, solicita à equipe central de dados:

- Dados históricos dos sensores dos equipamentos;
- Histórico de intervenções de manutenção;
- Dados de produção dos poços;
- Informações operacionais da plataforma.

A equipe central recebe a solicitação, mas encontra dificuldades porque:

- Não conhece o significado de vários parâmetros dos sensores;
- Não sabe quais eventos são considerados falhas críticas;
- Não entende quais variáveis impactam mais o desempenho do poço;
- Precisa realizar diversas reuniões para entender as regras de negócio.

Enquanto isso, outras áreas também enviam solicitações semelhantes.

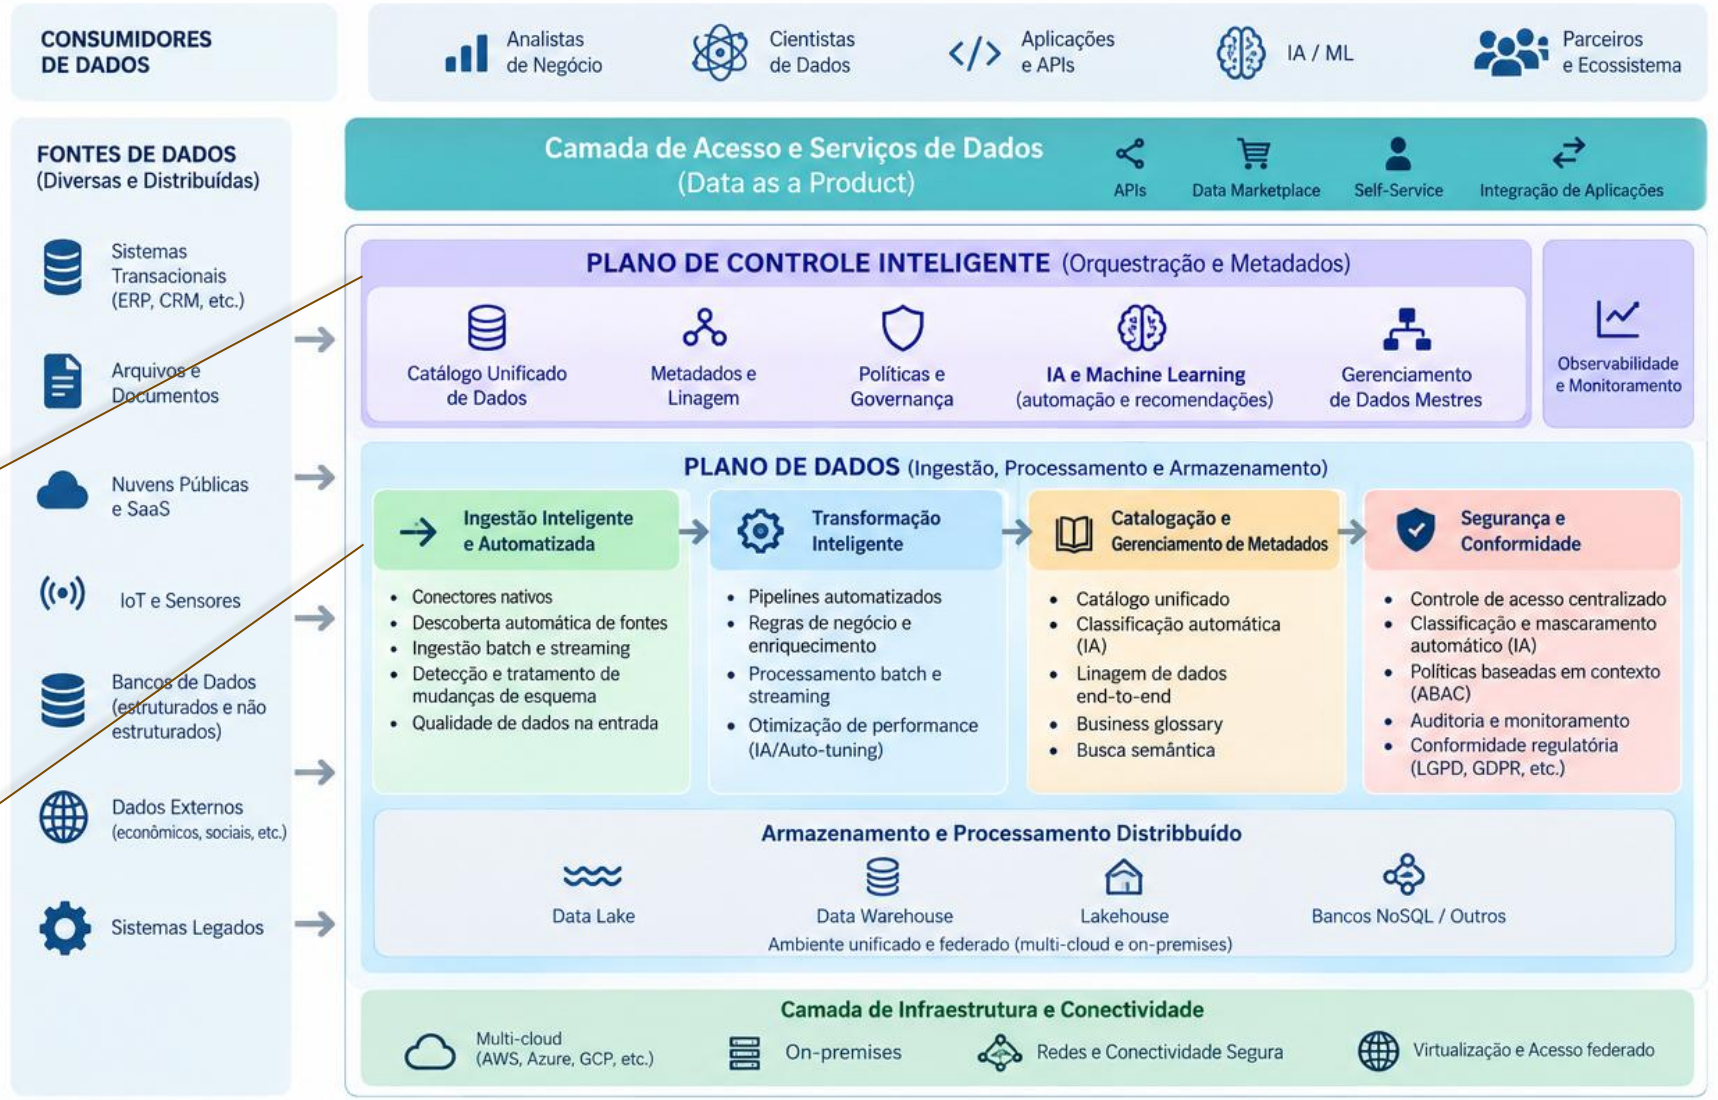
Qual é a solução para este cenário?

Data Fabric

Não é uma mudança na estrutura organizacional

Catálogo de metadados ativo, políticas de acesso, gestão de dados mestres, processamento em tempo real, APIs e, frequentemente, virtualização de dados.

Camada inteligente e automatizada de ingestão, transformação, catalogação e segurança.



DIFERENCIAIS DO DATA FABRIC

- **Visão unificada e federada** de dados (sem necessidade de mover todos os dados)
- **Catálogo de dados inteligente** com linagem e semântica
- **Automação com IA/ML** (em ingestão, transformação, classificação e governança)
- **Governança e segurança consistentes** em qualquer ambiente (multi-cloud e híbrido)
- **Suporte a múltiplos formatos e localizações de dados** (lake, warehouse, SaaS, etc.)
- **Data as a Product** e marketplace de dados
- **Orquestração centralizada** e observabilidade de ponta a ponta

PRINCIPAIS BENEFÍCIOS

- Acesso mais rápido e seguro aos dados
- Maior confiabilidade e qualidade dos dados
- Redução de custos e complexidade
- Maior agilidade para IA e inovação
- Suporte a ambientes híbridos e multi-cloud
- Dados como ativo estratégico do negócio

EM COMPARAÇÃO COM O LAKEHOUSE

O Lakehouse é uma plataforma de armazeaamento e processamento. O Data Fabric vai além: conecta, governa, integra e automatiza todo o ecossistema de dados, independentemente de onde os dados estão.

Data Mesh



Zhamak Dehghani

PRINCÍPIOS DO DATA MESH

1. **Dados como produto**
   Cada domínio é responsável por entregar dados de alta qualidade como um produto.
2. **Propriedade de domínio**
   Times de negócio (domínios) possuem e gerenciam seus dados, ponta a ponta.
3. **Plataforma de dados como habilitadora**
   Plataforma self-service, robusta, segura e reutilizável por todos os domínios.
4. **Governança federada**
   Padrões e princípios globais, com implementação descentralizada e colaborativa.

RESULTADOS ESPERADOS

- Maior agilidade e autonomia
- Dados mais próximos do negócio
- Escalabilidade organizacional
- Inovação com dados
- Maior confiança e qualidade
- Evolução contínua e colaborativa

"Data Mesh não é apenas uma arquitetura, é uma mudança de mentalidade, organizacional e cultural, para tratar dados como um produto, empoderando os domínios e promovendo uma economia de dados distribuída."

Zhamak Dehghani

Data Fabric vs Data Mesh

Critério	Data Fabric	Data Mesh
Natureza da mudança	Predominantemente tecnológica	Predominantemente organizacional
Propriedade do dado	Centralizada	Descentralizada, por domínio
Foco principal	Integração, automação, catálogo ativo	Autonomia de domínio, dado como produto
Pré-requisito organizacional	Menor: evolui sobre a TI atual	Maior: exige reorganização por domínios
Risco típico	Complexidade tecnológica, dependência de fornecedor	Inconsistência entre domínios, duplicação

Nenhuma das duas substitui automaticamente Data Lake, Data Warehouse ou Lakehouse: normalmente são construídas sobre essas camadas.

ENCADEAMENTO LÓGICO

Como os assuntos se conectam

1

Big Data

Dados crescem em volume, variedade e velocidade

2

Relacional × NoSQL

Dimensão estrutural do armazenamento

3

DW, Data Lake, Lakehouse

Arquiteturas de armazenamento e processamento

4

Fabric e Mesh

Governança e propriedade em escala organizacional

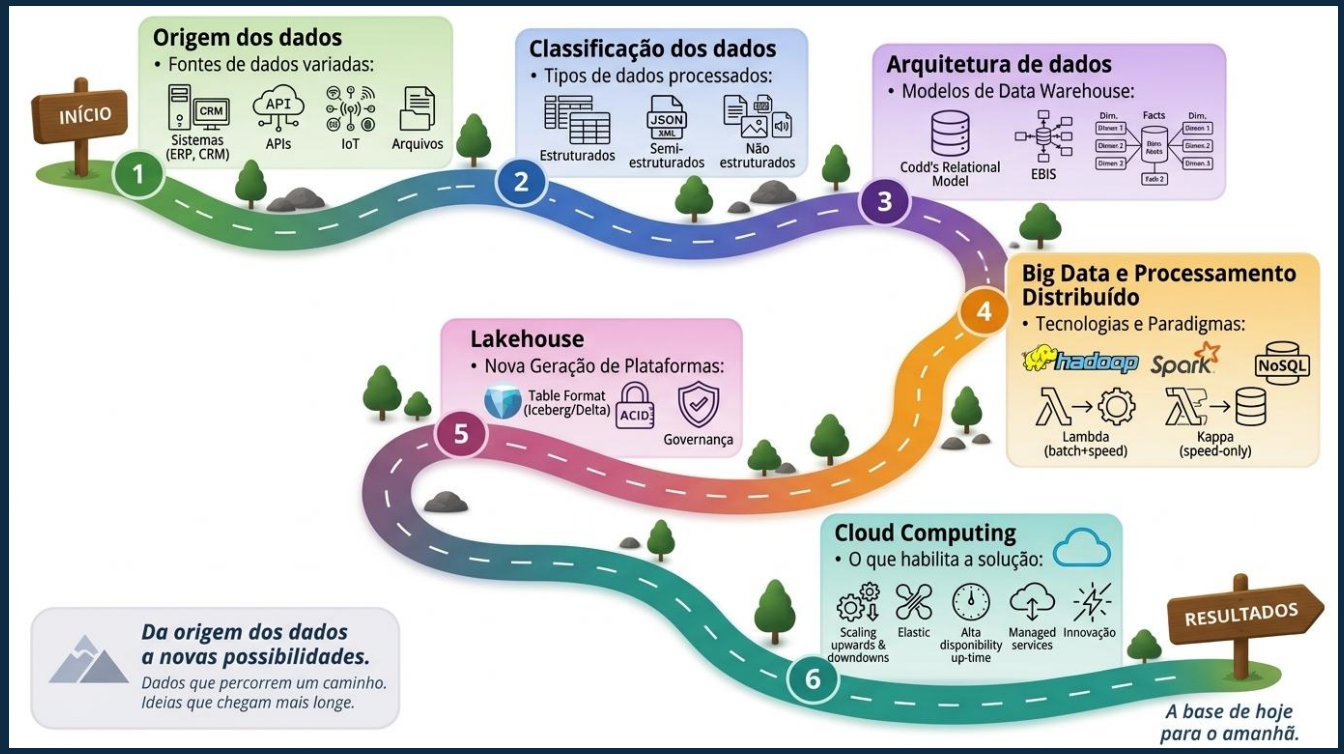
3

BLOCO

Introdução a cloud-computing

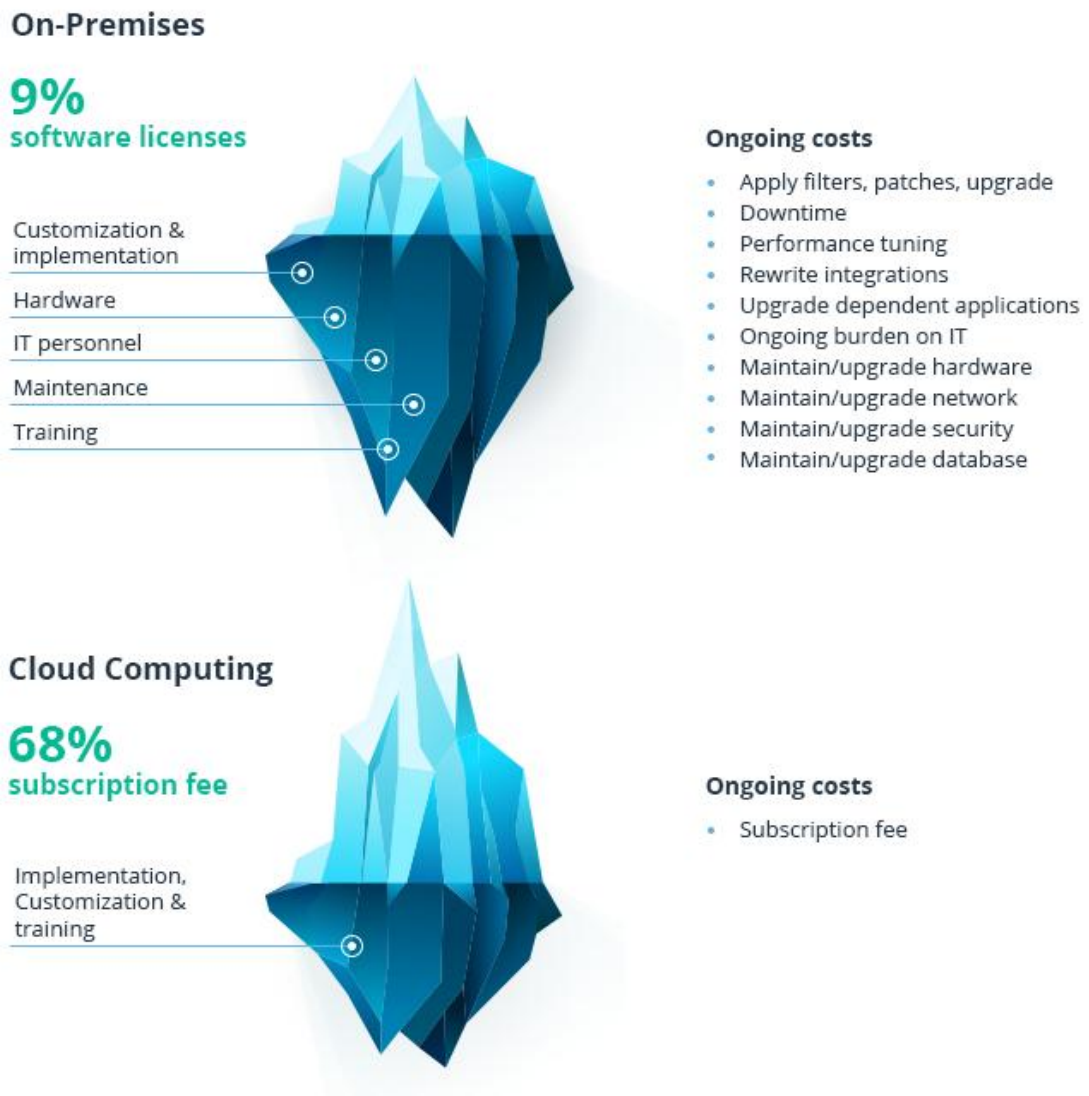
Computação na nuvem

- Introdução a computação na nuvem
- Modelos de serviços em nuvem
- Uso multi-cloud



Cloud computing: On-premises VS nuvem

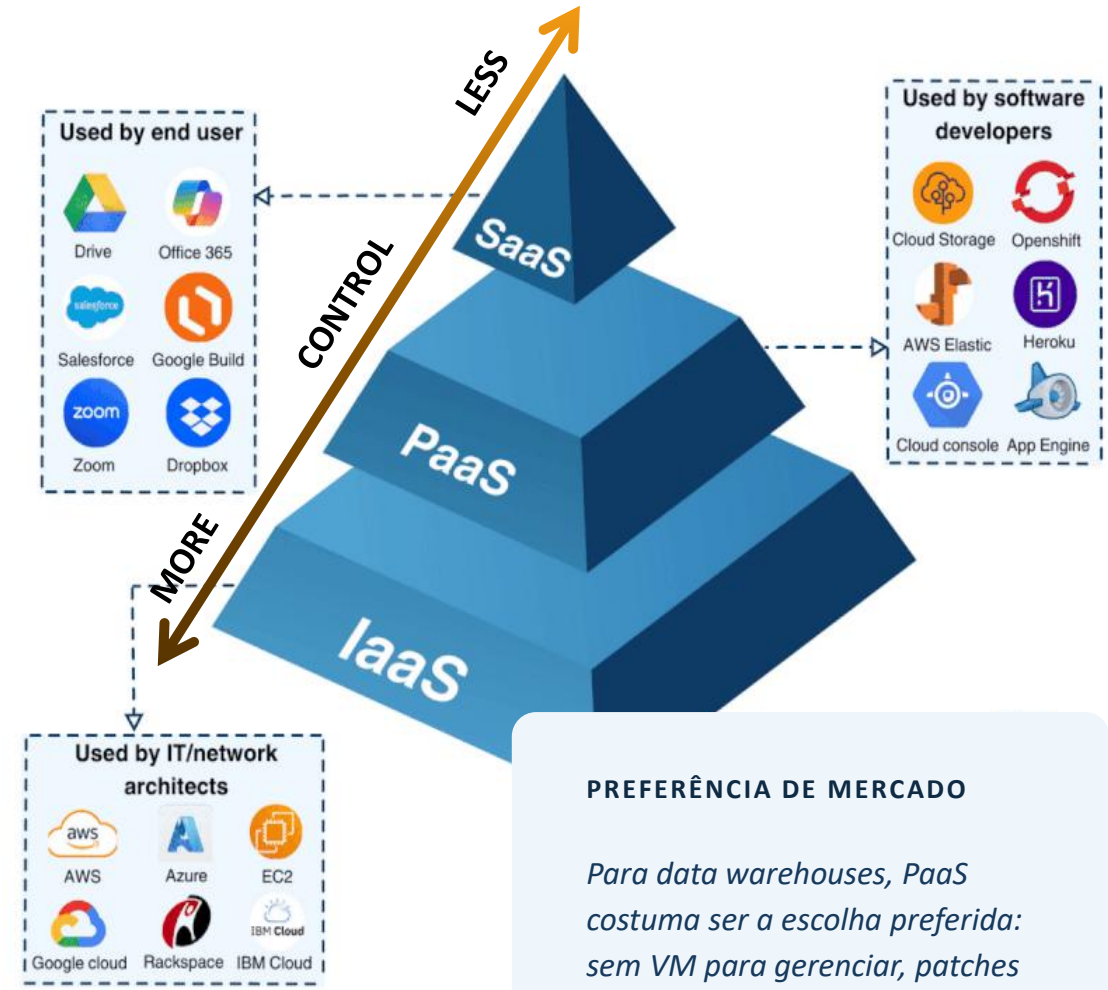
- On-premise significa comprar, instalar e manter seus próprios servidores fisicamente. Controle total, mas custo alto de hardware, energia, datacenter e equipe especializada.
- Na nuvem, você aluga capacidade computacional de um provedor (CSP, Cloud Service Provider) e paga apenas pelo que consome, podendo escalar para cima ou para baixo em minutos.
- Vantagens documentadas: custo elimina investimento inicial pesado (CapEx vira OpEx); implantação em horas, não em semanas; SLAs e suporte dedicado do provedor; datacenters distribuídos globalmente garantem alta disponibilidade e baixa latência; segurança e conformidade regulatória incorporadas.
- O custo de errar também cai: se uma arquitetura não funcionar, basta apagar os recursos criados, sem hardware parado.
- A tendência de mercado é clara: cada vez mais cargas de Big Data migram para a nuvem, e o próprio ecossistema Hadoop, historicamente on-premise, vem perdendo espaço para serviços nativos de nuvem.



Modelos de serviços em nuvem

Pense nos três modelos como formas diferentes de alugar uma moradia:

- IaaS (Infrastructure as a Service): você aluga um terreno com fundação e encanamento prontos, mas constrói e mobília a casa. O provedor entrega servidores, armazenamento e rede virtualizados; você gerencia sistema operacional, aplicações e dados.
- PaaS (Platform as a Service): você aluga um apartamento pronto para morar. O provedor cuida da estrutura (runtime, middleware, sistema operacional); você só configura e usa. Não existe máquina virtual para gerenciar.
- SaaS (Software as a Service): você fica em um hotel, tudo incluso. O provedor hospeda e gerencia software e infraestrutura por completo; você só acessa pela internet.



PREFERÊNCIA DE MERCADO

Para data warehouses, PaaS costuma ser a escolha preferida: sem VM para gerenciar, patches e backups automáticos, e recuperação de desastre configurada em poucos cliques.

IaaS, PaaS e SaaS lado a lado

Critério	IaaS	PaaS	SaaS
O que o provedor gerencia	Hardware, virtualização, rede	Tudo do IaaS + runtime, middleware, SO	Tudo, incluindo o próprio software
O que você gerencia	SO, aplicações, dados	Aplicações e dados	Apenas o uso
Flexibilidade	Alta	Média	Baixa
Facilidade de uso	Exige conhecimento de infraestrutura	Foco total em código e dados	Nenhuma configuração técnica
Exemplo típico	Máquinas virtuais (VMs)	Bancos de dados gerenciados, Databricks	Salesforce, ferramentas de BI prontas

Mercado: Os 3 grandes provedores

Critério	Azure	AWS	GCP
Ano de lançamento	2008	2006	2008
Participação de mercado (global)	≈ 23%	≈ 32%	≈ 10%
Ponto forte	Integração com produtos Microsoft	Maior variedade de serviços e tipos de instância	Analytics e machine learning
Curva de aprendizado	Mais fácil para quem já usa Microsoft	Mais íngreme, dado o volume de serviços	Interface amigável
Produto analítico principal	Azure Synapse Analytics, Microsoft Fabric	Amazon Redshift	Google BigQuery

DUAS DECISÕES, DOIS CRITÉRIOS DIFERENTES

- Uma seguradora com forte presença de ferramentas Microsoft (Office 365, Power BI, Active Directory) tende a escolher Azure: a integração nativa reduz atrito de implementação e a curva de aprendizado da equipe já instalada.
- Uma startup de recomendação de produtos, cujo diferencial é machine learning em grande escala, tende a considerar GCP pela força histórica do provedor em analytics e IA, incluindo BigQuery e Vertex AI.

Ponto central: a escolha do provedor raramente é sobre "qual nuvem é tecnicamente superior". As três oferecem hoje conjuntos de serviços muito parecidos. A decisão real pondera o ecossistema já existente na empresa, o custo negociado e a estratégia de longo prazo do negócio.

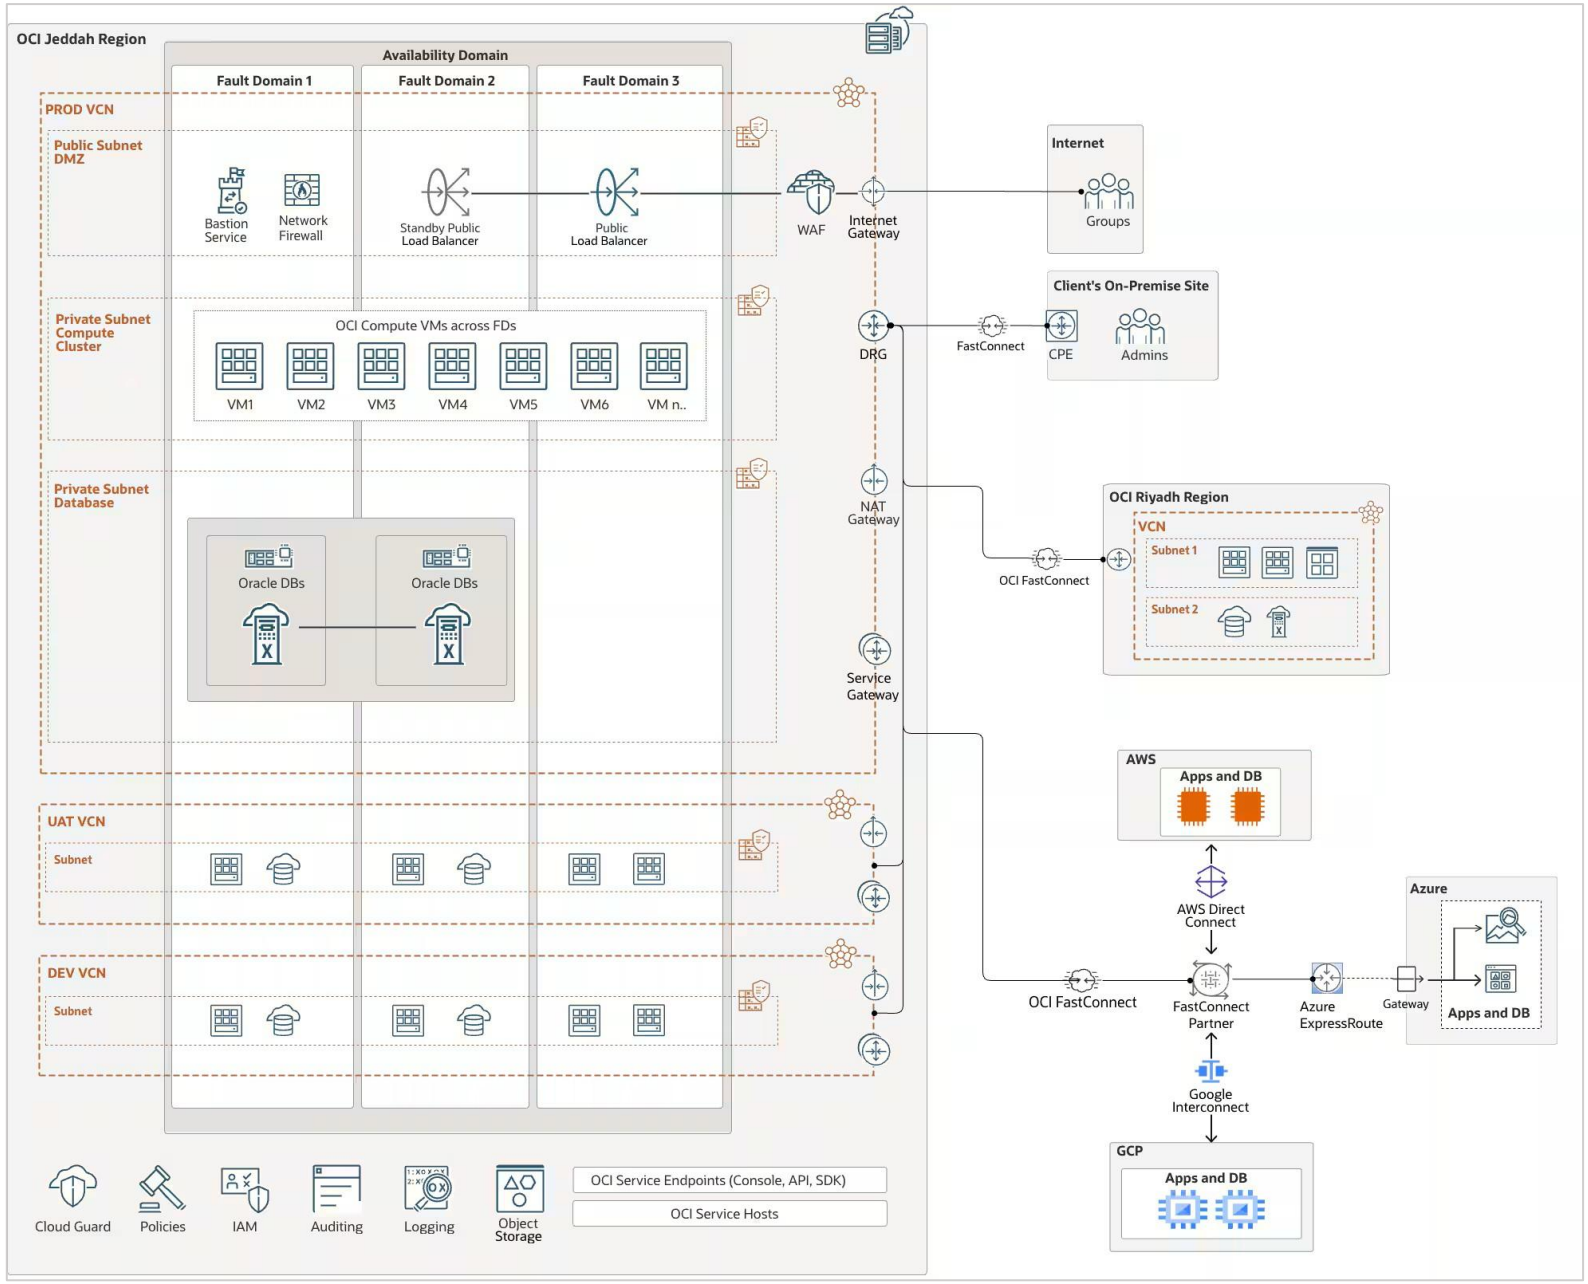
Multi-cloud: vantagens reais

- Multi-cloud é usar mais de um provedor de nuvem simultaneamente, geralmente para aproveitar o ponto forte de cada um.
- Redundância e disponibilidade: se um provedor tem uma indisponibilidade regional, a operação segue no outro.
- Soberania de dados: nem todo provedor tem datacenter em toda região do mundo. Uma empresa que precisa manter dados de clientes fisicamente em determinado país pode precisar de um provedor específico só para aquela região.
- Evitar dependência exclusiva de um único fornecedor ("todos os ovos na mesma cesta"), especialmente se o provedor puder se tornar concorrente do seu próprio negócio.

MITO A DESFAZER

Multi-cloud raramente gera poder de barganha real. Os provedores dão descontos maiores conforme o volume de consumo em uma única nuvem, então dividir o consumo entre dois provedores costuma custar mais, não menos.

Cenário Multi-cloud



1. Setor de Energia e Utilities

Distribuidoras de energia, geração hidrelétrica, comercializadoras.

Como usariam a arquitetura:

- Centralizar dados de medidores inteligentes, SCADA e sensores IoT.
- Previsão de demanda de energia usando Machine Learning.
- Manutenção preditiva de subestações, transformadores e linhas de transmissão.
- Detecção de perdas não técnicas (fraudes e furtos de energia).
- Monitoramento ESG e indicadores regulatórios.

2. Serviços Financeiros e Seguros

Bancos, fintechs, seguradoras e administradoras de cartão.

Como usariam a arquitetura:

- Consolidação de dados transacionais em tempo real.
- Modelos de crédito e risco.
- Detecção de fraudes com algoritmos de IA.
- Segmentação de clientes para ofertas personalizadas.
- Análises regulatórias e compliance.

3. Varejo e E-commerce

Marketplaces, supermercados, lojas omnichannel.

Como usariam a arquitetura:

- Integração de dados de vendas, CRM, logística e canais digitais.
- Recomendação de produtos usando IA.
- Previsão de demanda e otimização de estoque.
- Análise de comportamento do consumidor.
- Precificação dinâmica.

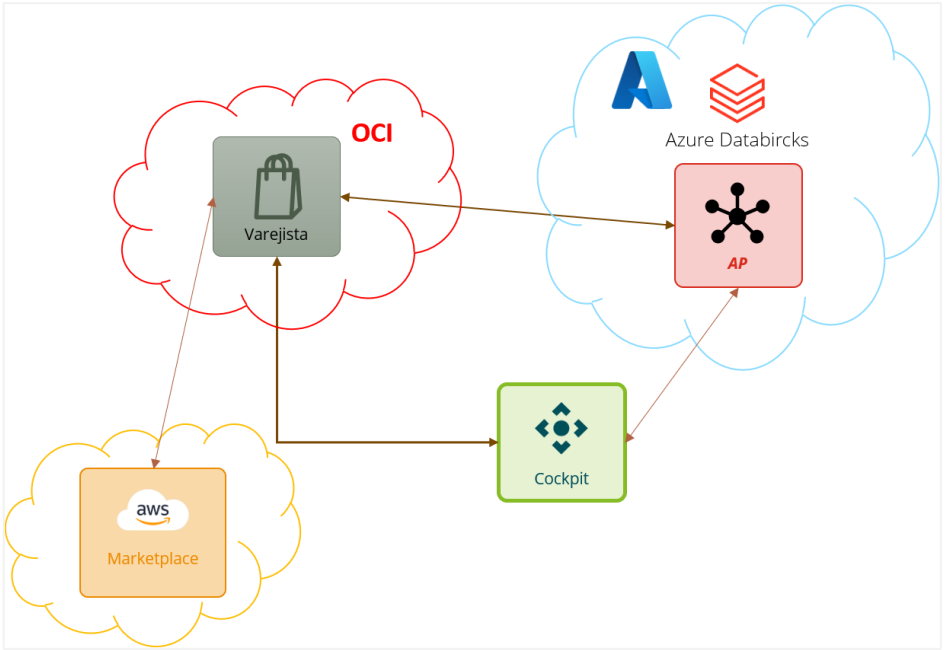
Estudo de caso

Uma empresa de varejo possui suas operações centralizadas em OCI e utiliza Azure para integrar com serviços Microsoft que são utilizados corporativamente (email, sharepoint, teams, Power BI, etc).

Além disso, esta varejista utiliza o marketplace da AWS para vender seus produtos online.

Esta empresa criou uma aplicação ***AP*** dentro da nuvem Azure utilizando Databricks, que faz o ranking de melhor cotação de frete consultando uma aplicação externa ***EXT*** (SaaS) que contém regras de imposto por CEP.

A varejista quer evoluir a aplicação ***AP,*** que contém apenas regras de negócio simples, para um motor de decisão inteligente, guiado por dados e algoritmos avançados de otimização combinando frete, custo do produto, capacity e impostos para gerar o melhor cenário de economia interna a cada pedido. A comunicação entre a aplicação ***AP*** e o motor de decisão **precisa ocorrer near-real time**.



O fornecedor **X** fez uma proposta de criar o motor inteligente na nuvem AWS, sugerindo aproveitamento dos dados do Marketplace que já estão nesta nuvem.

O fornecedor **Y** fez a proposta de criar o motor inteligente na nuvem Azure, sugerindo melhor conectividade com a aplicação ***AP***, que já está implementada em Azure.

Responda e justifique:

Qual nuvem deve ser escolhida para desenvolver e operar o otimizador inteligente?

Multi-cloud: armadilhas e quando evitar

- Interoperabilidade limitada: as nuvens não foram desenhadas para conversar entre si. Mover dados e processamento de um provedor para outro é lento e tecnicamente complexo.
- Custo de saída (egress fees): provedores cobram para você tirar dados da nuvem deles, o que penaliza justamente quem tenta trocar de fornecedor.
- Duplicação de esforço operacional: duas equipes de segurança, duas políticas de acesso, dois painéis de monitoramento, duas faturas. Isso é custo real de pessoal e complexidade administrativa.
- Se a meta é apenas flexibilidade para trocar de provedor no futuro, isso exige adotar IaaS, abrindo mão de boa parte dos serviços de valor agregado que fazem o PaaS valer a pena.
- Regra prática: a maioria das empresas se beneficia mais escolhendo um provedor principal e aprofundando o uso dele do que espalhando a operação entre vários.

Exercícios

1. O problema deixou de caber na arquitetura tradicional?

Uma empresa passa de 10 GB de dados mensais, uma única base relacional e atualização diária para 10 TB mensais, milhares de eventos por segundo, imagens e documentos, sensores IoT, APIs externas e necessidade de alguns casos de uso quase em tempo real.

Questão: Analise se essa empresa entrou em um contexto de Big Data.
Utilize os conceitos de **Volume, Variedade e Velocidade**.
Explique por que o problema não pode ser resolvido simplesmente aumentando a capacidade do servidor atual.

2. Desenhe uma arquitetura conceitual

Uma empresa deseja utilizar dados provenientes de ERP, CRM, APIs, logs e sensores.
Desenhe uma arquitetura contendo: **Fontes** → **Ingestão** → **Armazenamento** → **Processamento** → **Governança** → **Consumo**.

Depois responda:
1. Onde poderiam existir processos Batch?
2. Onde poderiam existir processos Streaming?
3. Onde a qualidade dos dados deveria ser aplicada?
4. Onde segurança e controle de acesso deveriam aparecer?
5. Quais consumidores poderiam utilizar os dados: BI, Analytics, IA/ML e aplicações operacionais?

3. Diagnóstico arquitetural: "temos muitos dados, mas pouca informação"

A organização afirma: *"Possuímos grandes volumes de dados, mas os relatórios são inconsistentes, diferentes áreas usam números diferentes e ninguém sabe qual é a fonte oficial."*

Identifique **cinco possíveis problemas arquiteturais ou de governança** que podem explicar essa situação.

Depois, proponha uma ação para cada problema.

Considere, entre outros: integração; qualidade; catálogo; linhagem; segurança; ownership; padronização; armazenamento; definição de métricas.

4. Desafio integrador — Projete a arquitetura de dados de uma empresa digital

A empresa possui: vendas em lojas físicas; e-commerce; aplicativo; CRM; ERP; sensores de estoque; atendimento por chat; redes sociais; parceiros externos via API.

Ela deseja:
1. dashboards gerenciais;
2. previsão de demanda;
3. alertas de ruptura de estoque;
4. personalização de ofertas;
5. análise de sentimento de clientes.

Sua tarefa: proponha uma arquitetura **conceitual** respondendo:

A. Fontes — Quais são as principais fontes?

B. Tipos — Quais dados são estruturados, semiestruturados e não estruturados?

C. Processamento — Quais processos deveriam ser Batch? Quais deveriam ser Streaming?

D. Armazenamento — Que tipos de ambientes poderiam coexistir?

E. Consumo — Quais consumidores utilizariam os dados: BI, Analytics, IA/ML ou aplicações operacionais?

F. Governança — Quais controles garantiriam dados confiáveis, acessíveis, seguros e rastreáveis?

Critério de avaliação: capacidade de justificar suas decisões arquiteturais.

RESPOSTAS DOS EXERCÍCIOS

Síntese dos exercícios: distribuir, desacoplar e governar o caminho do dado até a decisão.

1 SIM: É UM CONTEXTO DE BIG DATA

- **Volume** — 10 TB/mês requer armazenamento e computação distribuídos.
- **Variedade** — SQL, eventos, documentos, imagens, IoT e APIs pedem formatos e motores diferentes.
- **Velocidade** — milhares de eventos/s e baixa latência pedem streaming.

Conclusão — um servidor só vira gargalo e ponto único de falha; a solução deve escalar horizontalmente e com elasticidade.

2 ARQUITETURA CONCEITUAL

Fluxo — fontes → ingestão → lakehouse → batch/stream → trusted/refined → consumo.
Batch/stream — cargas, histórico, reconciliação e treino; telemetria, alertas e decisões imediatas.
Controles — qualidade na entrada e nas transformações; catálogo, linhagem, segurança e acesso atravessam as camadas.
Saídas — BI, Analytics, IA/ML e aplicações operacionais usam produtos governados.

3 CINCO CAUSAS — CINCO AÇÕES

- **Silos** → integração padronizada + modelo canônico.
- **Duplicidade/incompletude** → regras, SLAs e monitoramento.
- **Sem catálogo/linhagem** → catálogo ativo + rastreio.
- **Sem ownership** → owner/steward + contratos por domínio.
- **Métricas divergentes** → glossário + camada semântica.

4 EMPRESA DIGITAL: PROPOSTA INTEGRADA

Fontes/tipos — transações e IoT (estruturados), APIs/logs (semi), chat/social/mídia (não estruturados).
Processamento — batch para fechamento, histórico e treino; streaming para estoque, eventos e personalização.
Dados — object storage/lakehouse + warehouse/marts + feature store/cache.
Consumo — BI/Analytics; ML para demanda, oferta e sentimento; apps para alertas.
Governança — catálogo, linhagem, qualidade, contratos, IAM/LGPD, criptografia e observabilidade.

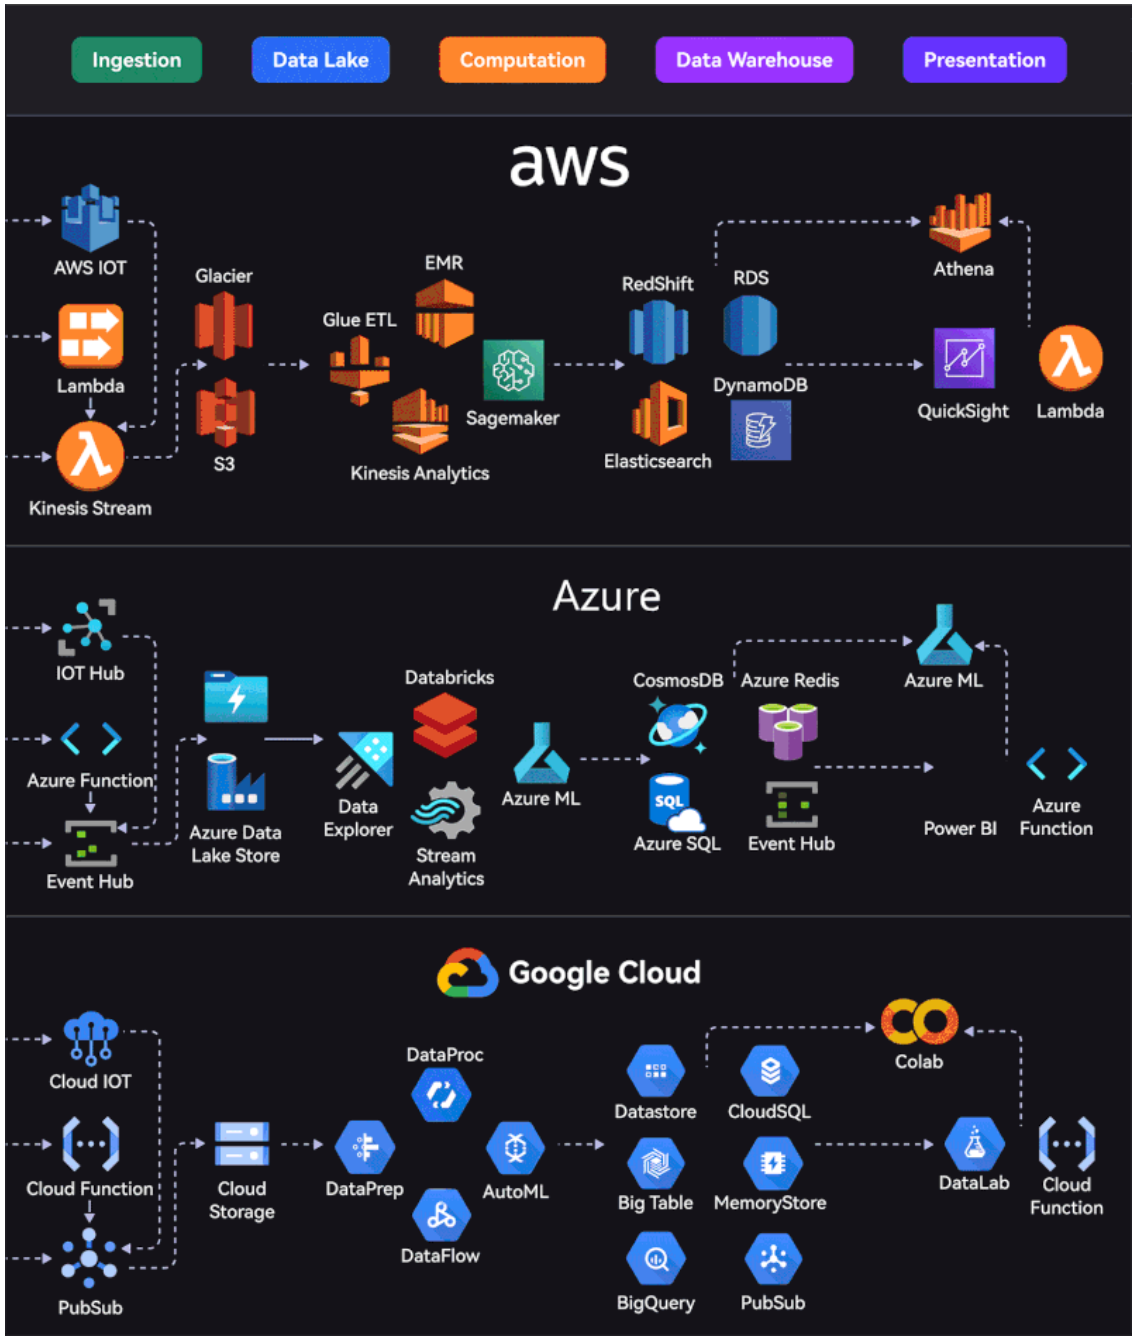
Comunicando a arquitetura

“Seu CEO não se importa com sua plataforma de dados. Nem um pouco. E isso não é culpa dele.
Você fala em arquiteturas.
Eles pensam em resultados.
A empresa não precisa entender sua plataforma.
*Precisa entender o que ela **resolve**.*

Então, quando você diz "plataforma de dados moderna", eles ouvem "projeto científico caro". Se quiser que eles entendam, tente isto:

1 Comece com a dor que eles já sentem.
"Sabe aquele relatório que leva 3 semanas e ninguém confia? É isso que a gente corrige."
2 Use o "antes e depois".
Antes: 5 pessoas costurando manualmente planilhas. Depois: Um dashboard. Tempo real. Zero palpitações. Pule o diagrama de arquitetura. Mostre a transformação.
3 Traduza cada componente em um resultado de negócio.
Não diga "pipeline de dados" Diga "a coisa que garante que seus números de vendas estejam precisos até as 8h."
Não diga "governança" Diga "o motivo pelo qual você não será multado.“

Use a linguagem deles, não a sua.
Sente-se nas reuniões deles. Leia os e-mails deles. Espelhe as palavras que eles já usam.
A melhor plataforma de dados do mundo não vale nada se ninguém acredita nela.
E a crença não vem das especificações técnicas. Vem da clareza.”



SÍNTESE FINAL

Uma boa arquitetura não é a que utiliza as tecnologias mais recentes. É a que consegue explicar, medir e operar o caminho entre um evento de origem e uma decisão confiável.

Bibliografia

Referência
Serra, J. (2024). Deciphering Data Architectures: Choosing Between a Modern Data Warehouse, Data Fabric, Data Lakehouse, and Data Mesh. O'Reilly Media.
Kaufmann, M., & Meier, A. (2023). SQL and NoSQL Databases: Modeling, Languages, Security and Architectures for Big Data Management. Springer.
Inmon, W. H., Linstedt, D., & Levins, M. (2019). Data Architecture: A Primer for the Data Scientist. Elsevier.
Silva, F. R., Santos, R. M., & Oliveira, L. A. (2020). Cloud Computing. Soluções Educacionais Integradas.
Molinari, L. (2017). Cloud Computing: A Inteligência na Nuvem e seu Novo Valor em TI. Editora Érica.
Mulder, J. (2020). Multi-Cloud Architecture and Governance. Packt Publishing.
Kleppmann, M. (2017). Designing Data-Intensive Applications. O'Reilly Media.

FGV

MÓDULO 3 CONCLUÍDO

Disciplina · Arquitetura de Dados e Big Data — MBA em Inteligência Artificial e Analytics Aplicados a Negócios

Debora Corsino