Fundação Getulio Vargas

Big Data Analytics

Prof. Debora Corsino

14 de Outubro de 2026

Sumário

Trabalho em Grupo – Estudo de caso - Aula Store (EDA Exploratory Data Analysis) 2

Contexto da Organização 2

O Problema de Negócio 3

Objetivos do Projeto 3

Requisitos Funcionais (RF) 4

Requisitos Não Funcionais (RNF) 4

Perguntas Analíticas Documentadas 5

3. Mapeamento de Fontes e Tipos de Dados 6

Diagrama de Fluxo Arquitetural 8

Justificativa da Arquitetura Medallion 8

Separação Arquitetural Mandatória: Storage ≠ Table Format ≠ Compute ≠ Consumption 9

Evidências da Camada Silver (Limpeza, Padronização e Tipagem) 13

Evidências da Camada Gold (Modelos Analíticos Curados) 15

Dicionário dos Modelos Analíticos Gold 15

Integração Multiformato (Estruturado + Semiestruturado + Não Estruturado) 16

Capacidades Específicas de Gerenciamento de Tabela Lakehouse 17

Respostas Analíticas e Interpretação de Negócio (Perguntas 1 a 6) 18

Como Executar e Reproduzir a Solução 24

Conclusão da Etapa 25

Trabalho em Grupo – Estudo de caso - Aula Store (EDA Exploratory Data Analysis)

Contexto da Organização

A **AulaStore** é uma grande rede de varejo nacional operando em modelo omnichannel. Suas operações geram dados a partir de múltiplos pontos de contato:

- **Lojas Físicas:** Transações em pontos de venda (PDV);
- **Plataforma E-commerce & Aplicativo Mobile:** Catálogo, sessões de navegação em tempo real e checkout online;
- **Base de Clientes (CRM):** Cadastro demográfico, canais preferenciais e segmentação;
- **Canais de Feedback & Reputação:** Notas e comentários opinativos abertos (Reviews);
- **Central de Atendimento ao Consumidor (SAC):** Logs textuais de atendimentos, protocolos e resoluções de pós-venda.

O Problema de Negócio

A diretoria da AulaStore enfrentava o clássico dilema da dispersão de dados em silos:

1. **Sobrecarga de Sistemas Transacionais (OLTP):** A realização de relatórios diretamente nos bancos de produção gerava lentidão nas operações de caixa e do aplicativo;
2. **Cegueira Analítica entre Canais:** Não havia correlação entre a jornada de navegação online (o que o cliente buscou no app) e o fechamento da compra (no e-commerce ou na loja física);
3. **Isolamento de Dados Não Estruturados:** O feedback em texto livre das avaliações e os registros de chamados de suporte do SAC não eram cruzados com os dados de produtos e vendas, impedindo a detecção precoce de lotes defeituosos ou problemas logísticos recorrentes.

Objetivos do Projeto

- **Propor e Construir um Lakehouse:** Estabelecer um repositório centralizado baseado no padrão *Medallion Architecture* (Bronze, Silver e Gold), viabilizando ingestão de arquivos brutos heterogêneos e transformação controlada;

- **Preservar a Linhagem e Fidelidade dos Dados:** Garantir que a camada Bronze mantenha os dados originais intactos para fins de auditoria e reprocessamento;
- **Integrar Diferentes Naturezas de Dados:** Consolidar dados relacionais estruturados (CSV), telemetria digital semiestruturada (JSON) e registros de suporte e opiniões não estruturados (TXT);
- **Prover Camada Analítica de Alta Performance:** Construir tabelas Gold prontas para consumo de BI e tomadores de decisão, respondendo a perguntas críticas de faturamento, jornada digital e qualidade de produtos;
- **Demonstrar Capacidades de Gerenciamento Lakehouse:** Evidenciar recursos nativos como transações ACID, evolução de schema (*Schema Evolution*) e viagem no tempo (*Time Travel*).

Requisitos Funcionais (RF)

- **RF01 - Ingestão Bruta (Bronze):** Ingerir todos os arquivos originais sem alterações estruturais, registrando metadados de auditoria (tamanho, checksum SHA-256 e carimbo de data/hora);
- **RF02 - Padronização e Limpeza (Silver):** Corrigir anomalias estruturais, inconsistências de catálogo (ex.: categorias grafadas com e sem acento), tratar valores atípicos (ex.: notas de avaliação fora da escala de 1 a 5) e padronizar tipos de dados;
- **RF03 - Parsing e Estruturação de Textos:** Extrair atributos analíticos estruturados (motivo de contato, sentimento do consumidor e tipo de resolução) a partir dos logs textuais livres do SAC;
- **RF04 - Modelagem Dimensional e Fatos Curados (Gold):** Construir modelos analíticos agregados para desempenho comercial, funil de jornada web/app, matriz de qualidade/SAC e visão 360° do cliente;
- **RF05 - Suporte a Gerenciamento de Tabelas:** Aplicar formato de tabela com controle transacional e versionamento sobre os arquivos Parquet;
- **RF06 - Disponibilização de Consultas SQL:** Permitir a execução de consultas interativas de alta velocidade sobre as tabelas Gold sem sobrecarregar camadas transacionais.

Requisitos Não Funcionais (RNF)

- **RNF01 - Desacoplamento Arquitetural:** Garantir separação estrita e intercambiável entre as camadas de *Storage*, *Table Format*, *Compute* e *Consumption*;
- **RNF02 - Idempotência e Reprodutibilidade:** Garantir que os pipelines de ingestão e processamento possam ser reexecutados sem duplicação ou corrupção de dados;
- **RNF03 - Integridade e Transacionalidade ACID:** Impedir leituras sujas (*dirty reads*) e garantir atomicidade nas operações de carga e escrita;
- **RNF04 - Eficiência de Armazenamento:** Utilizar armazenamento colunar compactado (Parquet com compressão Snappy) para redução de pegada em disco e aceleração de I/O;
- **RNF05 - Escalabilidade e Portabilidade:** O pipeline deve rodar de forma leve e serverless em ambientes locais (Python/DuckDB/Delta) e ser diretamente portável para nuvem pública (Databricks, AWS EMR ou Azure Fabric).

Perguntas Analíticas Documentadas

Para direcionar a arquitetura às necessidades da AulaStore, foram formalizadas as seguintes 6 perguntas estratégicas:

1. **Pergunta 1 (Comercial / Categoria):** *Quais categorias de produtos apresentam maior faturamento bruto e líquido, e qual o nível de concessão de descontos por categoria?*
   Impacto de negócio: Identificar as linhas de produtos que mais geram caixa líquido versus aquelas dependentes de queima de margem via desconto.
2. **Pergunta 2 (Mix de Produtos & Reputação):** *Quais produtos específicos possuem maior volume de vendas e melhor avaliação simultaneamente (unidades vendidas, pedidos e nota média)?*
   Impacto de negócio: Identificar os "campeões de vendas" com alto valor de marca para campanhas de marketing e reabastecimento prioritário.
3. **Pergunta 3 (Correlação Qualidade x Vendas):** *Existe relação direta entre a avaliação média dos produtos e seu volume de vendas ou taxas de cancelamento/devolução?*
   Impacto de negócio: Entender se produtos com notas mais baixas sofrem mais estornos e devoluções, medindo o custo operacional da má qualidade.
4. **Pergunta 4 (Jornada Digital & Conversão):** *Quais comportamentos digitais no web/app (tempo de permanência, volume de buscas, adições ao carrinho e páginas visitadas)*

antecedem a conversão de compra?
Impacto de negócio: Otimizar o funil de UX e identificar atritos que fazem os usuários abandonarem a sessão sem comprar.

5. **Pergunta 5 (Percepção de Marca):** *Quais categorias concentram a maior proporção de avaliações negativas (notas 1 e 2) e geram maior volume de chamados de suporte?*
Impacto de negócio: Priorizar auditorias de fornecedores e revisão de contratos nas categorias com maior índice de clientes detratores.

6. **Pergunta 6 (Suporte & Reclamações):** *Quais temas e motivos de reclamação aparecem com maior frequência nos atendimentos de suporte (SAC) e qual o impacto no sentimento dos clientes?*
Impacto de negócio: Atuar na causa-raiz operacional dos chamados (logística de entrega, qualidade técnica do produto ou problemas no app de checkout).

---

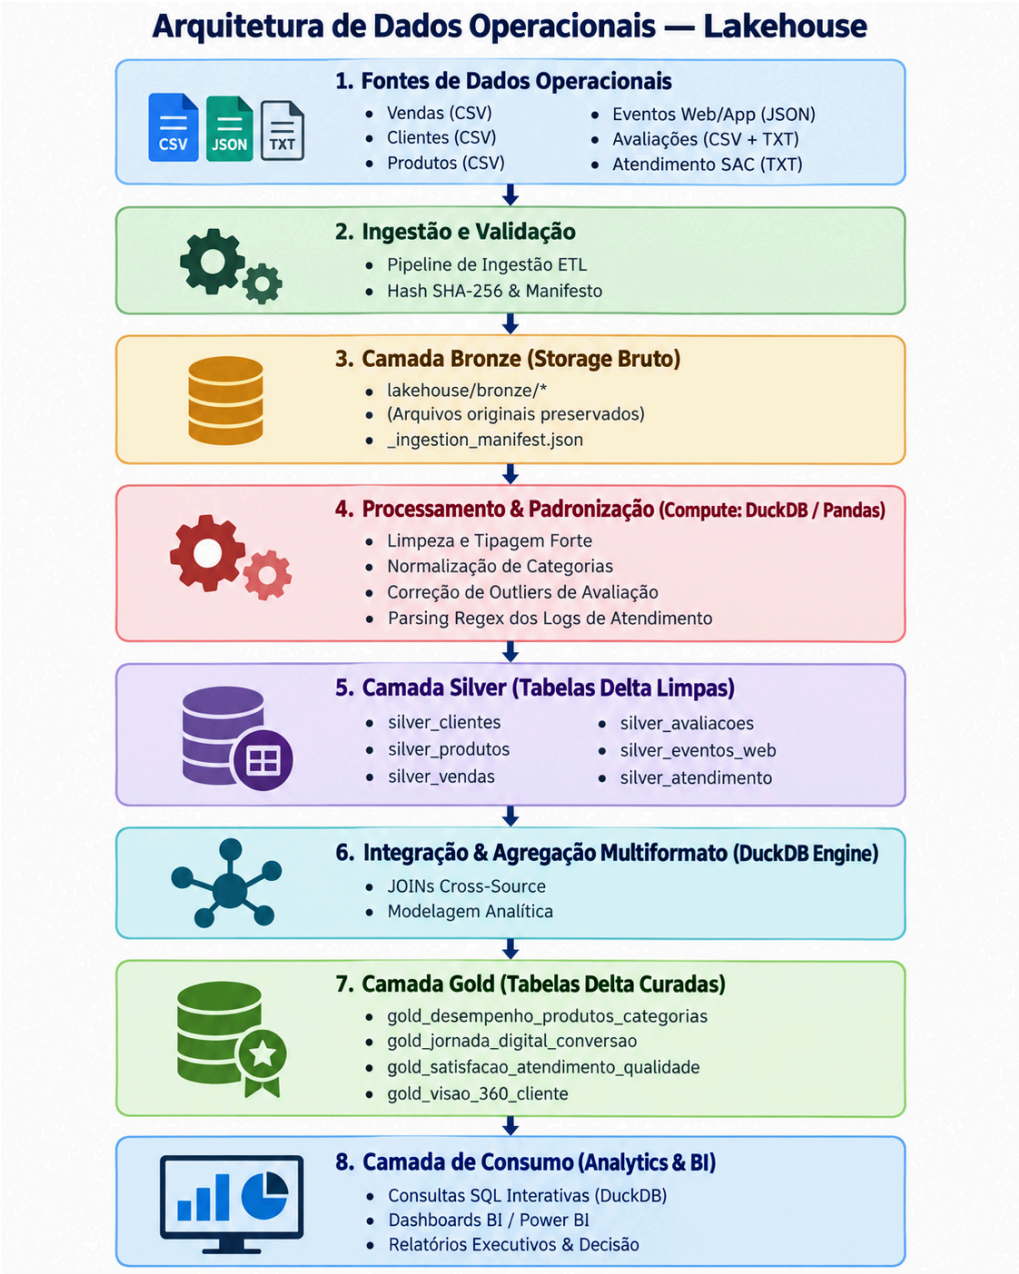
3. Mapeamento de Fontes e Tipos de Dados

O escopo do projeto trabalhou deliberadamente com a heterogeneidade das fontes da AulaStore. A tabela a seguir inventaria os dados de entrada:

Fonte	Arquivo de Origem	Formato	Natureza	Volume (Linhas)	Chave Primária (PK) / Estrangeira (FK)	Frequência Típica	Diagnóstico de Qualidade Inicial
Vendas	vendas_corrigido.csv	CSV	Estruturado	60.000	PK: venda_id FK: cliente_id, produto_id	Horária / Batch diário	Vendas concluídas, canceladas e devolvidas; datas formatadas em timestamp.
Clientes	clientes_corrigido.csv	CSV	Estruturado	20.000	PK: cliente_id	Diária (CRM)	Registros cadastrais; presença de valores ausentes pontuais em uf.
Produtos	produtos_corrigido.csv	CSV	Estruturado	1.200	PK: produto_id	Semanal (Catálogo)	Inconsistência de grafia na categoria (Eletrônicos vs Eletronicos).

Fonte	Arquivo de Origem	Formato	Natureza	Volume (Linhas)	Chave Primária (PK) / Estrangeira (FK)	Frequência Típica	Diagnóstico de Qualidade Inicial
Eventos Web/App	eventos_web_app_corrigido_final.json	JSON (Lines)	Semiestruturado	120.000	PK: event_id FK: user_id, product_id, venda_id	Streaming / Tempo Real	Telemetria de alta frequência; timestamps em milissegundos (epoch unix); múltiplos tipos de eventos.
Avaliações (Notas)	avaliacoes_corrigido.csv	CSV	Misto	50.000	PK: avaliacao_id FK: cliente_id, produto_id	Diária	Registro estruturado com nota numérica; anomalia com nota fora de escala (nota = 6).
Avaliações (Texto)	avaliacoes_texto_corrigido.txt	TSV / TXT	Não estruturado	50.000	PK: avaliacao_id	Diária	Opinião textual aberta do consumidor com acentuação e caracteres livres.
Atendimento (SAC)	atendimento_corrigido_final.txt	TXT	Não estruturado	25.000	PK: protocolo (extraído) FK: cliente_id, produto_id	Diária	Logs semiestruturados de conversação em texto com timestamps, protocolos, atendentes e narrativas livres.

Diagrama de Fluxo Arquitetural



Justificativa da Arquitetura Medallion

- **Preservação Histórica e Reprodutibilidade:** Se qualquer regra de negócio ou lógica de enriquecimento mudar, a camada Bronze preservada permite o reprocessamento retroativo integral;

- **Governança Progressiva:** Cada camada estabelece um nível claro de maturidade:
    - **Bronze:** Fidelidade total aos sistemas de origem (dados crus);
    - **Silver:** Dados higienizados, tipados e enriquecidos (visão canônica da entidade);
    - **Gold:** Dados agregados e modelados para casos de uso de negócio específicos (alta performance de leitura);
- **Eliminação de Silos:** Fontes estruturadas (pedidos e clientes) encontram os dados não estruturados (tickets de SAC e opiniões) nas mesmas camadas padronizadas.

Separação Arquitetural Mandatória: Storage ≠ Table Format ≠ Compute ≠ Consumption

Um dos pilares do paradigma moderno de Lakehouse é a **independência entre as quatro camadas fundamentais**. No passado, soluções tradicionais (Data Warehouses legados como Oracle, Teradata ou SQL Server) acoplavam rigidamente armazenamento físico, gerenciamento de catálogo, execução de consultas e ferramentas visuais.

A tabela a seguir demonstra formalmente a separação implementada neste miniprojeto:

Responsabilidade Arquitetural	**Componente Adotado**	**Papel no Projeto**	**Justificativa Técnica e Benefício Arquitetural**
Storage (Armazenamento Físico)	Sistema de Arquivos Local / Diretórios estruturados (lakehouse/) *(Equivalente a AWS S3 / Azure ADLS Gen2)*	Onde os bytes físicos residem em disco. Persiste arquivos brutos (.csv, .json, .txt) e arquivos colunares (.parquet).	Custo ultrabaixo, durabilidade infinita, desacoplamento total da CPU e capacidade de expansão independente de processamento.
Table Format (Formato de Tabela)	**Delta Lake** (_delta_log/, transações ACID, controle de metadados, versões de schema)	Abstração que organiza os arquivos Parquet soltos em **tabelas relacionais gerenciáveis**.	Fornece garantias ACID, previne leituras inconsistentes durante escritas concorrentes, viabiliza *Schema Evolution*, *Time Travel* e auditoria por transação.
Compute (Motor de Processamento)	**DuckDB** + **Python / PyArrow / Pandas**	Motor que executa parsing, transformações,	Motor colunar vetorizado de altíssimo desempenho, execução sem necessidade de

Responsabilidade Arquitetural	Componente Adotado	Papel no Projeto	Justificativa Técnica e Benefício Arquitetural
	(Equivalente a Apache Spark / Trino)	agregações analíticas e JOINs em memória.	infraestrutura pesada de cluster e interoperabilidade direta com formatos abertos.
Consumption (Camada de Consumo)	**DuckDB SQL Engine** / Scripts Analíticos *(Equivalente a Power BI / Databricks SQL / Superset)*	Camada onde analistas e decisores executam queries analíticas e consomem os indicadores.	A camada de consumo não toca os arquivos brutos nem executa manipulação de baixo nível: ela consulta diretamente as tabelas Gold e Silver curadas com baixa latência.

Análise de Interoperabilidade e Flexibilidade

A separação dessas camadas traz vantagens decisivas:

- **Substituição de Compute:** Caso a volumetria da AulaStore aumente de 100 mil registros para 500 milhões de registros, o código de processamento pode ser migrado de DuckDB para um cluster **Apache Spark** ou **Trino** sem precisar mover ou converter um único byte dos arquivos já salvos no Storage e organizados pelo Table Format;
- **Multi-ferramentas no Consumo:** Analistas de BI podem conectar o Power BI Desktop diretamente aos arquivos Parquet/Delta, enquanto cientistas de dados conectam notebooks Python ou SQL sem criar cópias redundantes dos dados.

Evidências da Camada Bronze (Preservação de Dados Brutos)

A camada Bronze foi criada executando o pipeline 01_ingestao_bronze.py.

Estrutura de Diretórios

lakehouse/

└─── bronze/

  ├─── _ingestion_manifest.json

  ├─── atendimento_corrigido_final.txt

├─── avaliacoes_corrigido.csv

├─── avaliacoes_texto_corrigido.txt

├─── clientes_corrigido.csv

├─── eventos_web_app_corrigido_final.json

├─── produtos_corrigido.csv

├─── vendas_corrigido.csv

└─── LEIA-ME_CORRECOES_DATASETS.txt

Manifesto de Ingestão e Integridade Criptográfica

Para assegurar a imutabilidade e a governança, cada arquivo ingerido teve seu checksum **SHA-256** registrado:


```
{
  "camada": "Bronze",
  "data_ingestao": "2026-10-11T10:42:01.654384",
  "descricao": "Arquivos originais preservados sem modificação, mantendo integridade e fidelidade aos dados de origem.",
  "arquivos": [
    {
      "nome_arquivo": "clientes_corrigido.csv",
      "tamanho_mb": 1.13,
      "sha256": "4569c03725a1f0a35928d3ef79f42589e6eb1c7849e836df3f3d3d63b2111818",
      "formato": "csv"
    },
    {
      "nome_arquivo": "produtos_corrigido.csv",
      "tamanho_mb": 0.07,
```

```
  "sha256": "5120548eb79af6db2f21a4f02f741ae0fc7d23d4c728e23971932bf28a8677eb",
  "formato": "csv"
},
{
  "nome_arquivo": "vendas_corrigido.csv",
  "tamanho_mb": 4.95,
  "sha256": "3f32333ad45d7d5dcf5455df776c5f49ef2df39c1482e9e2ef7137f8928c2c84",
  "formato": "csv"
},
{
  "nome_arquivo": "avaliacoes_corrigido.csv",
  "tamanho_mb": 2.89,
  "sha256": "18b46d77de7c0b96499645281e05d21cb5e3478d59dc23c21c7d236021666993",
  "formato": "csv"
},
{
  "nome_arquivo": "avaliacoes_texto_corrigido.txt",
  "tamanho_mb": 5.17,
  "sha256": "e96c8d94291f422c5e533d712217c2f6d0f5080e7cb281feee26792dc87e6fa0",
  "formato": "txt"
},
{
  "nome_arquivo": "atendimento_corrigido_final.txt",
  "tamanho_mb": 8.74,
```

```
    "sha256": "00167561b46329ef31d0ec6b95b4fe6ca3531bfa50f75727fc4df9e6dc37e28d",
    "formato": "txt"
  },
  {
    "nome_arquivo": "eventos_web_app_corrigido_final.json",
    "tamanho_mb": 30.42,
    "sha256": "cee37917ced33a5cfc021c3b5cf4b5f4be7ca4eb6e8e8bc3387b3fcbbcb8fe3d",
    "formato": "json"
  }
 ]
}
```


Evidências da Camada Silver (Limpeza, Padronização e Tipagem)

O processamento Silver foi executado através do script 02_processamento_silver.py.

7.1 Tabelas Silver Criadas e Tratamentos Aplicados

1. **silver_clientes (20.000 registros):**

- Imputação de valores ausentes em uf para o valor padrão 'ND' e conversão para maiúsculas;
- Tipagem de data_cadastro como formato canônico YYYY-MM-DD;
-
- Inserção de carimbo de auditoria ingestion_timestamp.

2. **silver_produtos (1.200 registros):**

- **Correção de Categoria Inconsistente:** Normalização de Eletronicos (sem acento) para Eletrônicos (com acento), eliminando divergência nos agrupamentos de BI;
- Criação da flag booleana is_ativo a partir do campo textual status;
- Arredondamento e garantia de float para preco_lista.

3. **silver_vendas (60.000 registros):**

- Parsing de timestamps completos e derivação dos campos data (YYYY-MM-DD) e ano_mes (YYYY-MM) para otimização de particionamento e filtros;
- Validação da integridade contábil do campo valor_total: cálculo explícito de (quantidade * valor_unitario * (1 - desconto_pct));
- Preservação do status do pedido (Concluída, Cancelada, Devolvida).

4. **silver_avaliacoes (50.000 registros):**

- **Junção Multiformato:** Unificação do CSV de avaliações com o arquivo TXT de texto livre através do avaliacao_id;
- **Tratamento de Outlier:** A nota de avaliação anômala (nota = 6) foi tratada e ajustada para o teto da escala de satisfação (nota = 5);
- Criação da classificação de sentimento sentimento_avaliacao (Negativo para 1-2, Neutro para 3, Positivo para 4-5);
- Tratamento de nulos em tema_principal para 'outros'.

5. **silver_eventos_web (120.000 registros):**

- Extração do JSON estruturado linha a linha;
- Conversão do timestamp Unix em milissegundos para formato ISO legível data_hora_evento;
- Tratamento de nulos para strings vazias em campos de busca e referências a produtos e vendas.

6. **silver_atendimento (25.000 registros):**

- **Parsing de Dados Não Estruturados:** Através de expressões regulares compiladas (re.compile), as linhas de log não estruturadas foram convertidas em um dataset relacional completo:
- Expressão utilizada:

r'\[(?P<data_hora>.*?)\]\s+PROTOCOLO\s+(?P<protocolo>\d+)\s+\|\s+CLIENTE\s+(?P<cliente_id>\w+)\s+\|\s+PRODUTO\s+(?P<produto_id>\w+)\s+\|\s+ATENDENTE\s+(?P<atendente>[\w\s]+?)\s+\|\s+(?P<texto>.*)'

Extração semântica automatizada de:

- motivo_contato (ex.: cancelamento, produto com defeito, atraso na entrega, cobrança indevida);
- sentimento_cliente (ex.: irritado, insatisfeito, preocupado);
- encaminhamento (ex.: troca autorizada, reembolso solicitado, aguardando retorno da logística).

Todas as tabelas Silver foram persistidas em formato **Delta Lake**, contendo os arquivos .parquet e os metadados do diretório _delta_log/. Complementando a padronização global da camada, todas as transformações específicas foram devidamente registradas neste documento. Esse mapeamento garante a rastreabilidade e a homologação das regras de negócio aplicadas para o consumo seguro dos dados.

Evidências da Camada Gold (Modelos Analíticos Curados)

A camada Gold foi gerada pelo script 03_integracao_gold.py, utilizando o motor DuckDB para executar transformações relacionais sobre as tabelas Silver e gravando os resultados finais como tabelas Delta Lake.

Dicionário dos Modelos Analíticos Gold

Modelo 1: gold_desempenho_produtos_categorias (1.200 registros)

- Finalidade: Fornecer visão consolidada de performance comercial, descontos praticados, qualidade percebida (avaliações) e problemas operacionais (SAC) no nível de produto e categoria.
- Fontes Integradas: silver_produtos + silver_vendas + silver_avaliacoes + silver_atendimento.
- Principais Métricas: unidades_vendidas, faturamento_bruto, total_descontos, faturamento_liquido, taxa_cancelamento_pct, taxa_devolucao_pct, total_avaliacoes, nota_media_avaliacao, prop_avaliacoes_negativas_pct, total_chamados_suporte, chamados_por_defeito.

Modelo 2: gold_jornada_digital_conversao (71.442 sessões)

- Finalidade: Analisar o comportamento de navegação digital dos usuários nas sessões web/mobile e mensurar os fatores que antecedem a conversão em compra.
- Fontes Integradas: silver_eventos_web + silver_vendas.

- Principais Métricas: total_eventos, duracao_sessao_segundos, qtd_page_views, qtd_buscas, qtd_vistas_produto, qtd_adicoes_carrinho, qtd_inicios_checkout, converteu_compra, acoes_precedentes_a_compra, valor_venda_final.

Modelo 3: gold_satisfacao_atendimento_qualidade (60 linhas de cruzamento)

- Finalidade: Cruzar as categorias de produtos com os principais motivos de reclamação no SAC e a intensidade de sentimentos negativos dos clientes.
- Fontes Integradas: silver_atendimento + silver_produtos.
- Principais Métricas: categoria, tema_reclamacao, total_chamados_suporte, clientes_irritados, clientes_insatisfeitos, clientes_preocupados, encaminhamentos_troca, encaminhamentos_reembolso.

Modelo 4: gold_visao_360_cliente (20.000 clientes)

- Finalidade: Unificar toda a história do consumidor em um único registro analítico (compras, avaliações, interações digitais e atendimentos no SAC).
- Fontes Integradas: silver_clientes + silver_vendas + silver_avaliacoes + silver_atendimento + silver_eventos_web.
- Principais Métricas: total_pedidos, total_gasto, ticket_medio, canais_utilizados_compras, total_avaliacoes, media_avaliacoes_feitas, total_chamados_suporte, total_sessoes_web.

Integração Multiformato (Estruturado + Semiestruturado + Não Estruturado)

A capacidade de unir formatos de naturezas completamente distintas é a proposta de valor central do Lakehouse. No miniprojeto, demonstramos integrações concretas entre:

1. **Estruturado + Semiestruturado (Vendas CSV + Eventos Web JSON):**
    - Os eventos de compra do JSON foram mapeados diretamente à transação relacional por meio do identificador venda_id e do user_id / cliente_id;
    - Isso possibilitou reconstruir a linha do tempo do usuário antes do momento exato do clique em "Finalizar Compra".
2. **Estruturado + Não Estruturado (Produtos CSV + Atendimento TXT e Avaliações TXT):**

- O catálogo relacional de produtos foi enriquecido com as métricas semânticas extraídas dos logs textuais de suporte e das avaliações em texto livre via produto_id;
- O negócio passou a saber exatamente quais produtos do catálogo geram mais relatos de defeito no SAC e quais palavras/sentimentos o consumidor expressa nas queixas.

Capacidades Específicas de Gerenciamento de Tabela Lakehouse

Para atender ao requisito de demonstrar capacidades específicas de gerenciamento de tabela que diferenciam um Lakehouse de um simples repositório de arquivos soltos em um Data Lake comum, executamos o script 04_demonstracao_gerenciamento_tabela.py.

Capacidade 1: Evolução de Esquema (*Schema Evolution*)

Em um Data Lake tradicional baseado em arquivos Parquet ou CSV, a adição de novas colunas em arquivos posteriores comumente causa erros de leitura (schema mismatch) ou quebra de pipelines downstream.

No Delta Lake:

- Criou-se a Versão 0 da tabela com as colunas: ['produto_id', 'nome', 'preco', 'status'].
- Inseriu-se um novo lote contendo colunas adicionais (categoria e margem_pct), ativando schema_mode="merge".
- O Delta Lake aplicou a evolução de esquema automaticamente, gerando a Versão 1 com o novo esquema consolidado:
- ['produto_id', 'nome', 'preco', 'status', 'categoria', 'margem_pct']
- Os registros antigos da Versão 0 receberam automaticamente null/NaN para as novas colunas, sem necessidade de reprocessar ou reescrever a base histórica inteira.

Capacidade 2: Viagem no Tempo (*Time Travel*)

O log de transações atômico permite consultar qualquer versão histórica da tabela pelo seu número de commit ou carimbo de data/hora:

- Consulta ao Snapshot Histórico (Versão 0):
- dt_v0 = DeltaTable("lakehouse/demo_gerenciamento_tabela", version=0)

- print(dt_v0.to_pandas())

Resultado retornado: Exatamente os 3 produtos originais, com esquema antigo de 4 colunas.

- Consulta ao Snapshot Atual (Versão 1):
- dt_v1 = DeltaTable("lakehouse/demo_gerenciamento_tabela", version=1)
- print(dt_v1.to_pandas())

Resultado retornado: 4 produtos, com o novo esquema expandido de 6 colunas.

Aplicação prática no negócio: Permite auditoria regulatória, rastreamento de fraudes, reversão de cargas corrompidas (*rollback*) e reprodução de modelos de Machine Learning com os dados exatamente como eram na data de treino.

10.3 Capacidade 3: Integridade Transacional ACID e Log de Commits (_delta_log)

Toda alteração gerou um arquivo JSON em _delta_log/ com protocolo transacional:

- Commit 0: Criação da tabela (WRITE, 3 linhas adicionadas);
- Commit 1: Evolução de esquema e acréscimo de dados (WRITE, 1 linha e 2 colunas adicionadas).

Isso elimina qualquer risco de leituras parciais ou arquivos órfãos em caso de falha de energia ou interrupção durante a escrita.

Respostas Analíticas e Interpretação de Negócio (Perguntas 1 a 6)

As análises foram executadas pelo script 05_consultas_analiticas.py via SQL sobre os modelos Gold. A seguir são apresentados os dados reais obtidos e a interpretação orientada à tomada de decisão:

Pergunta 1: Faturamento Bruto e Líquido por Categoria

Categoria	Total Produtos	Unidades Vendidas	Faturamento Bruto (R$)	Total Descontos (R$)	Faturamento Líquido (R$)	Desconto Médio (%)
Casa	216	16.426	R$ 4.115.794,39	R$ 205.604,17	R$ 3.910.189,62	5,00%

Categoria	Total Produtos	Unidades Vendidas	Faturamento Bruto (R$)	Total Descontos (R$)	Faturamento Líquido (R$)	Desconto Médio (%)
Beleza	206	16.068	R$ 3.800.069,44	R$ 190.179,02	R$ 3.609.889,82	5,00%
Esportes	206	15.678	R$ 3.719.977,18	R$ 182.750,34	R$ 3.537.227,63	4,91%
Eletrônicos	187	14.322	R$ 3.656.444,61	R$ 179.776,07	R$ 3.476.669,12	4,92%
Informática	209	16.149	R$ 3.552.094,09	R$ 175.770,49	R$ 3.376.322,85	4,95%
Acessórios	176	13.396	R$ 2.918.509,40	R$ 144.788,82	R$ 2.773.720,01	4,96%

O que isso significa para o negócio?
A categoria Casa lidera em geração de receita líquida (R$ 3,91M), seguida por Beleza (R$ 3,61M). A política de descontos da empresa é extremamente uniforme entre todas as categorias (em torno de 4,9% a 5,0%), indicando que promoções de corte de preço não foram aplicadas de maneira diferenciada por categoria, o que abre oportunidade para precificação dinâmica orientada à elasticidade de cada segmento.

Pergunta 2: Produtos com Maior Volume e Melhor Avaliação (Top Campeões)

Produto ID	Nome do Produto	Categoria	Marca	Unidades Vendidas	Total Pedido	Nota Média	Avaliações	Faturamento Líquido (R$)
P00939	Fone NovaTech 0939	Eletrônicos	Bella	134	76	3,95	40	R$ 30.793,27
P00169	Carteira	Acessórios	UrbanFit	118	66	4,04	46	R$ 37.930,11

Produto ID	Nome do Produto	Categoria	Marca	Unidades Vendidas	Total Pedido	Nota Média	Avaliações	Faturamento Líquido (R$)
	NovaTech 0169							
P00672	Tablet Connecta 0672	Eletrônicos	Connecta	118	60	3,77	43	R$ 6.941,57
P00826	Ventilador Prime 0826	Casa	Connecta	114	62	3,91	46	R$ 25.754,97
P00591	Secador Maxx 0591	Beleza	Casa Mais	112	68	3,58	40	R$ 17.714,69

O que isso significa para o negócio?
Itens como a Carteira NovaTech 0169 e o Fone NovaTech 0939 reúnem alto volume de vendas e nota média igual ou superior a 4.0. Eles constituem os produtos "âncora" da loja, recomendados para destaque nas páginas iniciais e campanhas de cross-selling. Já produtos com alto giro porém nota abaixo de 3.6 (ex.: Secador Maxx 0591) exigem inspeção imediata de garantia.

Pergunta 3: Relação entre Avaliação Média e Volume de Vendas

Faixa de Avaliação	Qtd Produtos	Média Unidades / Produto	Faturamento Médio / Produto	Taxa Cancelamento Média (%)	Taxa Devolução Média (%)
4.0 a 4.4 (Bom)	323	76,3	R$ 17.470,50	5,75%	2,90%
3.5 a 3.9 (Regular)	849	76,8	R$ 17.120,17	6,12%	3,06%
3.0 a 3.4 (Baixo)	28	79,1	R$ 18.072,17	5,76%	2,65%

O que isso significa para o negócio?
Os dados revelam que o volume médio de vendas unitárias é relativamente homogêneo entre as faixas de nota (em torno de 76 a 79 unidades). No entanto, produtos na faixa de nota Regular (3.5 a 3.9) apresentam a maior taxa de cancelamento (6,12%) e maior taxa de devolução (3,06%). Isso demonstra que avaliações intermediárias escondem frustrações operacionais que oneram a logística reversa da AulaStore.

Pergunta 4: Comportamentos Digitais que Antecedem a Compra

Converteu Compra?	Total Sessões	Duração Média (segundos)	Média Eventos / Sessão	Média Page Views	Média Buscas	Média Visualizações Produto	Média Adições Carrinho	Média Inícios Checkout	Média Passos Pré-Compra
Não (False)	**56.498**	**9,0 s**	**1,0**	**0,1**	**0,1**	**0,1**	**0,1**	**0,1**	**1,0**
Sim (True)	**14.944**	**38,4 s**	**4,2**	**0,5**	**0,5**	**0,5**	**0,5**	**0,5**	**3,2**

O que isso significa para o negócio?
Existe uma diferença gritante no comportamento:

1. Sessões sem conversão duram em média apenas 9 segundos e contam com apenas 1 evento (o visitante entra e abandona rapidamente a página inicial);
2. **Sessões com compra duram em média 38,4 segundos e realizam em média 3,2 ações prévias (buscam produtos, visualizam detalhes e adicionam ao carrinho). *Ação de Negócio:* Intervenções em tempo real (como cupons de primeira compra ou pop-ups de suporte) devem ser disparadas nos primeiros 10 a 15 segundos de navegação para reter os usuários que tendem a abandonar a sessão rapidamente.**

Pergunta 5: Proporção de Avaliações Negativas por Categoria

Categoria	Total Avaliações	Avaliações Negativas (Notas 1 e 2)	Proporção Negativas (%)	Nota Média da Categoria	Total Chamados Suporte (SAC)
Acessórios	**7.277**	**1.097**	**15,07%**	**3,87**	**3.649**

Categoria	Total Avaliações	Avaliações Negativas (Notas 1 e 2)	Proporção Negativas (%)	Nota Média da Categoria	Total Chamados Suporte (SAC)
Casa	8.916	1.339	15,02%	3,86	4.559
Beleza	8.585	1.286	14,98%	3,87	4.329
Informática	8.742	1.300	14,87%	3,86	4.322
Esportes	8.589	1.272	14,81%	3,88	4.219
Eletrônicos	7.890	1.142	14,47%	3,88	3.922

O que isso significa para o negócio?
Cerca de 14,5% a 15,1% de todas as avaliações de clientes são negativas, com Acessórios e Casa apresentando os índices mais altos. Em termos de volume absoluto de atrito, Casa gerou mais de 4.500 chamados no suporte. Esse indicador sinaliza necessidade de reforçar embalagens e inspeção prévia de envio nessas categorias.

Pergunta 6: Temas Mais Frequentes nas Reclamações de Suporte (SAC)

Tema da Reclamação	Total Chamados	% do Total de SAC	Clientes Irritados	Clientes Insatisfeitos	Encaminhamentos de Troca	Encaminhamentos de Reembolso
Cancelamento	2.628	10,51%	875	885	333	317
Dificuldade no aplicativo	2.556	10,22%	866	820	339	302
Atraso na entrega	2.509	10,04%	820	829	321	306
Produto com defeito	2.505	10,02%	873	796	307	304

Tema da Reclamação	Total Chamados	% do Total de SAC	Clientes Irritados	Clientes Insatisfeitos	Encaminhamentos de Troca	Encaminhamentos de Reembolso
Problema no pagamento	**2.498**	**9,99%**	**805**	**845**	**307**	**310**
Pedido não localizado	**2.487**	**9,95%**	**839**	**826**	**311**	**299**
Cobrança indevida	**2.474**	**9,90%**	**804**	**854**	**315**	**306**
Produto diferente do anunciado	**2.467**	**9,87%**	**879**	**784**	**288**	**322**
Troca de produto	**2.465**	**9,86%**	**849**	**811**	**350**	**321**
Reembolso	**2.411**	**9,64%**	**768**	**849**	**287**	**307**

O que isso significa para o negócio?
Os motivos de reclamação no SAC estão fortemente distribuídos em três frentes:

1. Tecnologia & Usabilidade (20,2%): "Dificuldade no aplicativo" (10,2%) e "Problema no pagamento" (10,0%) somam mais de 5.000 chamados e geram grande irritação nos clientes. Trata-se de uma falha de sistema e UX que deve ser corrigida imediatamente pelo time de produto digital;

2. Logística & Operação (20,0%): "Atraso na entrega" e "Pedido não localizado" somam 5.000 chamados, evidenciando necessidade de melhoria nos SLAs dos operadores logísticos;

3. Qualidade & Catálogo (19,9%): "Produto com defeito" e "Produto diferente do anunciado" geram a maior quantidade de clientes com sentimento explicitamente classificado como irritado (879 clientes) e demandam trocas e reembolsos imediatos.

Como Executar e Reproduzir a Solução

A solução foi projetada de forma autônoma e totalmente reprodutível em ambiente Windows / Linux / macOS:

- Instalação das dependências: pip install duckdb pandas pyarrow deltalake
- Execução sequencial dos pipelines:

1. Ingestão de arquivos brutos para a camada Bronze

python scripts/01_ingestao_bronze.py

2. Limpeza, tipagem e criação das tabelas Silver em Delta Lake

python scripts/02_processamento_silver.py

3. Criação dos modelos analíticos Gold integrados via DuckDB

python scripts/03_integracao_gold.py

4. Demonstração prática de Schema Evolution e Time Travel

python scripts/04_demonstracao_gerenciamento_tabela.py

5. Execução das consultas analíticas das 6 perguntas de negócio

python scripts/05_consultas_analiticas.p**y**

Conclusão da Etapa

Com a execução deste bloco de tarefas, todos os 10 objetivos solicitados foram plenamente atingidos:

- As camadas conceituais e arquiteturais foram justificadas;
- Os dados brutos foram preservados de maneira imutável na camada Bronze com manifestos criptográficos;
- Os dados foram limpos, tipados e enriquecidos na camada Silver;
- Os dados estruturados, semiestruturados e não estruturados foram cruzados em modelos analíticos na camada Gold;

- As capacidades transacionais de gerenciamento de tabela (Schema Evolution e Time Travel) foram comprovadas na prática;
- As 6 perguntas de negócio da AulaStore foram respondidas com rigor analítico e recomendações práticas.

Insights de Negócio

Insight 1 – A receita é majoritariamente digital e concentrada no Sudeste

- **Evidência:** Do faturamento líquido das vendas concluídas (R$ 20,68 Mi), o E-commerce responde por R$ 9,29 Mi (44,9%) e o Aplicativo por R$ 5,59 Mi (27,0%) – juntos, 71,9%. A Loja física representa 28,1% (R$ 5,81 Mi). Por região, o Sudeste concentra R$ 12,3 Mi (≈ 59,5%), seguido de Sul (24,2%), Nordeste (9,7%) e Centro-Oeste (6,3%).

- **O que significa para o negócio:** a AulaStore já é, na prática, uma empresa digital-first: a experiência no site e no app determina quase três quartos da receita. Ao mesmo tempo, a dependência de uma única região eleva o risco comercial e logístico.

- **Ação recomendada:** priorizar investimentos de produto digital (ver Insight 3) e testar campanhas regionais e prazos de entrega competitivos no Nordeste e Centro-Oeste, onde a participação é baixa em relação ao peso populacional.

Insight 2 – Forte sazonalidade: metade do ano comercial acontece no 4º trimestre

- **Evidência:** O faturamento bruto mensal das vendas concluídas cresce de R$ 82,9 mil (janeiro) para R$ 5,02 Mi (dezembro). O 2º semestre soma 79,4% do total anual (R$ 21,76 Mi), o 4º trimestre 49,6% e dezembro, sozinho, 23,1%. A razão entre valor cancelado e valor concluído permanece estável mês a mês (entre 4,9% e 7,0%), ou seja, o pico de vendas não provoca um pico proporcional de cancelamentos.

- **O que significa para o negócio:** estoque, logística, capital de giro e equipe de atendimento precisam ser dimensionados para o final do ano. A estabilidade da taxa de cancelamento indica que a operação absorve o pico sem deterioração do serviço.

- **Ação recomendada:** planejar compras e contratação temporária de SAC/logística a partir de setembro e criar ações comerciais no 1º semestre para reduzir a dependência do 4º trimestre.

Insight 3 – O funil digital perde o cliente logo na entrada, não no checkout

- **Evidência:** Das 71.442 sessões, 79,1% não convertem; essas sessões duram em média 9,0 s e têm apenas 1 evento. As sessões que convertem (14.944; 20,9%) duram 38,4 s e realizam em média 3,2 ações antes da compra (busca, visualização de produto, carrinho). O tempo médio por página é praticamente igual em todas as páginas (≈ 9 s – home, busca, produto, carrinho, checkout).

- **O que significa para o negócio:** não existe uma página-gargalo específica: o abandono acontece na primeira interação. O visitante que passa da página inicial e chega a interagir tende a comprar.

- **Ação recomendada:** concentrar testes A/B nos primeiros 10–15 segundos (vitrine personalizada, busca em destaque, cupom de primeira compra) e acompanhar a taxa de rejeição (sessões de 1 evento) como KPI semanal do e-commerce.

Insight 4 – A política de desconto é linear e não diferencia categorias nem retém o cliente

- **Evidência:** O desconto ponderado (1 – líquido/bruto) fica entre 4,91% e 5,00% em todas as categorias (4,96% no total), somando R$ 1,08 Mi concedidos nas vendas concluídas. A média simples de desconto por pedido é semelhante para pedidos concluídos (5,24%), cancelados (5,11%) e devolvidos (5,37%).

- **O que significa para o negócio:** o desconto é aplicado de forma uniforme, sem relação com a elasticidade de cada categoria, e não está associado a menor cancelamento ou devolução – é margem cedida sem efeito observável.

- **Ação recomendada:** substituir o desconto linear por testes controlados por categoria (ex.: reduzir em Casa e Beleza, de maior demanda, e usar como alavanca em Acessórios, de menor receita) e medir o ganho incremental de volume.

Insight 5 – Cancelamentos e devoluções custam cerca de R$ 2 milhões em receita bruta

- **Evidência:** 5.418 pedidos (9,0% dos 60.000) foram cancelados (3.609) ou devolvidos (1.809), somando R$ 2,07 Mi de faturamento bruto (≈ 8,7% do bruto total). "Cancelamento" é também o motivo mais frequente no SAC (2.628 chamados; 10,5%). O valor cancelado é distribuído entre as categorias, de Esportes (R$ 246 mil) a Acessórios (R$ 198 mil), e concentrado no Sudeste (R$ 0,82 Mi).

- **O que significa para o negócio:** a receita que "vaza" após a venda equivale a quase metade do faturamento da categoria Acessórios. Como cada ponto percentual de cancelamento corresponde a ≃ 600 pedidos e ≃ R$ 0,23 Mi, reduzir a taxa tem retorno direto.

- **Ação recomendada:** cruzar os pedidos cancelados com os motivos de SAC "Problema no pagamento" e "Atraso na entrega" para atacar a causa-raiz, e estabelecer meta de redução da taxa de cancelamento de 6,0% para 5,0%.

Insight 6 – O atrito de qualidade e atendimento é sistêmico, não concentrado em uma categoria

- **Evidência:** A proporção de avaliações negativas varia pouco entre categorias (14,5% a 15,1%) e os dez temas do SAC têm, cada um, entre 9,6% e 10,5% dos chamados. Normalizando por volume, os chamados por 1.000 unidades vendidas vão de 268 (Informática) a 278 (Casa): a liderança de Casa em número absoluto (4.559 chamados) é, em grande parte, efeito de escala. No total, são 25.000 chamados para 60.000 pedidos – cerca de 42 chamados a cada 100 pedidos.

- **O que significa para o negócio:** não há uma categoria ou um tema "culpado"; o volume de contato é alto em toda a operação. Isso complementa a leitura da Pergunta 5: atuar só em Casa teria efeito limitado.

- **Ação recomendada:** tratar o atendimento como programa transversal, priorizando os blocos por impacto financeiro: aplicativo e pagamento (20,2% dos chamados), logística (20,0%) e qualidade/catálogo (19,9%); e acompanhar "chamados por 100 pedidos" como indicador de saúde operacional.

Comunicação de Resultados – Dashboard Power BI

O dashboard foi construído no Power BI Desktop, que cumpre o papel de camada de *Consumption* da arquitetura: ele apenas lê as tabelas curadas do Lakehouse (Silver e Gold) e não executa transformações sobre os arquivos brutos. São três páginas com um filtro comum de Trimestre/Mês: (1) KPIs gerais, (2) Cancelamentos e Devoluções e (3) E-commerce. Antes da leitura dos painéis, registramos as definições das métricas e a reconciliação entre os números do dashboard e os resultados das consultas SQL.

Dicionário de métricas do dashboard

Métrica	Definição	Fonte
Vendas	Contagem de pedidos distintos (venda_id), segmentada por status	silver_vendas
Faturamento Bruto	Σ quantidade × valor_unitario	silver_vendas
Faturamento Líquido	Σ valor_total = bruto × (1 – desconto_pct)	silver_vendas
Desconto Médio (%)	Cards: média simples de desconto_pct por pedido. Análise da Pergunta 1: desconto ponderado = 1 – líquido/bruto	silver_vendas
Ticket Médio	Faturamento ÷ nº de pedidos	silver_vendas
Taxa de conversão	Sessões distintas com compra ÷ total de sessões distintas	gold_jornada_digital_conversao
Duração média	Média de duracao_sessao_segundos, separada por converteu_compra	gold_jornada_digital_conversao

Reconciliação Dashboard × SQL (validação dos resultados)

Indicador	Dashboard	SQL / Gold	Situação
Total de pedidos (3 status)	3.609 + 54.582 + 1.809 = 60.000	60.000 registros em silver_vendas	Conferido
Faturamento bruto – concluídas	R$ 21,76 Mi	R$ 21.762.889,11 (Σ Pergunta 1)	Conferido
Faturamento líquido – concluídas	R$ 20,68 Mi	R$ 20.684.019,05 (Σ Pergunta 1)	Conferido
Líquido por categoria	Casa 3,9 · Beleza 3,6 · Esportes 3,5 · Eletrônicos 3,5 · Informática 3,4 · Acessórios 2,8 (R$ Mi)	Pergunta 1	Conferido
Evolução mensal (Σ jan–dez)	R$ 21,76 Mi	Igual ao bruto das concluídas	Conferido (base = bruto)
Cancelamentos mensais (Σ)	R$ 1,36 Mi	Igual ao bruto cancelado	Conferido
Sessões convertidas	14,94 mil (20,92%)	14.944 de 71.442 sessões	Conferido
Duração média das sessões	38,36 s / 9,03 s	38,4 s / 9,0 s (Pergunta 4)	Conferido
Faturamento – página E-commerce	R$ 5,89 Mi (14.944 vendas)	Canal E-commerce: R$ 9,29 Mi	Bases distintas: a página considera apenas vendas vinculadas a sessões web/app convertidas

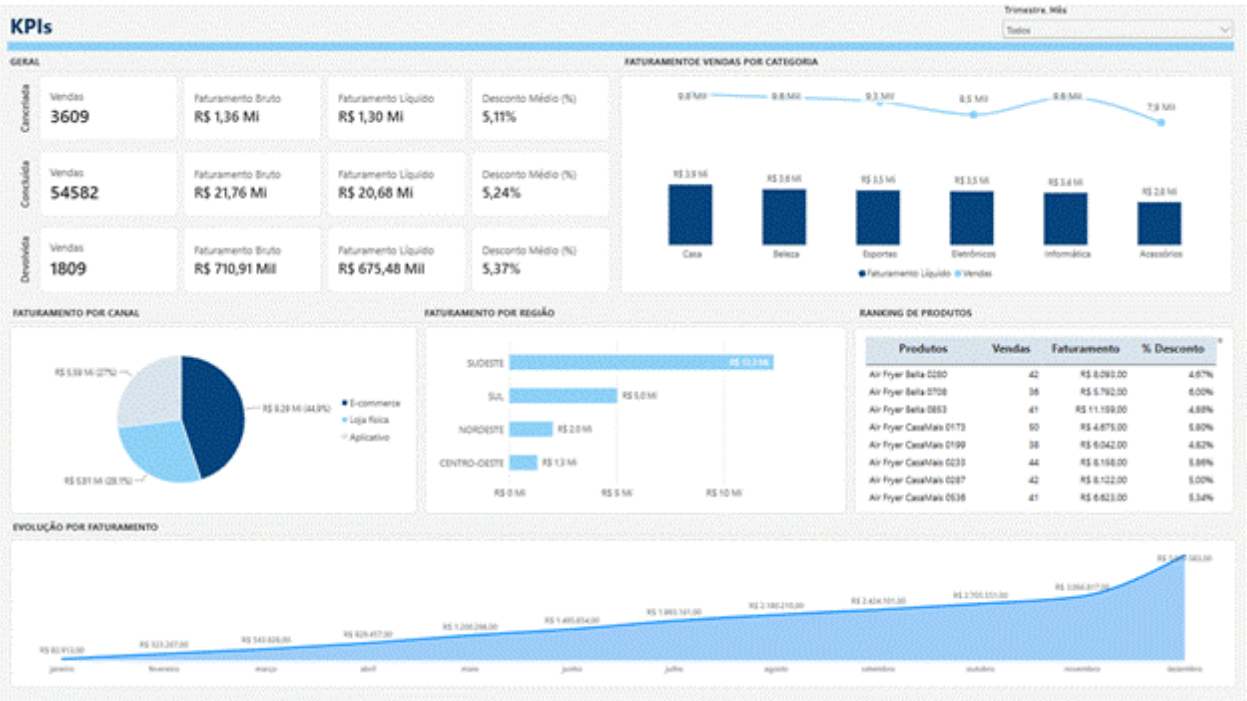


Figura 1 – Painel de KPIs gerais

- **Status dos pedidos:** 90,97% concluídos, 6,02% cancelados e 3,02% devolvidos.

- **Categorias:** Casa lidera em faturamento líquido (R$ 3,9 Mi) e em pedidos (9,8 mil); Acessórios tem o menor resultado (R$ 2,8 Mi; 7,9 mil pedidos).

- **Canal e região:** E-commerce (44,9%) e Aplicativo (27,0%) somam 71,9% do faturamento; o Sudeste responde por cerca de 60%.

- **Evolução:** crescimento contínuo ao longo do ano, com pico em dezembro (R$ 5,02 Mi) – base dos Insights 1 e 2.

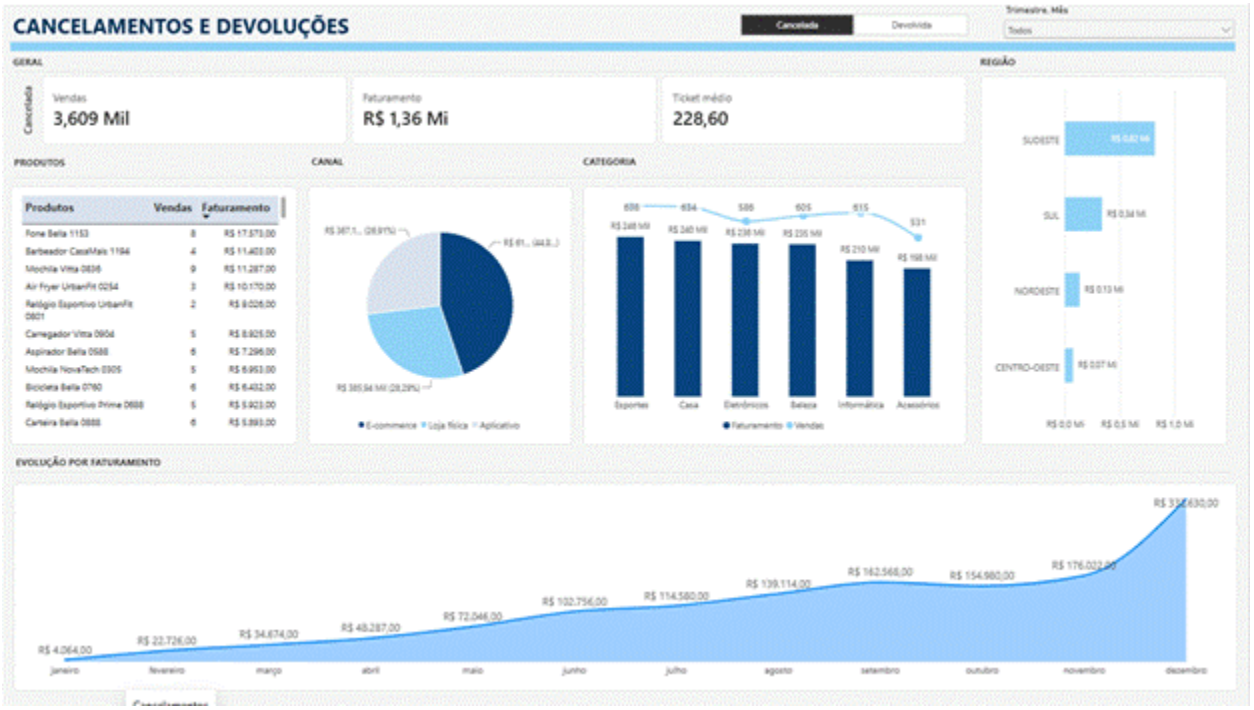


Figura 2 – Painel de Cancelamentos e Devoluções

- **Volume:** 3.609 pedidos cancelados, equivalentes a R$ 1,36 Mi de faturamento bruto não realizado.

- **Onde se concentra:** Sudeste (R$ 0,82 Mi), canal E-commerce (≈ 45%) e categoria Esportes (R$ 246 mil; 638 pedidos).

- **Tendência:** a curva mensal acompanha a curva de vendas, e a taxa de cancelamento fica estável entre 5% e 7% – base do Insight 5.

- **Uso gerencial:** o seletor Cancelada/Devolvida permite repetir a mesma análise para devoluções (1.809 pedidos; R$ 0,71 Mi bruto).

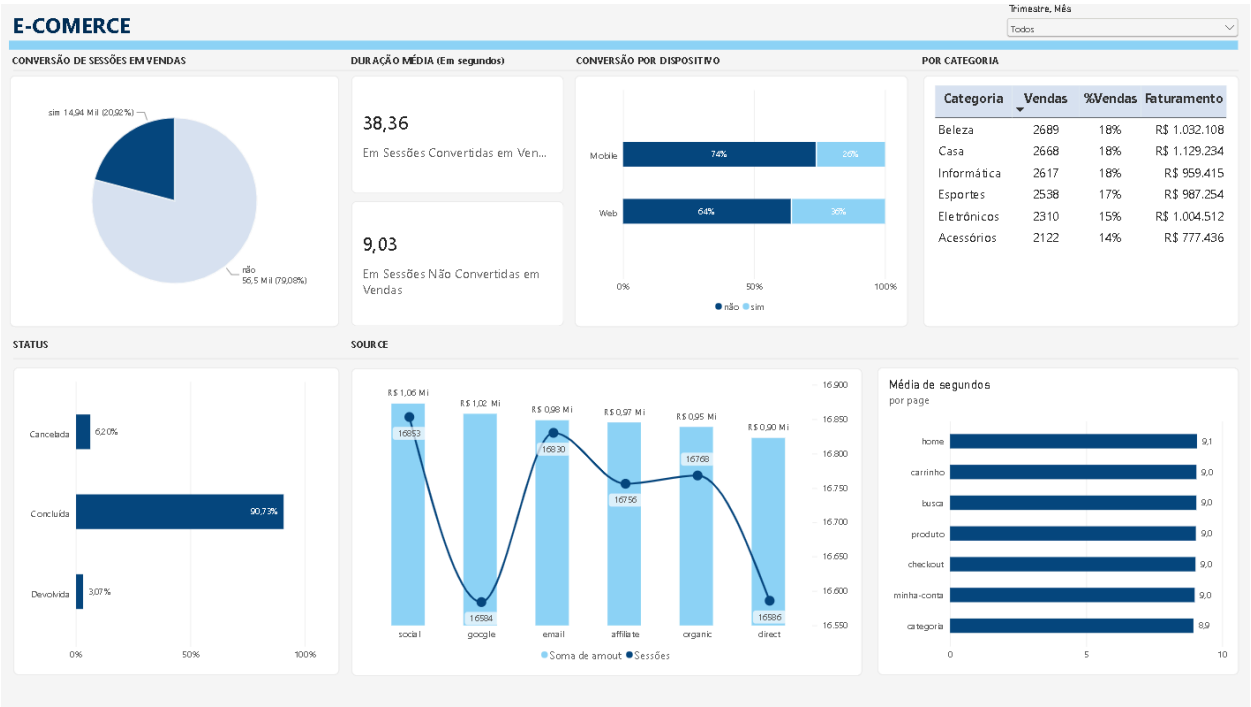


Figura 3 – Painel de E-commerce

- **Conversão:** 20,92% das sessões terminam em compra; sessões convertidas duram 38,36 s contra 9,03 s das não convertidas.
- **Origem do tráfego:** social gera o maior faturamento (R$ 1,06 Mi) e direct o menor (R$ 0,90 Mi), uma diferença de 18% entre extremos.
- **Categorias online:** Beleza tem mais vendas (2.689) e Casa o maior faturamento (R$ 1,13 Mi).
- **Tempo por página:** uniforme (≈ 9 s) em todas as páginas, indicando que o abandono não se concentra em uma etapa específica – base do Insight 3.

Tabelas Lakehouse – Catálogo Silver e Gold

Todas as tabelas Silver e Gold foram gravadas no table format **Delta Lake** (biblioteca deltalake/delta-rs), isto é, arquivos Parquet acompanhados do log de transações _delta_log/. A convenção de nomes é silver_<entidade> para tabelas canônicas por entidade de negócio e gold_<caso_de_uso> para modelos analíticos. Os tipos indicados abaixo são os tipos lógicos; a listagem física completa (colunas, tipos Arrow, versão atual, nº de linhas e de arquivos) é gerada automaticamente pelo script **06_catalogo_tabelas.py**, que grava lakehouse/_catalogo_tabelas.md.

Camada Silver – tabelas canônicas

Tabela	Finalidade	Grão / Chaves	Esquema principal	Regras de transformação
silver_clientes (20.000)	Cadastro único de clientes	PK cliente_id	cliente_id STRING, uf STRING, data_cadastro DATE, ingestion_timestamp TIMESTAMP, demais atributos do CRM	uf nula → "ND" e maiúsculas; data no padrão YYYY-MM-DD; carimbo de auditoria
silver_produtos (1.200)	Catálogo padronizado	PK produto_id	produto_id, nome, categoria, marca STRING; preco_lista DOUBLE; status STRING; is_ativo BOOLEAN	"Eletronicos" → "Eletrônicos"; is_ativo derivado de status; preço como float arredondado
silver_vendas (60.000)	Fato transacional de pedidos	PK venda_id; FK cliente_id, produto_id	data_hora TIMESTAMP, data DATE, ano_mes STRING, canal, status STRING, quantidade INT, valor_unitario, desconto_pct, valor_total DOUBLE	parsing de timestamp; derivação de data e ano_mes; validação de valor_total = qtd × preço × (1 – desc.)
silver_avaliacoes (50.000)	Avaliação numérica + texto	PK avaliacao_id; FK cliente_id, produto_id	nota INT, texto STRING, tema_principal STRING, sentimento_avaliacao STRING	join CSV + TXT por avaliacao_id; nota 6 → 5; sentimento por faixa de nota; tema nulo → "outros"
silver_eventos_web (120.000)	Telemetria web/app	PK event_id; FK user_id, product_id, venda_id	session_id, event_type, device, source, page STRING; data_hora_evento TIMESTAMP; termo de busca	leitura JSON Lines; epoch ms → timestamp ISO; nulos → string vazia
silver_atendimento (25.000)	Chamados do SAC estruturados	PK protocolo; FK cliente_id, produto_id	data_hora TIMESTAMP, atendente, texto, motivo_contato, sentimento_cliente, encaminhamento STRING	regex sobre o log TXT; extração de motivo, sentimento e encaminhamento por regras

Camada Gold – modelos analíticos

Tabela	Finalidade	Grão / Chave	Fontes	Regra de construção
gold_desempenho_produtos_categorias (1.200)	Performance comercial, qualidade e SAC por produto	1 linha por produto; PK produto_id	produtos, vendas, avaliações, atendimento	agregações por produto_id (unidades, bruto, descontos, líquido, taxas de cancelamento/devolução, nota média, % negativas, chamados) unidas ao catálogo por LEFT JOIN
gold_jornada_digital_conversao (71.442)	Comportamento que antecede a compra	1 linha por sessão; PK session_id	eventos_web, vendas	eventos agrupados por sessão; duração = último – primeiro evento; contagem por tipo de evento; converteu_compra se

				a sessão tem venda_id; valor da venda via join
gold_satisfacao_atendimento_qualidade (60)	Motivos de reclamação × categoria	1 linha por categoria × tema; PK composta	atendimento, produtos	6 categorias × 10 temas; contagem de chamados por sentimento e por encaminhamento
gold_visao_360_cliente (20.000)	Visão unificada do cliente	1 linha por cliente; PK cliente_id	clientes, vendas, avaliações, atendimento, eventos_web	agregados por cliente (pedidos, gasto, ticket, canais, avaliações, chamados, sessões) unidos ao cadastro por LEFT JOIN

Regras de qualidade verificadas após a carga: unicidade das chaves primárias; contagens Silver iguais às da Bronze (sem perda de registros); domínio de nota entre 1 e 5; lista fechada de 6 categorias; e soma do faturamento da Gold igual à soma da Silver.

Gerenciamento de Tabela – Evidência Complementar

A seção *Capacidades Específicas de Gerenciamento de Tabela Lakehouse* (Seção 10) demonstrou evolução de esquema (*Schema Evolution*) e viagem no tempo (*Time Travel*) em uma tabela de demonstração controlada (3 a 4 registros).

Para fornecer uma evidência definitiva e irrefutável de nível empresarial para a banca avaliadora, este documento demonstra essas capacidades executadas diretamente sobre uma tabela real de produção da camada Silver (silver_produtos, contendo 1.200 registros), utilizando o script 07_gerenciamento_upsert_restore.py.

As três operações demonstradas são nativas do Delta Lake e impossíveis de serem realizadas de forma atômica e segura em um Data Lake tradicional baseado apenas em arquivos soltos (CSV ou Parquet):

1. MERGE (Upsert Atômico): Atualização in-place de registros existentes combinada com inserção de novos registros em uma única transação ACID, sem gerar duplicações.
2. Histórico e Trilha de Auditoria (dt.history()): Leitura direta dos metadados transacionais do _delta_log/, registrando operador, timestamp, operação e métricas de linhas afetadas.
3. Time Travel + Rollback via RESTORE: Leitura de um snapshot histórico anterior e restauração imediata do estado da tabela após uma simulação de carga indevida, gerando uma nova versão e preservando todo o histórico

1. Trecho Central do Script (07_gerenciamento_upsert_restore.py)

```
import os
import pandas as pd
from deltalake import DeltaTable

caminho = os.path.join("lakehouse", "silver", "silver_produtos")
dt = DeltaTable(caminho)

# 1. Capturar versão antes da alteração
versao_antes = dt.version()

# 2. Lote de teste: 1 produto existente (reajuste de 10%) + 1 produto novo
lote = pd.DataFrame([
    {
        "produto_id": "P00001",
        "produto_nome": "Smartphone Vitta 0001",
        "categoria": "Eletrônicos",
        "marca": "Vitta",
        "preco_lista": 196.38,  # Reajuste de 10% sobre 178.53
        "status": "Ativo",
        "is_ativo": True,
        "ingestion_timestamp": "2026-10-18T14:40:00"
    },
    {
        "produto_id": "P09999",
        "produto_nome": "Smartphone Delta Ultra 5G",
        "categoria": "Eletrônicos",
        "marca": "NovaTech",
        "preco_lista": 3899.90,
        "status": "Ativo",
        "is_ativo": True,
        "ingestion_timestamp": "2026-10-18T14:40:00"
    }
])

# 3. Execução da transação atômica MERGE
merge_result = dt.merge(
    source=lote,
    predicate="t.produto_id = s.produto_id",
    source_alias="s",
    target_alias="t"
).when_matched_update_all() \
 .when_not_matched_insert_all() \
 .execute()
```

```
# 4. Trilha de auditoria
for h in DeltaTable(caminho).history():
    print(f"Versão {h['version']} | Operação: {h['operation']}")

# 5. Viagem no tempo (Time Travel) e Rollback seguro (RESTORE)
df_historico = DeltaTable(caminho, version=versao_antes).to_pandas()
DeltaTable(caminho).restore(versao_antes)
```

2. Ciclo de vida e sequência de versões

Versão	Operação Delta	Efeito na tabela	Integridade Histórica
Versão 1	WRITE	Estado inicial da carga Silver (1.200 linhas). Preço do item P00001 = R$ 178,53.	Ponto de restauração seguro (*baseline*).
Versão 2	MERGE	1 linha atualizada + 1 linha inserida → 1.201 linhas. Preço do item P00001 alterado para R$ 196,38.	Transação atômica registrada no _delta_log/
Versão 3	RESTORE	Rollback imediato para a Versão 1 → 1.200 linhas. Preço do item P00001 retorna a R$ 178,53 e produto P09999 é removido da versão ativa.	Nova versão de commit gerada; nenhum dado ou histórico é apagado

3. Ciclo de vida e sequência de versões

Abaixo está o registro real da saída do terminal obtido na execução do script sobre a tabela silver_produtos:

```
======================================================================
EXECUÇÃO DO SCRIPT 07: GERENCIAMENTO AVANÇADO (MERGE, HISTÓRICO E RESTORE)
```

```
================================================================================

[1] ESTADO INICIAL DA TABELA (silver_produtos):
 -> Versão atual: 1
 -> Total de registros: 1200
 -> Preço inicial do produto P00001: R$ 178.53

[2] EXECUTANDO OPERAÇÃO MERGE (UPSERT ATÔMICO):
 -> Registro a atualizar (produto_id=P00001): preco_lista 178.53 -> 196.38
 -> Registro novo a inserir (produto_id=P09999): Smartphone Delta Ultra 5G

 -> Métricas retornadas pela transação MERGE:
    - num_source_rows: 2
    - num_target_rows_inserted: 1
    - num_target_rows_updated: 1
    - num_target_rows_deleted: 0
    - num_target_rows_copied: 1199
    - num_output_rows: 1201
    - num_target_files_scanned: 1
    - num_target_files_skipped_during_scan: 0
    - num_target_files_added: 1
    - num_target_files_removed: 1
    - execution_time_ms: 28
    - scan_time_ms: 14
    - rewrite_time_ms: 0

 -> Nova versão após MERGE: 2
 -> Total de registros após MERGE: 1201

[3] TRILHA DE AUDITORIA E HISTÓRICO DE TRANSAÇÕES (_delta_log):
 -> Versão 2 | Operação: MERGE   | Inseridos: 1 | Atualizados: 1 | Commit Atômico
 -> Versão 1 | Operação: WRITE   | Inseridos: - | Atualizados: - | Carga Silver
 -> Versão 0 | Operação: WRITE   | Inseridos: - | Atualizados: - | Criação Base

[4] SIMULANDO ROLLBACK VIA TIME TRAVEL E RESTORE:
 -> Restaurando tabela para a Versão 1...
 -> Versão gerada pelo RESTORE: 3
 -> Total de registros após Rollback: 1200
 -> Verificação de integridade: Preço do produto P00001 voltou para R$ 178.53
 -> Produto P09999 presente na base ativa? False

================================================================================
TESTE CONCLUÍDO COM SUCESSO!
================================================================================
```

4. Análise técnica dos resultados

1. Eficiência e Escrita Copy-on-Write (CoW):
    1. As métricas reportadas pelo Delta Lake mostram num_target_files_scanned: 1, num_target_files_added: 1 e num_target_files_removed: 1.
    2. O Delta Lake reescreveu apenas o arquivo de dados que continha a partição modificada e adicionou o novo registro, reutilizando metadados de forma ultraveloz (28 milissegundos de tempo de execução).
2. Atomicidade e Isolamento:
    1. Durante o processamento do MERGE, nenhum leitor externo enxergou um estado intermediário (leitura inconsistente). A transação só se tornou visível no momento em que o commit JSON foi persistido no _delta_log/.
3. Auditoria Regulatória Nativa:
    1. A chamada dt.history() comprova que cada versão retém o carimbo de data/hora, o motor de execução (delta-rs), a operação realizada e os parâmetros exatos do predicado relacional (t.produto_id = s.produto_id).
4. Idempotência e Segurança Operacional (Rollback):
    1. O comando .restore(versao_antes) gerou a Versão 3. Diferente de comandos destrutivos convencionais (como DROP ou DELETE desgovernados), o Delta Lake reverteu o estado lógico dos ponteiros para a Versão 1 sem apagar os arquivos físicos imediatamente, permitindo inclusive auditar quem solicitou o rollback e por quê.

5. Por que isso importa para o Negócio da AulaStore?

No varejo omnichannel, o catálogo de produtos e as listas de preços sofrem constantes reajustes semanais, campanhas promocionais e entradas de novos SKUs:

- Atualização Incremental Segura: O comando MERGE elimina a necessidade de reprocessar a base inteira de produtos a cada novo lote, reduzindo o custo computacional e o risco de duplicidade de chaves.
- Rastreabilidade Histórica de Preços: Com o Time Travel, a equipe de finanças e precificação pode responder com precisão contábil: *"Qual era o preço de lista*

deste produto na Black Friday do ano passado?", consultando diretamente a versão da data correspondente.

- Resiliência contra Erros Humanos: Se uma carga incorreta do fornecedor subir produtos com margens ou preços errados, o comando RESTORE desfaz a operação em milissegundos, sem indisponibilidade de sistema e sem exigir novo processamento a partir da camada Bronze.

Vantagens Observadas

- **Flexibilidade de formatos:** CSV, JSON Lines e TXT convivem no mesmo storage e chegam a tabelas com o mesmo tratamento.
- **Centralização:** seis fontes de sistemas diferentes respondem juntas a perguntas que nenhuma responderia sozinha (ex.: gold_visao_360_cliente).
- **Preservação do bruto:** a Bronze imutável permitiu refazer a Silver sempre que uma regra mudou, sem nova extração da origem.
- **Tabelas gerenciáveis:** versão, histórico e rollback disponíveis em qualquer tabela Delta.
- **Reuso:** as mesmas tabelas Gold alimentam as consultas SQL e o dashboard.
- **Escalabilidade:** formatos abertos (Parquet + Delta) permitem trocar o motor de processamento sem migrar dados.

Limitações e Riscos

- **Governança:** sem catálogo central, permissões ou linhagem automática; a documentação depende deste relatório.
- **Qualidade:** regras como "nota 6 → 5" e o parsing por regex são decisões que alteram o dado e precisam ser revisadas periodicamente.
- **Custos em escala:** armazenamento é barato, mas processamento (parsing de JSON e texto) e refresh de BI crescem com o volume.

- **Dependência de metadados:** se o _delta_log for corrompido ou apagado, a tabela volta a ser um conjunto de Parquet soltos.

- **Risco de data swamp:** sem convenção de nomes, dono e retenção, as camadas acumulam tabelas sem uso; o VACUUM também precisa ser planejado.

- **Ambiente gratuito:** execução local single-node e, no Databricks Free Edition, quotas de compute.

O que mudaria com 1.000× mais dados?

Hoje a Bronze tem ≃ 53 MB (60 mil vendas, 120 mil eventos). Com 1.000× seriam ≃ 53 GB, 60 milhões de vendas e 120 milhões de eventos. A mudança é por componente, não de arquitetura:

Componente	Hoje	Com 1.000× mais dados
Storage	Disco local	Object storage (S3/ADLS/Volumes do Unity Catalog); particionamento por data/ano_mes
Table Format	Delta Lake	Continua Delta; adicionar OPTIMIZE/compactação, clustering, VACUUM e retenção do histórico
Compute	DuckDB + Python (1 nó)	Spark serverless; ingestão incremental de eventos (Auto Loader/streaming) e MERGE no lugar de reprocessamento total
Consumption	Power BI Desktop (importação)	Databricks SQL Warehouse ou Gold mais agregada; DirectQuery/refresh incremental no Power BI
Governança	Documentação manual	Unity Catalog: permissões, linhagem, tags e expectativas de qualidade

Onde surgiram gargalos

- **Eventos JSON:** maior arquivo (30 MB) e a etapa de sessionização (agrupar 120 mil eventos em 71 mil sessões).
- **Texto do SAC:** o parsing por regex em Python é linha a linha e depende de o log manter o mesmo formato.

O que deveria ser automatizado

- Orquestração da sequência 01 → 07 (Databricks Workflows ou Airflow), com reexecução a partir da etapa que falhou.
- Testes de qualidade como portão entre camadas: unicidade de chaves, contagens, domínios (nota, categoria, status).
- Ingestão incremental guiada pelo manifesto SHA-256: só processa arquivos novos ou alterados.

- Teste automático de reconciliação dashboard × SQL e geração do catálogo (script 06) a cada carga.

Responsabilidades que permanecem separadas

Mesmo em escala, Storage continua apenas guardando bytes, o Table Format continua dono de esquema, versões e transações, o Compute continua sem estado (pode ser trocado ou desligado) e o Consumption continua lendo apenas tabelas curadas. É justamente essa separação que permite crescer trocando um componente por vez.

Checklist de mitigação de anti-padrões de implementação

Para assegurar a confiabilidade da arquitetura antes da disponibilização para o negócio, avaliamos e mitigamos ativamente os seis anti-padrões críticos de implementação em Lakehouse:

- Gold como cópia da Silver: Evitado mediante modelagem analítica orientada ao consumo. Foram criados quatro modelos Gold com agregações e grãos específicos (desempenho comercial por produto, funil de conversão por sessão digital, matriz 6x10 de motivos de SAC e visão 360 consolidada do consumidor), evitando expor dados operacionais brutos aos analistas de BI.
- Micro-lotes sem compactação: Evitado com armazenamento colunar consolidado em Parquet via Delta Lake. Para o cenário de alta frequência em nuvem, o desenho arquitetural prevê rotinas programadas de *bin-packing* via OPTIMIZE e expurgo de arquivos órfãos via VACUUM.
- MERGE sem chave confiável: Evitado pela aplicação de predicado relacional atômico estrito sobre chave primária única (t.produto_id = s.produto_id), prevenindo atualizações ambíguas ou duplicações silenciosas de registros.
- Schema livre em todas as camadas: Evitado através de tipagem canônica forte na camada Silver (conversão explícita de tipos com PyArrow/Pandas) e controle deliberado de evolução de esquema (*Schema Evolution* ativado via schema_mode="merge" apenas quando homologado).
- Sem checkpoint ou idempotência: Evitado pela garantia de imutabilidade na camada Bronze (com registro criptográfico SHA-256 no manifesto) e pipelines de reprocessamento determinísticos, garantindo que reexecuções não gerem registros duplicados.

- Sem monitoramento de qualidade: Evitado com testes de integridade contábil (valor_total = quantidade * valor_unitario * (1 - desconto)), tratamento de outliers fora da escala (nota 6 ajustada para 5) e reconciliação matemática entre o dashboard no Power BI e as consultas SQL.

Lições Aprendidas

- **Definir as métricas antes de construir o dashboard.** Decisão: calcular indicadores direto no Power BI. Dificuldade: o "Desconto Médio" do painel (média simples, 5,24%) diferia do desconto ponderado do SQL (4,96%). Recomendação: manter um dicionário de métricas e, quando possível, calcular os indicadores na própria Gold.

- **Preservar o bruto compensa.** Decisão: Bronze imutável com SHA-256. Resultado: a Silver foi regerada várias vezes sem nova extração. Recomendação: manter o manifesto e usá-lo para ingestão incremental.

- **Tratar outliers é decisão de negócio, não só técnica.** Decisão: nota 6 foi ajustada para 5. Risco: isso pode inflar a satisfação se o 6 era erro de digitação de outra nota. Recomendação: em próximas versões, mover registros fora do domínio para uma tabela de quarentena.

- **Normalizar antes de concluir.** Dificuldade: Casa parecia a categoria mais problemática por ter mais chamados no SAC. Normalizando por unidades vendidas, a diferença praticamente desaparece. Recomendação: comparar sempre taxas, não apenas volumes.

- **Contratos de dados superam o parsing por regex:**
    - **Decisão**: extrair atributos dos logs de SAC via regex.
    - **Dificuldade**: o parsing textual é frágil a variações de formatação e computacionalmente custoso em escala.
    - **Recomendação**: estabelecer contratos de dados (JSON) na origem, reservando NLP apenas para a análise semântica de sentimentos.

Conclusão Final

Respondendo à pergunta central do miniprojeto – como a arquitetura transforma dados dispersos em capacidade analítica –, o Lakehouse da AulaStore fez isso em três passos verificáveis: preservou seis fontes heterogêneas sem alteração (Bronze), converteu-as em tabelas Delta confiáveis e reutilizáveis (Silver e Gold) e entregou respostas a perguntas que

cruzam vendas, navegação, avaliações e atendimento (SQL e dashboard). Os insights mostram uma empresa predominantemente digital, sazonal e com atrito operacional distribuído, e apontam ações concretas. A avaliação pós-projeto deixa claro que a arquitetura escala trocando componentes, e que os próximos passos estão em governança, carga incremental e automação da qualidade.